Trabalho Final

Especialização em IA e Machine Learning

Módulo: Fundamentos de Machine Learning - Stella Sposito

Integrantes do Grupo

Rafael Silva

Deivison

Fabrício Londero

Jéssica

Sábinë Márígo

Análise Preditiva de Churn em Telecomunicações

Análise Preditiva de Churn

Abordagem Técnica: EDA, Processamento e Modelagem Avançada

- **Análise Exploratória Profunda**
- **Pipeline de Processamento Robusto**
- **Modelagem e Tuning Avançado**

DATASET: 7.043 CLIENTES | 21 VARIÁVEIS | 26.5% CHURN

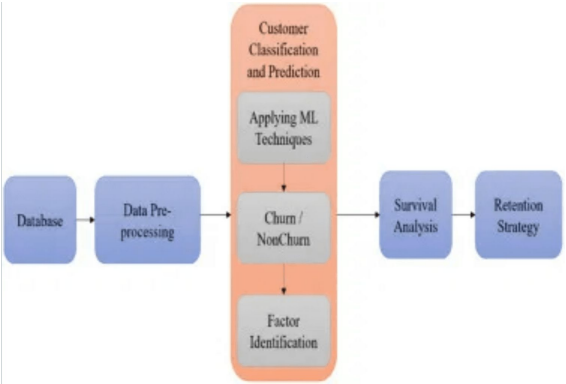

Contratos mensais e perfil demográfico revelam padrões claros de churn

Taxa de Churn por Tipo de Contrato

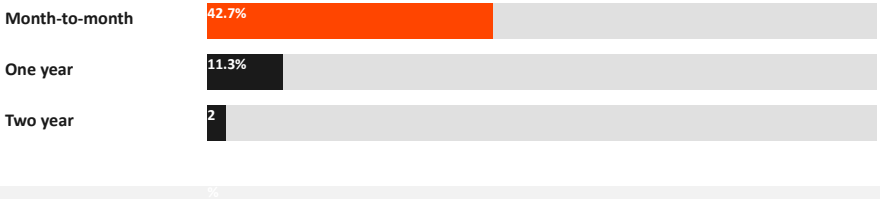

Churn por Perfil Demográfico

Fator Tenure

Correlação Inversa

Clientes com **tenure < 12 meses** apresentam risco crítico. A taxa de retenção estabiliza significativamente após o primeiro ano de contrato.

Insight Crítico

A flexibilidade contratual é o maior preditor de risco: contratos mensais aumentam a probabilidade de churn em **15 vezes** comparado a contratos de dois anos.

Pipeline de pré-processamento garante qualidade e compatibilidade

Limpeza

Tratamento de 11 nulos em TotalCharges (imputação).

Encoding

One-Hot Encoding: 21 ⟶ 32 features.

Escala

StandardScaler para normalização (z-score).

Split

Divisão 80/20 estratificada por classe.

Target

Codificação binária do Churn (0/1).

Estratégia de Dados Ausentes

Apenas 0.2% dos dados em TotalCharges eram nulos. A conversão para float e imputação pela mediana preservou a integridade do dataset sem introduzir viés significativo.

Decisão sobre Balanceamento

O desbalanceamento de classes (73.5% / 26.5%) foi mantido intencionalmente nesta fase para avaliar a performance real dos modelos em cenário natural, antes de aplicar técnicas sintéticas como SMOTE.

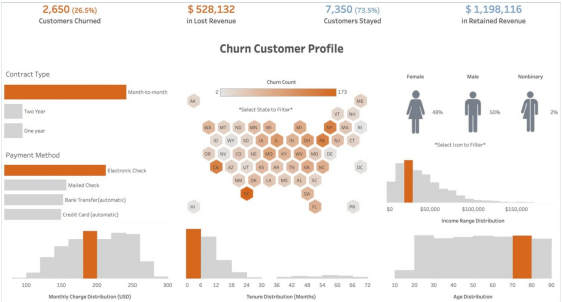

Gradient Boosting lidera com ROC-AUC de 0,8358, seguido por Logistic Regression

Modelo	ROC-AUC	PR-AUC	Accuracy	Precision	Recall	F1-Score
Gradient Boosting	**0.8358**	**0.6474**	**0.79**	**0.65**	**0.52**	**0.58**
Logistic Regression	0.8307	0.6232	0.79	0.62	0.49	0.55
AdaBoost	0.8303	0.6405	0.79	0.62	0.52	0.56
Random Forest	0.8143	0.6159	0.78	0.60	0.48	0.53
SVC	0.7786	0.6003	0.79	0.65	0.46	0.54
KNN	0.7567	0.5184	0.74	0.51	0.51	0.51
Decision Tree	0.6565	0.5605	0.73	0.50	0.50	0.50

Vencedor: Gradient Boosting

Melhor capacidade de discriminação (ROC-AUC) e robustez em dados desbalanceados (PR-AUC). Apresenta o melhor equilíbrio geral.

Baseline Forte

Logistic Regression surpreende com performance muito próxima ao topo (apenas 0.5% abaixo), sendo uma alternativa rápida e interpretável.

Desafio de Recall

Todos os modelos apresentam **Recall moderado (~0.50)**. O desbalanceamento de classes (26.5% churn) dificulta a identificação de todos os casos positivos sem ajustes de threshold.

GridSearch e RandomizedSearch refinam Random Forest, elevando ROC-AUC para 0,8265

GridSearch

43.7s	60	0.8265
Tempo	Fits	ROC-AUC

n_estimators=100, max_depth=10, min_samples_split=5

RandomizedSearch

140.7s	100	~0.826
Tempo	Fits	ROC-AUC

n_estimators=152, max_depth=10, min_samples_split=3

+1.2 p.p.

Ganho de Performance

vs Baseline (0.8143)

Gradient Boosting é o modelo recomendado para produção

Modelo Vencedor

Gradient Boosting

0.8358	0.6474	0.79
ROC-AUC	PR-AUC	Accuracy

- **Performance Superior:** Melhor equilíbrio entre discriminação de classes e generalização.
- **Tuning Efetivo:** Otimização de hiperparâmetros gerou ganhos reais (+1.2 p.p. no RF).
- **Atenção ao Recall:** Desbalanceamento limita a sensibilidade (~50%); requer técnicas de sampling.

Roteiro de Evolução

01 **Balanceamento (SMOTE)**

02 **Feature Engineering Temporal**

03 **Ensemble Stacking**

04 **Calibração de Probabilidades**