

Processamento de Linguagem Natural e LLMs

Prof. Msc. Renato Camacho
renato@propetec.com.br

RENATO CAMACHO NEVES, MSc

Formação Acadêmica

- Graduação em Administração - Registro (CRA-SP nº 87.456)
- Graduação em Pedagogia

Especializações e MBAs

- MBA /Especialização em Gestão Estratégica de Marketing
- MBA em Ciência de Dados e Inteligência Artificial
- Especialização em Governança e Tecnologia da Informação

Mestrado

- Mestrado em Engenharia de Produção

Certificações e Atuação em Normas ISO

- Auditor Líder ISO/IEC 27001:2022
 - Sistema de Gestão de Segurança da Informação (SGSI)



Telefone

18 99785-1414



Site

www.propetec.com.br



E-mail

renato@propetec.com.br



LinkedIn

linkedin.com/in/renato-camacho



YouTube

youtube.com/@propetec



Instagram

[@propetec.consultoria](https://instagram.com/propetec.consultoria)

Ementa

Fundamentos teóricos e práticos do Processamento de Linguagem Natural, com ênfase em modelos de linguagem de grande porte (LLMs).

Desenvolvimento de aplicações avançadas baseadas em Transformers, embeddings semânticos, fine-tuning e integração de LLMs em sistemas corporativos.

Capacitar o aluno a projetar soluções robustas de PLN, utilizando desde técnicas clássicas até LLMs modernos, avaliando desempenho, confiabilidade, explicabilidade e riscos associados.



Processamento de Linguagem Natural

Definição Fundamental

Processamento de Linguagem Natural (PLN) é uma área da Inteligência Artificial que permite que computadores compreendam, interpretem e respondam à **linguagem humana de forma significativa**. Integra linguística, ciência da computação e aprendizado de máquina.

Definição Fundamental

"PLN transforma palavras em dados processáveis por máquinas, reconhecendo contexto e intenção por trás das entradas dos usuários."

Pilares do PLN



💡 Insight

O PLN está presente em **bilhões de interações diárias**, tornando a comunicação humano-máquina mais natural e intuitiva.

O que é PLN?

Área da inteligência artificial que capacita máquinas a compreender, interpretar e gerar linguagem humana de modo útil, contextualizado e significativo.

Por que é importante?

- Automatiza tarefas manuais envolvendo grandes volumes de texto
- Melhora o aproveitamento de dados não estruturados
- Eleva a qualidade da experiência (chatbots, busca inteligente, atendimento)
- Permite extrair insights relevantes para análise e tomada de decisão

Aplicações Práticas



Análise de Sentimentos



Tradução Automática



Chatbots & Assistentes



Resumo de Textos

O que o PLN faz

- classifica sentimento
- extrai nomes e datas
- resume documentos
- responde perguntas
- traduz textos
- organiza e-mails

PLN - Processamento de Linguagem Natural

Linguística + Computação
X
Computação + Linguística

- **LINGUÍSTICA**
Modela a linguagem
- **COMPUTAÇÃO**
Implementa os modelos

Do TEXTO BRUTO À DECISÃO

Transformando Linguagem em Apoio à Decisão Estruturada



Texto Bruto



Pré-Processamento



Representação Textual



Análise Linguística



Modelagem



Avaliação



Aplicação Empresarial



Risco e Governança

**O Valor Está na Transformação
da Linguagem em Suporte Estruturado
à Decisão.**



Se há tanto texto nas empresas, por que ainda se perde tanta informação?

Exemplos

- ✉ E-mails
- 📄 Contratos
- 📑 Pareceres
- 📄 Relatórios
- 📑 Políticas internas
- 🗣 Chamados
- 📄 Atas
- ✉ Mensagens
- 📄 Currículos
- 💬 Feedbacks

Grande parte do conhecimento organizacional está em linguagem natural, e não em formato estruturado.

Sem método, texto vira custo oculto.

Com Processamento de Linguagem Natural, texto pode virar análise, automação e decisão.

Problema central



Alto volume



Baixa padronização



Leitura manual lenta



Dificuldade de busca



Retrabalho



Conhecimento disperso

Evolução da Inteligência Artificial (IA)



Insight: A IA evoluiu de **regras** → **dados** → modelos adaptativos em escala

Fonte: Stanford HAI (AI Index), IBM, AI100

FONTES LINKS DIRETOS

Inteligência Artificial (IA)

Fontes

- Stanford Human-Centered AI Institute

 <https://aiindex.stanford.edu>

(Relatório global mais utilizado sobre evolução da IA)

- Stanford University

 <https://ai100.stanford.edu>

(Estudo oficial de longo prazo sobre IA)

- IBM

 <https://www.ibm.com/think/topics/history-of-artificial-intelligence>

Evolução do Processamento de Linguagem Natural (PLN)



Insight: O PLN evoluiu de gramática → probabilidade → **contexto semântico**

Fonte: Jurafsky & Martin, ACL, DeepLearning.AI

FONTES LINKS DIRETOS

- Speech and Language Processing

👉 <https://web.stanford.edu/~jurafsky/slp3/>

(Principal livro acadêmico de PLN no mundo)

- Association for Computational Linguistics

👉 <https://aclanthology.org>

(Base científica oficial de artigos de PLN)

- DeepLearning.AI

👉 <https://www.deeplearning.ai/resources/natural-language-processing/>

Evolução dos Large Language Models (LLMs)



Insight: LLMs transformaram a IA em interface de decisão e execução

Fonte: Vaswani et al. I (2017), Devlin et al. (2018), Brown et al. (2020)

FONTES LINKS DIRETOS

LLMs

Papers fundamentais

- Attention Is All You Need

 <https://arxiv.org/abs/1706.03762>

(Criação dos Transformers)

- BERT Pre-training of Deep Bidirectional Transformers

 <https://arxiv.org/abs/1810.04805>

(Base do NLP moderno)

- Language Models are Few-Shot Learners

 <https://arxiv.org/abs/2005.14165>

(Base dos LLMs em escala)

Pipeline clássico de Processamento de Linguagem Natural

Do texto bruto à informação utilizável para análise, automação e decisão



Processamento de Linguagem Natural não é uma técnica isolada.

É um fluxo de etapas que transforma texto em informação utilizável.

Níveis essenciais do Processamento de Linguagem Natural

Da palavra ao contexto: como a linguagem é analisada em diferentes camadas



Baixa Complexidade Interpretativa

Alta Complexidade Interpretativa

Quanto mais avançado o problema, mais importante se torna o contexto.

PLN - Processamento de Linguagem Natural

Quão difícil é processar automaticamente a linguagem natural?

O	menino	foi	para	a	escola	de	ônibus	.
---	--------	-----	------	---	--------	----	--------	---

Tokenização

Tokenização

Dividir o texto em unidades menores para que o computador consiga processar a linguagem

Texto original:

“A inteligência artificial ajuda empresas.”

Tokenização por palavras:

“A” “inteligência,” “artificial,” “ajuda,” “empresas”

Tokenização por subpalavras

“in” “feliz”, “mente”

“infeliz” “mente”

▶ [infeliz, mente] → [“in”, “mente”]


Os tokens podem ser:

- Ab palavras
- ≡ partes de palavras
- # símbolos
- 123 números
- pontuação

A tokenização é a etapa que transforma o texto em partes menores para análise computacional.

PLN - Processamento de Linguagem Natural

Quão difícil é processar automaticamente a linguagem natural?



Etiquetação morfossintática

Etiquetação Morfossintática

Classificar cada palavra de acordo com sua função gramatical

Frase Original:

“A inteligência artificial transforma empresas.”

Etiquetação:


A	inteligência	artificial	transforma	empresas
Artigo	Substantivo	Adjetivo	Verbo	Substantivo

Para que serve:

-  Entender a estrutura das frases
-  Melhorar a interpretação de texto
-  Apoiar tradução automática
-  Auxiliar análise de dados textuais
-  Melhorar respostas de sistemas de IA

A etiquetação morfossintática atribui a cada palavra uma classe gramatical, permitindo a análise estrutural e semântica do texto.

Quão difícil é processar automaticamente a linguagem natural?



Análise sintática

Análise Sintática

Identificar a função de cada termo na estrutura da frase

Frase original:

"A inteligência artificial
transforma empresas."

Estrutura Sintática:

**A inteligência
artificial**

Sujeito

transforma

Verbo (Predicado)

empresas


Objeto Direto

Para que serve:

-  Identificar relações entre palavras
-  Compreender o sentido da frase
-  Melhorar interpretação de texto
-  Apoiar sistemas de tradução
-  Melhorar respostas de sistemas de IA

A análise sintática estuda a estrutura das frases, identificando as funções e relações entre seus termos.

Quão difícil é processar automaticamente a linguagem natural?



Análise Semântica
Semântica Lexical

Análise Semântica vs Semântica Lexical

Compreensão do significado na linguagem

Análise Semântica

"O banco está fechado."

-  **Banco** = Instituição financeira
-  **Banco** = Assento




Interpretação correta
depende do contexto

Palavra → Contexto → Significado

Semântica Lexical

"Banco"



- Instituição financeira
- Assento



Análise Semântica:

Compreende o significado da frase no contexto.

Semântica Lexical:

Estuda o significado das palavras individualmente.

Linguagem

Linguagem natural é a linguagem que os seres humanos usam no dia a dia, de forma espontânea.

*Exemplos: **português, inglês, espanhol.***

Ela tem contexto, ambiguidade, emoção, ironia e variações culturais.

Linguagem artificial é uma linguagem criada de forma planejada para um objetivo específico.

*Exemplos: **linguagens de programação** como Python, Java e SQL, ou linguagens formais usadas em lógica e matemática.*

Ela costuma ser mais exata, estruturada e com menos ambiguidade.

Em resumo

- **Natural** → surge do uso humano e da comunicação social.
- **Artificial** → é construída para regras, controle e precisão.

Linguagens

- **Linguagem natural** serve para comunicação humana.
Linguagem artificial serve para executar regras, comandos ou representar algo com precisão.
- **Ambiguidade**
Linguagem natural pode ter vários sentidos.
Linguagem artificial busca ter um único sentido.
- **Exemplo:**
 - Natural: “Está quente aqui.”
Pode ser só uma observação ou um pedido para ligar o ar.
 - Artificial: um comando precisa ser exato.

- **Regras**

Linguagem natural tem regras, mas muda com o tempo e varia conforme região e cultura.

Linguagem artificial tem regras definidas e mais rígidas.

- **Contexto**

Linguagem natural depende muito do contexto.

Linguagem artificial depende mais da sintaxe e da estrutura correta.

- **Emoção e subjetividade**

Linguagem natural expressa emoção, ironia, humor e intenção.

Linguagem artificial não foi feita para emoção, mas para instrução e precisão.

NÍVEIS LINGUÍSTICOS

Podem ser entendidos de **duas formas principais** na área de linguagem.

1. Níveis linguísticos como formas de uso da língua

São os modos como a língua varia conforme contexto, grupo social e situação de comunicação.

- **Linguagem culta ou padrão**

É a variedade mais formal, usada em textos acadêmicos, documentos oficiais, aulas, palestras e situações que exigem maior rigor.

Exemplo: “Solicito a revisão do documento encaminhado anteriormente.”

- **Linguagem coloquial**

É a linguagem do dia a dia, mais espontânea e informal.

Exemplo: “Queria que você desse uma olhada naquele documento.”

NÍVEIS LINGUÍSTICOS

- **Linguagem popular**

É marcada por usos mais informais, podendo trazer construções afastadas da norma-padrão.

Exemplo:

“Nós vai resolver isso depois.”

- **Linguagem regional**

Apresenta marcas próprias de determinada região.

Exemplo: expressões locais, sotaques e vocabulários específicos.


- **Linguagem técnica ou científica**

É usada em áreas profissionais e acadêmicas, com termos próprios.

Exemplo: “No processamento de linguagem natural, os modelos utilizam tokens e embeddings.”

Do laboratório à empresa: onde essas técnicas geram valor

Quando o Processamento de Linguagem Natural sai da teoria e entra na operação, o texto vira *produtividade, controle e decisão*



O objetivo não é apenas entender texto.

É usar linguagem como fonte de **produtividade, controle e decisão**.

Tokens vs Embeddings

Como a inteligência artificial lê e entende o texto

Tokens

Texto original:

“A inteligência artificial ajuda empresas.”

A inteligência artificial ajuda empresas

Quebra em partes

Unidades básicas de processamento




Texto → Tokens → Embeddings → Significado

Embeddings

“inteligência artificial”

[0.21, -0.45, 0.88, 0.12, ...]



Tokens: Dividem o texto em unidades para processamento.

Embeddings: Transformam texto em vetores que capturam significado.

NÍVEIS LINGUÍSTICOS COMO CAMADAS DE ANÁLISE DA LÍNGUA

Aqui o foco não é o uso social, mas a estrutura da linguagem.

- **Nível sintático**

Estuda a organização das palavras na frase.

Exemplo: sujeito, predicado, concordância.

- **Nível semântico**

Estuda os significados.

Exemplo: ambiguidade, sentido literal e figurado.

- **Nível pragmático**

Estuda o sentido no contexto de uso.

Exemplo: intenção do falante, ironia, situação comunicativa.

- **Nível fonológico**

Estuda os sons da língua.

Exemplo: fonemas, entonação, pronúncia.

- **Nível morfológico**

Estuda a estrutura e formação das palavras.

Exemplo: radical, prefixo, sufixo, flexões.


Quando usar BERT e quando usar GPT

Modelos Transformer com objetivos diferentes na prática

BERT

Foco em compreensão

- Classificação de texto
- Reconhecimento de entidades
- Matching textual
- Análise de contexto
- Busca semântica
- Tarefas de compreensão



GPT

Foco em geração

- Geração de texto
- Resumo
- Reescrita
- Resposta conversacional
- Apoio à produção de conteúdo
- Interação por linguagem natural



Compreensão ↔ Geração

Critérios de escolha



Tipo de tarefa



Custo



Latência



Privacidade



Geração ou Compreensão

Escolher modelo não é só decisão técnica. É decisão de adequação ao problema.

Compreensão profunda → Geração criativa

Como avaliar um sistema de Processamento de Linguagem Natural em produção

Avaliação real vai além da métrica do modelo

Avaliar um sistema em produção exige olhar além da métrica do modelo.



Dimensões de Avaliação



Indicadores Possíveis

Acurácia	Precisão	F1-Score
Groundedness	Taxa de Erro	Satisfação do Usuário
	Redução de Retabalho	

Um sistema bom não é apenas o que funciona no teste. É o que sustenta confiança em uso real.

Laboratório → Sistema → Negócio

Trade-offs reais: precisão, custo, latência, privacidade e escala

Toda decisão em Processamento de Linguagem Natural envolve trocas.



A decisão correta depende de:



Criticidade
do processo



Volume
de texto



Sensibilidade
dos dados



Tempo
disponível



Orçamento



Maturidade
da equipe

Não existe solução perfeita. Existe solução adequada ao contexto do negócio.

→ Otimização técnica

→ Decisão de negócio

Governança do Processamento de Linguagem Natural e dos LLMs

Soluções baseadas em linguagem exigem controle, não apenas desempenho.




*Uma solução madura não é apenas a que responde bem.
É a que responde com **controle, responsabilidade e segurança**.*

Performance → Governança → Confiança

ESTRATÉGIAS LINGUÍSTICA (SIMBÓLICA)

- O conhecimento é explicitamente mapeado por especialistas para ser utilizado pela máquina



APLICAÇÕES

Análise de Sentimentos



Chatbot



Assistente de voz



Tradução automática



Detecção de *fake news*



Reconhecimento de Entidades Nomeadas (NER)

Definição

Técnica PLN para **identificar e classificar entidades** em texto: nomes de pessoas, organizações, locais, datas, quantidades, etc. Transforma texto não estruturado em **informação estruturada**.

Tipos de Entidades

 **PER:** Pessoas

 **ORG:** Organizações

 **LOC:** Localizações

 **DATE:** Datas

 **MONEY:** Valores

 **PERCENT:** Percentuais

Exemplo Prático

Albert Einstein trabalhou no Instituto de Tecnologia de Massachusetts em 1921.

Evolução das Técnicas

- 1 Baseado em Regras**
Padrões manuais, alta precisão, baixo recall
- 2 Machine Learning**
CRF, feature engineering manual
- 3 Deep Learning**
BiLSTM-CRF, embeddings contextuais
- 4 Transformers (BERT)**
State-of-the-art, contexto bidirecional

Ferramentas Populares

- ✓ **spaCy:** Rápido, produção, múltiplos idiomas
- ✓ **Stanford CoreNLP:** Acadêmico, CRF
- ✓ **AllenNLP:** Pesquisa, ELMo, BERT
- ✓ **NeuroNER:** Deep learning, open-source

Classificação de Texto e Análise de Sentimentos

Classificação de Texto

Tarefa de **categorizar automaticamente** documentos em classes predefinidas. Base para muitas aplicações PLN.

Categorização de Notícias

Esportes, Política, Tecnologia, Economia

Filtro de Spam

Classificar emails como spam ou não-spam

Moderação de Conteúdo

Detectar conteúdo tóxico, ofensivo ou impróprio

Algoritmos Comuns

- Naive Bayes
- Random Forest
- BERT
- SVM
- CNN/RNN
- Logistic Regression

Análise de Sentimentos

Avalia o **tom emocional** expresso em textos. Determina se sentimento é positivo, negativo ou neutro.

Exemplo:


- "Produto excelente!" → **Positivo**
- "Péssima experiência" → **Negativo**
- "Produto chegou ontem" → **Neutro**

Aplicações Empresariais

-  **Monitoramento de Marca**
Acompanhar reputação em redes sociais
-  **Análise de Reviews**
Entender feedback de clientes
-  **Pesquisas de Satisfação**
Processar respostas abertas
-  **Campanhas de Marketing**
Medir reação do público

Caso integrado: onde o texto trava a operação

Quando linguagem natural desorganizada vira custo oculto no negócio



Documento

Busca



Interpretação

Resposta

Decisão

Escolha técnica do caso

Para cada tipo de dor, uma abordagem mais adequada



Operação → Técnica → Eficiência

O mesmo ecossistema textual pode exigir técnicas diferentes para dores diferentes.

Como medir impacto no caso

Resultado técnico + valor de negócio

Impacto no negócio



Métrica técnica → **Impacto real**

ANTES	DEPOIS
▶ Alta Latência	▶ Respostas Rápidas
▶ Erros Frequentes	▶ Erro Reduzido
▶ Baixa Produtividade	▶ Produtividade Aumentada

Sem PLN → Com PLN

Indicadores técnicos



**Implantar sem medir gera percepção.
Implantar e medir gera gestão.**

Adoção → Medição → Gestão → Decisão

Pergunta inicial

Você já conversou com uma máquina hoje?

- no celular
- no tradutor
- no e-mail
- no buscador
- no chatbot

Hoje vamos percorrer este caminho:



texto → tokens → vetores → contexto → recuperação

Onde o texto aparece

- e-mails
- contratos
- mensagens
- relatórios
- comentários
- prontuários
- políticas internas

O problema

Para humanos, linguagem parece natural. Para máquinas, não.

- palavras têm vários sentidos
- contexto muda o significado
- intenção nem sempre está explícita

Exemplo de ambiguidade

"O banco está fechado."

- banco financeiro?
- banco de praça?

Exemplo de ironia

"Parabéns, resolveu tudo..."

Pode significar: elogio, crítica ou ironia.

Por que linguagem é difícil

- ambiguidade
- contexto
- ironia
- cultura
- regionalismo
- erro de digitação
- sinônimos

Aplicações no financeiro

- análise de contratos
- compliance
- relatórios
- leitura de documentos
- apoio a decisões

Aplicações no jurídico

- leitura contratual
- extração de cláusulas
- due diligence
- pesquisa documental
- organização de jurisprudência

Aplicações na saúde

- resumo de prontuários
- apoio à triagem
- leitura de laudos
- organização documental
- suporte informacional

Aplicações em RH

- triagem de currículos
- classificação de mensagens
- análise de feedbacks
- organização de políticas
- apoio à comunicação interna

Aplicações no varejo

- atendimento
- análise de reviews
- recomendação
- FAQ
- suporte ao cliente

Como tudo começou

Nas primeiras fases, o PLN usava:

- regras
- dicionários
- padrões escritos manualmente

Limites dos sistemas por regras

- funcionavam em casos simples
- exigiam muito esforço humano
- quebravam fora do padrão
- eram pouco flexíveis

A fase estatística

Depois dos sistemas baseados em regras, surgiram métodos que analisavam grandes volumes de texto para identificar padrões na linguagem.

Esses métodos se apoiavam em:

- **Frequência:** quantas vezes uma palavra aparece
- **Probabilidade:** qual a chance de uma palavra vir depois da outra
- **Coocorrência:** quais palavras costumam aparecer juntas
- **Inferência estatística:** conclusões feitas a partir dos dados observados

O que mudou na fase estatística

- menos regra manual
- mais uso de dados
- melhor escalabilidade
- ainda com limitação de contexto

Redes neurais

Com redes neurais, o texto passou a ser tratado com:

- representações distribuídas
- melhor generalização
- mais capacidade de capturar padrões

A virada dos transformers

Transformers melhoraram:

- contexto
- relação entre palavras distantes
- desempenho em várias tarefas
- base para modelos modernos

A era dos LLMs

Exemplos: GPT, Claude, Gemini, LLaMA

Capacidades:



Responder perguntas



Resumir textos



Gerar conteúdo



Classificar informações



Reescrever conteúdos

Critérios de escolha entre modelos:



Tamanho de contexto



Custo por token



Latência



Política de privacidade dos dados



Modelo aberto ou fechado

Escolher um LLM não é só uma decisão técnica.

É também uma decisão de custo, velocidade, segurança e adequação ao negócio.

O que mudou com os LLMs

- Antes: um modelo para cada tarefa.
- Agora: um mesmo modelo pode executar várias tarefas.

Pergunta para aquecer

Se há tanto texto nas empresas, por que ainda se perde tanta informação?

- excesso de volume
- baixa organização
- busca ruim
- falta de contexto
- leitura manual demorada

Ideia-chave

Texto só vira valor quando a máquina consegue:

- representar
- comparar
- interpretar
- recuperar
- responder

O que é pré-processamento

Pré-processamento é a preparação do texto antes da análise.

Objetivos: reduzir ruído, organizar o texto, melhorar consistência.

Exemplo de texto bruto

"Olá!!! Meu pedido #458 chegou quebrado :("

O que aparece aqui: pontuação excessiva, número, símbolo, emoção, ruído visual.

Quando o pré-processamento pesa mais

- Especialmente em modelos clássicos e pipelines com regras.
- Em modelos modernos (BERT, GPT, Claude): a tokenização por subpalavra já lida com boa parte da variação. Foco fica em remover ruído extremo, segmentar entradas e organizar chunks.

BERT (Bidirectional Encoder Representations from Transformers) é um modelo de Inteligência Artificial do Google (2018) para Processamento de Linguagem Natural (PLN).

Pipeline de Pré-Processamento de Linguagem Natural

Etapa	O que faz	Importância em modelos modernos
 Tokenização →	Divide texto em unidades menores	Alta — feita internamente (BPE / WordPiece)
 Normalização →	Padroniza maiúsculas, espaços e ruídos	Média — ajuda na consistência do corpus
 Stopwords →	Remove palavras de alto uso sem semântica	Baixa — <i>modelos contextuais as ignoram naturalmente</i>
 Stemming →	Reduz à raiz aproximada (<i>corr-</i>)	Baixa — <i>tokenização por subpalavras substitui</i>
 Lematização →	Forma canônica (<i>correndo</i> → <i>correr</i>)	Média — <i>útil em tarefas específicas de NER</i>

Desafios do português

- acentos
- contrações
- flexão verbal
- plural
- gírias
- regionalismos

Cuidado com stopwords — armadilha clássica

- Remover "não" de "não gostei" inverte completamente o sentido.
- Em análise de sentimento: preserve sempre as palavras de negação.

Pipeline de pré-processamento textual



Pré-processar não é "limpar tudo"

- A mesma limpeza não serve para toda tarefa.
- Depende de: tipo de dado, idioma, objetivo e modelo usado.

Busca semântica e RAG em linguagem simples

Recuperação de informação + geração de resposta



RAG não substitui qualidade documental. Ele depende dela.

Base → Recuperação → Resposta → Confiança

One-hot encoding e seu limite

- Cada palavra vira uma posição em um vetor muito grande.
- Problema: representa identidade, não semântica. "Gato" e "felino" ficam tão distantes quanto "gato" e "avião".

O que é embedding

É uma representação numérica densa que tenta capturar significado.

"Você conhece uma palavra pelas palavras que aparecem perto dela."

Palavras parecidas ficam próximas no espaço vetorial.

Analogias vetoriais

rei – homem + mulher = rainha

paris – França + Brasil = Brasília

Existe significado na geometria do espaço vetorial.

Por que FastText ajuda no português

Palavras flexionadas compartilham partes internas.

Isso ajuda em: morfologia, variação lexical, palavras longas, termos técnicos.

Tipos de embedding

Tipo	Granularidade	Exemplo de uso
Embedding de palavra (estático)	Palavra individual	Word2Vec, GloVe, FastText
Embedding contextual de token	Token com contexto da frase	BERT, RoBERTa
Embedding de sentença	Frase ou parágrafo inteiro	Sentence-BERT, E5, text-embedding-3
Embedding de documento	Documento completo	Doc2Vec, modelos long-context

Embedding não é chatbot

- Embedding serve para: representar, comparar, buscar, agrupar.
- Chat generativo serve para: responder, escrever, sintetizar, dialogar.
- São funções complementares, não equivalentes.

Embedding (ou incorporação, em português) é um conceito fundamental na Inteligência Artificial e aprendizado de máquina que transforma dados brutos — como palavras, imagens, textos ou áudios — em listas de números, chamadas de **vetores**.

Limite dos embeddings estáticos

- A palavra "banco" tem o mesmo vetor em "banco financeiro" e "banco de praça".
- Precisamos de representações que mudem conforme a frase embeddings contextuais.

Fechamento do bloco de embeddings

- Embeddings resolveram a semântica básica, mas ainda faltava contexto dinâmico.
- A solução veio com os Transformers.

O que o Transformer mudou

Transformers melhoraram:

- contexto
- dependências longas
- relações entre palavras distantes
- flexibilidade de uso

Um Transformer é uma arquitetura de rede neural de inteligência artificial (IA) que revolucionou o processamento de linguagem natural (PLN) e visão computacional, baseada no mecanismo de "atenção" para processar dados em paralelo, não sequencialmente. Introduzida em 2017, ela é a base para modelos como GPT e BERT

Atenção — em linguagem simples

- O mecanismo de atenção ajuda o modelo a olhar para partes relevantes do texto.
- Ao interpretar uma palavra, o modelo aprende quais outras palavras importam mais para seu sentido.

Multi-head attention

- Na prática, o Transformer executa várias "cabeças" de atenção em paralelo.
- Cada cabeça aprende a prestar atenção a aspectos diferentes: uma pode focar em dependências sintáticas, outra em coreferenciais, outra em relações semânticas.
- O resultado de todas as cabeças é concatenado e projetado — por isso modelos maiores têm mais cabeças e capturam mais nuances.

Multi-Head Attention (Atenção de Múltiplas Cabeças) é um mecanismo fundamental na arquitetura Transformer, amplamente utilizada em processamento de linguagem natural (PLN) e IA Generativa (como o BERT e GPT), que permite ao modelo focar em diferentes partes da sequência de entrada simultaneamente.

Por que isso importa

- O significado de uma palavra depende do resto da frase.
- "Fui ao banco sacar dinheiro." $\neq$ "Sentei no banco da praça."
- Transformers resolvem esse problema com atenção bidirecional.

BERT

- BERT é um modelo baseado em Transformer voltado para entendimento de linguagem.
- O que BERT faz bem: classificação, extração de entidades, interpretação contextual, análise textual, apoio à recuperação.

BERT (Bidirectional Encoder Representations from Transformers) é um modelo de Inteligência Artificial do Google (2018) para Processamento de Linguagem Natural (PLN).

BERT **não** é GPT

	BERT	GPT
Direção de leitura	Bidirecional	Unidirecional (esquerda → direita)
Ponto forte	Entendimento, classificação, extração	Geração, diálogo, completamento
Pré-treinamento	Masked Language Model (MLM)	Causal Language Model (CLM)
Uso típico hoje	Fine-tuning em tarefas específicas	Base para LLMs conversacionais

BERTimbau e modelos em português

BERTimbau: versão do BERT treinada em português brasileiro — melhor aderência ao idioma.

Modelo	Destaque
BERTimbau	Clássico de referência em PT-BR
multilingual-e5 / bge-m3	Embeddings multilingues de alta qualidade para buscas e RAG
Sabiá-2 (Maritaca AI)	LLM instruído em português, benchmark ENEM e textos jurídicos
GPT-4o / Claude 3.5+ / Gemini 1.5	Suporte nativo a português, uso via API

O **BERTimbau** é um modelo de linguagem baseado na arquitetura BERT (Bidirectional Encoder Representations from Transformers), especificamente pré-treinado para a língua portuguesa, com foco no português brasileiro

Sentence-BERT e similaridade semântica

- Sentence-BERT (SBERT): modelo adaptado para comparar sentenças e medir similaridade.
- Duas frases podem usar palavras diferentes e ter sentido parecido.
- Exemplo: "como cancelar meu pedido?" $\approx$ "quero desistir da compra"
- Isso viabiliza a busca semântica — o próximo bloco.

SIMILARIDADE TEXTUAL

- Verificar o quão próximos são dois fragmentos de texto a partir do significado e estrutura

Frase 1: 'Os' 'gatos' '**comem**' 'os' 'ratos'
Frase 2: 'Os' 'gatos' '**comem**' 'os' 'insetos'

1 2 3

- Similaridade Semântica
- Carro / Automóvel
- Similaridade Léxica
- Carro / Barro

(Gomma & Fahmy, 2013)

SIMILARIDADE TEXTUAL

Baseada em Strings é uma abordagem de **similaridade textual** que compara textos olhando diretamente para a **forma das palavras**, ou seja, os **caracteres e termos**, sem considerar profundamente o significado.

Definição clara:

Similaridade baseada em strings mede o quanto dois textos são parecidos a partir da sequência de caracteres ou palavras que eles possuem.

Baseada em **Strings** (ou cadeias de caracteres) refere-se a qualquer sistema, processo ou dado em computação que manipule, armazene ou processe informações textuais. Uma string é uma sequência de caracteres que pode incluir letras, números, símbolos e espaços. Baseada em **Strings**

(Gomma & Fahmy, 2013)

SIMILARIDADE TEXTUAL

Como funciona na prática:

Ela analisa:

- letras
- ordem das palavras
- presença de termos iguais
- distância entre sequências

Exemplo simples:


Texto 1: carro

Texto 2: barro

- Muito parecidos na escrita (diferença de 1 letra)
- **Alta similaridade por string**
- Mas **significado diferente**

Qual técnica usar em cada problema?

A escolha da técnica depende da natureza da tarefa



Não se começa escolhendo a ferramenta. Começa-se entendendo a natureza do problema.

Problema → Técnica → Solução

SIMILARIDADE TEXTUAL

Tipos principais:

1. Baseada em termos (palavras):

- Cosine Distance
 - Jaccard
 - Dice
- compara conjuntos de palavras

Exemplo:

“gato preto” vs “gato branco”
→ compartilham a palavra “gato”

2. Baseada em caracteres:

- Levenshtein
 - Jaro-Winkler
 - N-gram
- compara letra por letra

Exemplo:

“casa” vs “caso”
→ pequena diferença → alta similaridade

Fechamento do bloco técnico e transição para produção, avaliação e tendências

- Até aqui, vimos como o texto é representado, como o contexto é capturado e como arquiteturas modernas ampliaram a capacidade de compreensão e geração.
- Como isso é usado em produção, como se avalia e quais riscos precisam ser governados?

Bloco final — produção, avaliação e tendências

Depois de entender fundamentos, representação, embeddings, Transformers, BERT e similaridade semântica, entramos agora na camada decisiva da disciplina:

- uso em produção
- critérios de avaliação
- ferramentas do ecossistema
- limitações atuais
- tendências futuras

Mecanismo de Atenção e Self-Attention

Conceito de Self-Attention

Mecanismo onde **cada token presta atenção a todos os outros tokens** (incluindo si mesmo) para gerar embeddings contextuais. Permite entender relações entre palavras independentemente da distância.

"Qual a importância de cada palavra para entender o significado das outras?"

Vetores Q, K e V

Q Query (Consulta)

O que o token atual está procurando em outros tokens

K Key (Chave)

Como o token atual é relevante para outros tokens

V Value (Valor)

A informação real que o token contribui

Multi-Head Attention

Múltiplas cabeças de atenção operam em paralelo, cada uma focando em **diferentes aspectos** das relações entre tokens.

- Relações sintáticas
- Relações semânticas
- Relações posicionais

Vantagem

Processamento paralelo reduz tempo de treinamento e permite capturar dependências de longo alcance eficientemente.

BERT vs GPT: Arquiteturas e Aplicações

B

BERT

Bidirectional Encoder Representations from Transformers

Arquitetura

Encoder-only, bidirecional

Processamento

Lê texto em ambas direções simultaneamente

Treinamento

Masked Language Modeling (MLM)

Melhores Aplicações

- Classificação de texto
- Question Answering
- Inferência textual

- NER
- Análise de sentimentos
- Similaridade semântica

G

GPT

Generative Pre-trained Transformer

Arquitetura

Decoder-only, unidirecional

Processamento

Lê texto da esquerda para direita

Treinamento

Causal Language Modeling (CLM)

Melhores Aplicações

- Geração de texto
- Chatbots
- Tradução

- Completar frases
- Escrita criativa
- Sumarização

i

Evolução dos Modelos

GPT-3 (2020): 175B parâmetros, geração de texto versátil

GPT-4 (2023): Multimodal (texto + imagem), raciocínio avançado

GPT-4o (2024): Unificado texto, visão e áudio em um modelo

Open Source: LLaMA, Mistral, DeepSeek democratizam acesso

Aplicações Práticas do PLN



Assistentes Virtuais

Siri, Alexa, Google Assistant usam PLN para entender comandos de voz, interpretar intenção e responder contextualmente.

- Definir alarmes e lembretes
- Responder perguntas complexas
- Controlar dispositivos smart home



Tradução Automática

Google Translate, DeepL quebram barreiras linguísticas para comunicação global, negócios e educação.

- Localização de websites
- Tradução de documentos
- Comunicação multilíngue



Reconhecimento de Fala

ASR (Automatic Speech Recognition) converte fala em texto para transcrição, comandos de voz e acessibilidade.

- Transcrição médica
- Legendas automáticas
- Comandos de voz



Chatbots

Atendimento ao cliente 24/7, resolução automática de dúvidas, redução de tempo de espera e custos operacionais.

- Suporte técnico automatizado
- Agendamento de compromissos
- Processamento de reembolsos



Análise de Sentimentos

Monitoramento de **reputação de marca** em redes sociais, análise de reviews e feedback de clientes.

- Twitter, Facebook, Instagram
- Reviews de produtos
- Pesquisas de satisfação



Análise de Documentos

Extração automática de insights de grandes volumes de texto em **setores jurídico, financeiro e de saúde**.

- Análise de contratos
- Relatórios financeiros
- Prontuários médicos

Métricas de Avaliação em PLN

Métricas de Classificação

Acurácia

Proporção de predições corretas

$$\text{Accuracy} = (\text{TP} + \text{TN}) / \text{Total}$$

Precisão

Proporção de predições positivas corretas

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Recall (Sensibilidade)

Proporção de casos positivos identificados

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

F1-Score

Média harmônica entre precisão e recall

$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Métricas de Geração

BLEU Score

Precision-oriented. Mede sobreposição de n-grams entre texto gerado e referência.

Ideal para: Tradução automática

ROUGE Score

Recall-oriented. Foca em capturar todo conteúdo relevante.

Ideal para: Sumarização de texto

Perplexidade

Mede quão bem o modelo prevê uma amostra. Menor = melhor.

Ideal para: Modelos de linguagem

Quando Usar Cada Métrica?

Classificação: Accuracy, Precision, Recall, F1

Tradução: BLEU, METEOR

Sumarização: ROUGE, BLEU

Geração: Perplexidade, BLEU, human evaluation

Principais Bibliotecas Python para PLN

ECOSISTEMA PYTHON



N NLTK

Natural Language Toolkit

- Tokenização, stemming
- POS tagging, parsing
- Corpora e datasets

Melhor para: Educação, prototipagem, pesquisa acadêmica

S spaCy

Industrial-Strength NLP

- NER, POS tagging
- Dependency parsing
- Word vectors

Melhor para: Produção, velocidade, APIs em tempo real

H Hugging Face

Transformers

- BERT, GPT, T5
- 100k+ modelos pré-treinados
- Fine-tuning fácil

Melhor para: SOTA models, LLMs, pesquisa avançada

G Gensim

Topic Modeling

- Word2Vec, Doc2Vec
- LDA (Latent Dirichlet Allocation)
- Similaridade semântica

Melhor para: Modelagem de tópicos, embeddings

St Stanza

Stanford NLP

- 70+ idiomas suportados
- Deep learning integrado
- Alta precisão

Melhor para: Multilíngue, alta acurácia

A AllenNLP

Research Framework

- ELMo, BERT avançado
- Question Answering
- Coreference resolution

Melhor para: Pesquisa, modelos customizados

Tabela Comparativa

Biblioteca	Velocidade	Deep Learning	Multilíngue	Curva	Uso Ideal
NLTK	Lenta	Não	Bom	Baixa	Educação
spaCy	Rápida	Integrado	70+ idiomas	Baixa	Produção
Hugging Face	Variável	Excelente	Hub vasto	Alta	SOTA/LLMs
Gensim	Rápida	Não	Agnóstico	Média	Tópicos
Stanza	Média	Built-in	70+ idiomas	Média	Multilíngue

Desafios e Tendências Futuras

O futuro do Processamento de Linguagem Natural: desafios atuais e direções emergentes para a próxima década

Desafios Atuais

Idiomas de Baixo Recurso

Falta de dados de treinamento para idiomas e dialetos menos representados

Interpretabilidade (Black Box)

LLMs atuam como caixas-pretas, dificultando rastrear decisões

Alucinações e Desinformação

Modelos geram fatos confiantes mas incorretos ou inventados

Impacto Ambiental

Treinamento de LLMs consome recursos computacionais massivos

Confiabilidade

Falhas em cenários dinâmicos, jargão técnico, sarcasmo

Tendências Futuras

PLN Multimodal

Integração de texto com imagem, vídeo e áudio (GPT-4o)

PLN em Tempo Real

Streaming ASR com análise de sentimento ao vivo

Edge NLP

Processamento local em dispositivos (privacidade, baixa latência)

PLN Explicável (XAI)

Modelos transparentes e interpretáveis para decisões críticas

Modelos Contínuos

Evolução constante com aprendizado contínuo e adaptativo

O Futuro do Processamento de Linguagem Natural

O PLN continua **revolucionando a forma como interagimos com a tecnologia**. Com avanços em arquiteturas Transformer, Grandes Modelos de Linguagem e técnicas de pré-processamento, o PLN está cada vez mais presente em nosso cotidiano.

*O futuro promete **integração multimodal**, **maior acessibilidade** e modelos **mais eficientes e explicáveis**, tornando a comunicação humano-máquina mais natural, intuitiva e inclusiva.*



Inteligência

Modelos cada vez mais sofisticados



Acessibilidade

Democratização da tecnologia



Interação

Comunicação natural e fluida



Inovação

Novas aplicações emergindo

CURIOSIDADES SOBRE INTELIGÊNCIA ARTIFICIAL E PLN

Curiosidades que ajudam a entender a inteligência artificial moderna

Bastidores históricos e conceituais que explicam por que a **IA evoluiu como evoluiu**



1950 — Turing

O famoso **teste** nasceu como experimento filosófico, não como benchmark técnico.



1966 — ELIZA

Mesmo sem compreender linguagem, já criava **ilusão de empatia**.



1970–1990 — Invernos da IA

O campo **quase perdeu relevância** duas vezes por prometer mais do que **entregava**.



Anos 1980 — Virada estatística

Dados começaram a superar regras linguísticas escritas manualmente.



2013 — Word2Vec

Relações semânticas emergiram dos dados **sem programação explícita**.



2017 — Transformer

A arquitetura que redefiniu o PLN moderno surgiu de um **paper curto** e objetivo.



Hoje — LLMs

Boa parte das capacidades atuais emerge de uma tarefa simples: **prever o próximo token**.



A evolução da IA não foi linear.

Foi construída por rupturas, fracassos, descobertas inesperadas e mudanças de paradigma.

O QUE O GESTOR PRECISA LEVAR DESTA AULA

PLN e LLM não são apenas tecnologias de texto. São instrumentos de **produtividade, decisão e transformação organizacional**.

- ✓ **Linguagem** é um dos maiores **ativos não estruturados** das organizações.
- ✓ O PLN transforma **texto em classificação, busca, extração**, resumo e apoio à decisão.
- ✓ **Embeddings e Transformers** mudaram a forma de representar e processar linguagem.
- ✓ **LLMs** ampliaram **escala, flexibilidade** e capacidade de interação com informação textual.
- ✓ Busca semântica e RAG aproximam modelos de linguagem do contexto real da empresa.
- ✓ O valor não está apenas no modelo, mas na qualidade dos dados, no processo e no uso **estratégico**.



Quem entende linguagem apenas como texto lê documentos.
Quem entende linguagem como ativo estratégico transforma operação, decisão e resultado.



MARCOS GLOBAIS 2026–2034

Negócios, empregos, tecnologias e automações

A próxima década será definida por automação inteligente, redesenho do trabalho e disciplina de gestão.

2026–2030



IA vira infraestrutura.

Copilotos entram na rotina e a automação avança onde há padrão e repetição.



Produtividade vira arquitetura.

Quem integra sistemas e redesenha funções entrega mais com menos gente.

2030–2034



O físico limita o digital.

Energia e infraestrutura passam a definir custo, escala e velocidade da IA.



Governança vira vantagem.

Auditoria, segurança e rastreabilidade deixam de ser opcionais e entram no padrão.

As vencedoras serão as empresas mais bem geridas.



Telefone
18 99785-1414



Site
www.propetec.com.br



E-mail
renato@propetec.com.br



LinkedIn
linkedin.com/in/renato-camacho



YouTube
youtube.com/@propetec



Instagram
[@propetec.consultoria](https://instagram.com/propetec.consultoria)

