

ByteTrack: Rastreamento de Múltiplos Objetos Associando Todas as Caixas de Detecção

ECCV (European Conference on Computer Vision) 2022 — Yifu Zhang et al.

Fonte: https://www.ecva.net/papers/eccv_2022/papers_ECCV/papers/136820001.pdf

Visão Computacional

Detecção e rastreamento em tempo real

Deep Learning

YOLOX como detector base

MOT (Multi-Object Tracking)

Associação de todas as caixas de detecção

Alunos: Deivison Takatu e Fabrício Londero



O Problema do MOT (Multi-Object Tracking)

Rastrear múltiplos objetos em vídeo significa atribuir e manter identidades únicas a cada objeto ao longo dos frames, mesmo sob condições adversas. É um dos problemas centrais da visão computacional moderna.

Oclusão

Objetos ficam parcialmente ou totalmente encobertos por outros

Movimento Rápido

Alta velocidade causa deslocamento brusco entre frames consecutivos

Baixa Iluminação


Condições de pouca luz reduzem a qualidade da detecção

Perda de Identidade

Troca incorreta de IDs entre objetos distintos durante o rastreamento



Deteções de **baixa confiança** são frequentemente descartadas, mas podem conter objetos reais valiosos para o rastreamento contínuo.



Limitação dos Métodos Tradicionais

O paradigma **tracking-by-detection** detecta objetos em cada frame e os associa ao longo do tempo. O problema central: métodos tradicionais filtram caixas com score abaixo de um limiar, descartando informações potencialmente úteis.

Método Tradicional

Aplica limiar de confiança rígido. Caixas com score baixo são **descartadas**. Objetos parcialmente ocultos ou em movimento deixam de ser rastreados. Resultado: fragmentação de trajetórias e troca de identidades.



Objetos reais são perdidos permanentemente

Abordagem ByteTrack

Utiliza **todas** as caixas de detecção — altas e baixas. Caixas fracas são aproveitadas na segunda etapa de associação. Trajetórias são mantidas mesmo sob oclusão parcial.



Nenhuma caixa válida é desperdiçada

Ideia Principal do ByteTrack

A hipótese central do ByteTrack é que **caixas de baixa confiança não são necessariamente falsos positivos**. Objetos reais sob oclusão, iluminação fraca ou movimento rápido naturalmente produzem detecções de score baixo — e essas informações devem ser exploradas.

● Alta Confiança

Score acima do limiar principal.
Associadas na **1ª etapa** com objetos já rastreados via IoU (Intersection over Union) ou Re-ID (Re-Identification).

● Baixa Confiança


Score entre limiar baixo e limiar alto.
Associadas na **2ª etapa** com rastros não associados da etapa anterior, recuperando objetos perdidos.

● Descarte Real

Apenas caixas **abaixo do limiar mínimo** são descartadas, pois representam ruído genuíno do detector.

 A associação em duas etapas é o coração da estratégia BYTE, que dá nome ao método.

Funcionamento do Algoritmo BYTE



Detector

Separação

Associação 1

**Associação
2**

**Novos
Tracks**

Filtro de Kalman (Kalman Filter)


Prediz a posição futura de cada objeto rastreado entre frames, mesmo sem nova detecção.

IoU (Intersection over Union)

Métrica de sobreposição espacial usada para associar caixas a rastros existentes.

Re-ID (Re-Identification)

Extrai aparência visual para auxiliar associação em casos de longa ausência.



Recuperação de Objetos Ocultos

Um dos cenários mais desafiadores para o rastreamento é quando um objeto fica **parcialmente oculto**: a confiança da detecção cai drasticamente, e métodos tradicionais perderiam o rastro. O ByteTrack mantém o ID original.

1

Frame T

Objeto visível, score alto. Associação direta na 1ª etapa.

2

Frame T+1

Objeto parcialmente oculto. Score baixo — 2ª etapa de associação ativa.

3

Frame T+2

Objeto reaparece. **Mesmo ID mantido** — sem troca de identidade.



Baixa confiança ≠ falso positivo — esta é a premissa que distingue o ByteTrack dos métodos anteriores.

BYTE vs ByteTrack: Entendendo a Diferença

BYTE — A Estratégia


É o **algoritmo de associação em duas etapas**. Pode ser aplicado como plug-in em qualquer rastreador existente (SORT, DeepSORT, CenterTrack, etc.), melhorando suas métricas sem alterar o detector.

📄 Estratégia modular e transferível

ByteTrack — O Rastreador Completo

Sistema end-to-end que combina **YOLOX (You Only Look Once X)** como detector de alta performance + estratégia BYTE + Filtro de Kalman para predição de estado. Otimizado para velocidade e precisão simultâneas.

📄 Sistema completo pronto para uso



Experimentos e Bases de Dados

A estratégia BYTE foi avaliada em múltiplos benchmarks públicos e aplicada sobre diferentes rastreadores base, demonstrando melhora consistente no IDF1 (ID F1 Score) — métrica que penaliza diretamente a troca de identidades.

1

MOT17 → Multiple Object Tracking 2017

Dataset padrão de pedestres em ambientes urbanos. Benchmark mais utilizado na literatura de MOT.

2

MOT20 → Multiple Object Tracking 2020

Cenas com alta densidade de pessoas e oclusões frequentes. Ambiente mais desafiador que o MOT17.

3

HiEve → High-density Crowd Event Video Dataset

Dataset com eventos humanos em ambientes de larga escala e múltiplas câmeras.

4

BDD100K → Berkeley DeepDrive 100K


Dataset de direção autônoma com múltiplas categorias de objetos além de pedestres.


Principais Resultados

Métrica	MOT17	MOT20
MOTA (Multiple Object Tracking Accuracy)	80.3	77.8
IDF1 (ID F1 Score)	77.3	75.2
HOTA (Higher Order Tracking Accuracy)	63.1	61.3
FPS (Frames Per Second)	30	—

✅ Estado da arte em MOT17 e MOT20 no momento da publicação

Rastreador





Conclusão

Caixas de baixa confiança carregam informação real

A premissa central do ByteTrack: descartar detecções fracas significa perder objetos genuinamente presentes na cena.

Associação em duas etapas reduz fragmentação

Diminui significativamente a perda de objetos e a troca de identidades (ID switches) em cenas desafiadoras.

Simples, eficiente e de alto desempenho

30 FPS em tempo real com métricas de ponta — sem necessidade de modelos de Re-ID complexos.

"O sucesso do ByteTrack mostra que **boas estratégias de associação** podem ser tão importantes quanto modelos complexos de deep learning."

Referências: Zhang et al., "ByteTrack: Multi-Object Tracking by Associating Every Detection Box", ECCV 2022. Ge et al., "YOLOX: Exceeding YOLO Series Detectors", 2021.

ByteTrack: Rastreamento de Múltiplos Objetos Associando Todas as Caixas de Detecção

ECCV (European Conference on Computer Vision) 2022 — Yifu Zhang et al.

Fonte: https://www.ecva.net/papers/eccv_2022/papers_ECCV/papers/136820001.pdf

Visão Computacional

Detecção e rastreamento em tempo real

Deep Learning

YOLOX como detector base

MOT (Multi-Object Tracking)

Associação de todas as caixas de detecção

Alunos: Deivison Takatu e Fabrício Londero

