



Visão Computacional e Deep Learning

Ma. Cilene Renata Real
cilene.real@facens.br

Agenda

- Apresentação da Professora
- Apresentação dos alunos
- Apresentação da Disciplina
- Fundamentos de Visão Computacional
- Processamento de imagens com OpenCV
- Atividades



Apresentação da Professora

Apresentação dos Alunos



<https://padlet.com/cilenereal2/apresentacao-dos-alunos-4wx9ioqyas7nb6x1>

Apresentação da Disciplina

1. EMENTA

Nesta disciplina serão apresentadas as principais técnicas e ferramentas de software para visão computacional aplicando redes neurais e arquiteturas de última geração, incluindo CNNs, Vision Transformers e modelos multimodais.

2. OBJETIVOS

Formar especialistas capazes de projetar e treinar modelos de visão para classificação, detecção e segmentação, aplicando técnicas modernas de otimização.

Apresentação da Disciplina

3. CONTEÚDO PROGRAMÁTICO

- Processamento básico de imagens com OpenCV
- CNNs e arquiteturas modernas
- Vision Transformers
- Detecção de objetos
- Segmentação
- Integração visão + LLMs para multimodalidade

4. CRITÉRIOS DE AVALIAÇÃO

Atividades realizadas durante as aulas.

Necessária nota mínima 7,00 para aprovação.

Apresentação da Disciplina

BIBLIOGRAFIA BÁSICA:

1. SZELISKI, R. Computer Vision: Algorithms and Applications. 2. ed. London: Springer, 2022.
2. PEDRINI, H.; SCHWARTZ, W. R. Análise de Imagens Digitais: princípios, algoritmos e aplicações. São Paulo: Thomson Learning, 2008.
3. GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016.
4. KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. ImageNet Classification with Deep Convolutional Neural Networks. Communications of the ACM, v. 60, n. 6, p. 84–90, 2017.
5. ZHANG, A.; LIPTON, Z. C.; LI, M.; SMOLA, A. Dive into Deep Learning. 2. ed. New York: Springer, 2023.

Horários

Café da Manhã (15 minutos):

Almoço (1h):

Café da Tarde (15 minutos):



Calendário

Nossas aulas acontecerão aos sábados das
8h às 17h:

- 16/05 (hoje)
- 30/05
- 13/06
- 27/06

Orientações Gerais

- Para obter a aprovação, o aluno deverá ter no mínimo 75% de frequência e alcançar a média 7.0 ou superior, entre as atividades propostas.
 - O conteúdo das aulas serão gravados e o material disponibilizado no Canvas.
 - Todos os exercícios serão realizados durante o tempo dos quatro encontros e inseridos no Canvas.
-

Alguma Dúvida?





menti.com
4136 7149

**Quando você pensa Visão Computacional
e Deep Learning, o que vem a sua
mente?**

**Indique 3 palavras
ou termos (termos
compostos por
mais
de uma palavra)**

Visão Computacional = área de aplicação: fazer computadores “entenderem” imagens/vídeos.

Deep Learning = abordagem/modelagem: redes neurais profundas para aprender padrões.


Em outras palavras: grande parte da visão computacional moderna usa deep learning, mas visão computacional é mais ampla.

O que é a Visão Computacional?

A visão computacional é um ramo da inteligência artificial dedicado a permitir que computadores interpretem e compreendam o mundo visual. Essa tecnologia possibilita que máquinas obtenham informações relevantes a partir de imagens e vídeos, simulando, em certa medida, a capacidade humana de enxergar e entender o ambiente.

Assim como o olho humano capta a luz e o cérebro processa essa informação, os sistemas de visão computacional utilizam câmeras para adquirir o dado visual e algoritmos para analisá-lo e executar tarefas equivalentes, embora por meio de mecanismo próprio e com limitações específicas.

O que é a Visão Computacional?



A analogia entre o sistema visual humano e a visão computacional é útil para compreender o desafio deste campo.

Enquanto processamos informações visuais de forma intuitiva, a máquina precisa de algoritmos complexos para interpretar pixels como objetos significativos.

O que é a Visão Computacional?

Por este motivo, “dar” o sentido da visão para uma máquina gera um resultado impressionante.

Imagens estão em todo o lugar e a capacidade de reconhecer objetos, paisagens, rostos, sinais e gestos torna as máquinas muito mais úteis.

História da Visão Computacional



Princípios Fundamentais



O processo fundamental da visão computacional começa com a captura da luz através de sensores, semelhantes à retina humana.

Esta luz é convertida em sinais elétricos que são digitalizados em matrizes de pixels, cada um com valores específicos de intensidade e cor.

Este é o formato básico que os algoritmos processam para extrair informações significativas.


Enquanto nós humanos vemos naturalmente objetos, rostos e cenas, os computadores inicialmente percebem apenas matrizes numéricas.

Cada pixel é representado por valores numéricos que indicam sua intensidade em diferentes canais de cor (geralmente RGB - vermelho, verde e azul).

Por exemplo, uma imagem colorida de 1000×1000 pixels é representada como três matrizes de 1000×1000 , totalizando 3 milhões de valores que precisam ser processados e interpretados.

O desafio fundamental da visão computacional está em transformar esta representação de baixo nível (pixels) em conceitos de alto nível (objetos, pessoas, ações).

Esta ponte entre dados brutos e semântica significativa é o que torna o campo tão desafiador e fascinante.



- **Detecção de Borda:** identifica contornos e mudanças de intensidade na imagem, ajudando a localizar formas e objetos.
- **Segmentação de Imagem:** divide a imagem em regiões para separar objetos e áreas de interesse.
- **Morfologia Matemática:** aplica operações para modificar formas, remover ruídos e melhorar estruturas visuais.

O processamento digital de imagens constitui a base fundamental para sistemas de visão computacional.

As técnicas preparam as imagens para análises mais complexas, melhorando a qualidade dos dados e facilitando a extração de informações relevantes nos estágios posteriores.

Técnicas clássicas:

- Filtro Gaussiano → suavização/redução de ruído.
- Equalização de Histograma → melhoria de contraste.
- Detecção de Bordas → realce de contornos.

Demais técnicas:

- binarização
- segmentação
- transformação geométrica
- rotação
- redimensionamento
- correção de iluminação
- morfologia matemática
- transformada de Fourier
- compressão
- restauração
- reconstrução
- extração de características

Extração de Características

A **extração de características** é uma etapa importante no processamento de imagens, pois transforma informações básicas dos pixels em dados mais úteis para identificar e reconhecer objetos.

Nessa etapa, algoritmos localizam pontos importantes da imagem, como cantos e regiões onde há mudanças significativas em diferentes direções.

Além disso, descritores como SIFT, SURF e ORB analisam essas regiões e extraem características marcantes dos objetos.


Esses métodos conseguem reconhecer padrões mesmo quando a imagem sofre alterações, como rotação, mudança de tamanho ou variações de iluminação.

Na prática, essas características funcionam como uma espécie de **assinatura visual**, permitindo identificar o mesmo objeto em diferentes imagens e condições.

Classificação de Imagens

A classificação de imagens é uma das tarefas fundamentais da visão computacional, onde o objetivo é atribuir uma categoria a uma imagem inteira.

Os classificadores tradicionais como SVM (Support Vector Machines) e árvores de decisão utilizam características extraídas manualmente para tomar decisões.



A inspiração para redes neurais veio da estrutura do cérebro humano, onde neurônios biológicos conectam-se formando redes complexas.

O perceptron, proposto por Frank Rosenblatt em 1958, foi o primeiro modelo computacional baseado neste conceito, capaz de aprender tarefas simples de classificação.

Por décadas, as limitações computacionais restringiram o desenvolvimento de redes mais complexas.

Foi apenas com o avanço das GPUs e o desenvolvimento de técnicas de treinamento mais eficientes que o Deep Learning revolucionou a visão computacional, particularmente após 2012 com a vitória da AlexNet na competição ImageNet.

Redes Neurais Convolucionais (CNNs)

CNNs são um tipo de rede neural desenvolvida principalmente para analisar imagens e identificar padrões visuais.

Elas funcionam processando a imagem em etapas, aprendendo automaticamente características importantes, como:

- bordas
- formas
- texturas
- objetos
- padrões complexos

Diferente de métodos tradicionais, a CNN aprende essas características sozinha durante o treinamento, sem precisar programar manualmente cada regra.

Redes Neurais Convolucionais (CNNs)

Como funciona:

O processo ocorre em camadas:

- **Camadas convolucionais** → detectam características da imagem.
- **Camadas de pooling** → reduzem dados e mantêm o essencial.
- **Camadas totalmente conectadas** → fazem a classificação final.

Exemplo:

uma CNN pode receber milhares de imagens de gatos e cachorros.

Durante o treinamento, ela aprende padrões visuais e depois consegue classificar novas imagens automaticamente.

As CNNs são muito aplicadas em:

- reconhecimento facial
- carros autônomos
- diagnóstico médico
- leitura de placas
- segurança
- inspeção industrial
- detecção de objetos

Redes Neurais Convolucionais são modelos de deep learning especializados em processar imagens, extraíndo características visuais automaticamente para tarefas como classificação, detecção e reconhecimento.

Transfer Learning é uma técnica em que você aproveita um modelo já treinado e o adapta para uma nova tarefa, em vez de começar o treinamento do zero.

Como funciona

Um modelo pré-treinado já reconhece características gerais, como:

- bordas
- texturas
- formas
- objetos

Então, em vez de treinar tudo novamente, você usa esse modelo como base e ajusta para seu caso.

Exemplo:

Um modelo treinado para reconhecer milhares de objetos pode ser adaptado para identificar:

- defeitos industriais
- exames médicos
- plantas
- animais
- documentos

Processo

- usa modelo pré-treinado
- mantém camadas iniciais
- ajusta camadas finais
- treina com novo conjunto de dados

Modelos usados (muito comuns):

- ResNet
- VGGNet
- EfficientNet
- MobileNet

Vantagens:

- menos dados
- menos tempo
- melhor precisão
- treinamento mais rápido
- ótimo para projetos reais

Transfer Learning é a reutilização de um modelo previamente treinado para uma nova tarefa, aproveitando conhecimentos já aprendidos e reduzindo tempo e quantidade de dados necessários.

Modelos usados (muito comuns):

- ResNet
- VGGNet
- EfficientNet
- MobileNet

Vantagens:

- menos dados
- menos tempo
- melhor precisão
- treinamento mais rápido
- ótimo para projetos reais


Introdução à Detecção de Objetos

Enquanto a classificação informa apenas a categoria da imagem, a **detecção de objetos localiza vários elementos ao mesmo tempo, indicando onde cada objeto aparece.**

O resultado geralmente é apresentado por meio de **caixas delimitadoras (bounding boxes)**, que são retângulos desenhados ao redor dos objetos detectados.

Cada caixa costuma incluir:

- o nome da classe identificada
- a posição do objeto
- o nível de confiança da detecção



Aplicações práticas:

Essa técnica é amplamente utilizada em diversas áreas, como:

- sistemas de assistência ao motorista;
- contagem de pessoas em ambientes públicos;
- monitoramento de animais e vida selvagem;
- inspeção e controle de qualidade industrial.

A detecção de objetos permite identificar e localizar diferentes elementos em uma imagem, utilizando caixas delimitadoras para indicar sua posição, classe e grau de confiança.

Algoritmos modernos de detecção são modelos de deep learning capazes de identificar e localizar objetos em imagens, oferecendo alta precisão e desempenho em aplicações práticas.

Principais algoritmos modernos

- **YOLO:**
Detecta objetos rapidamente em uma única etapa, sendo muito usado em aplicações em tempo real.
- **Faster R-CNN**
Possui alta precisão e é bastante aplicado em tarefas que exigem maior detalhamento.
- **SSD**
Equilibra velocidade e precisão, sendo útil para dispositivos com menor capacidade.
- **RetinaNet**
Destaca-se por melhorar a detecção de objetos pequenos e difíceis.

Como funcionam:

Esses modelos geralmente:

- recebem a imagem;
- identificam regiões importantes;
- localizam os objetos;
- classificam cada objeto;
- retornam coordenadas e confiança.

Aplicações

- veículos autônomos
- vigilância
- medicina
- indústria
- agricultura
- drones
- cidades inteligentes


Segmentação Semântica

Segmentação semântica é a técnica que classifica cada pixel da imagem em categorias, permitindo identificar e separar regiões com precisão detalhada.

Na prática, a imagem é dividida em regiões, e cada pixel recebe uma categoria, como:

- pessoa
- carro
- estrada
- árvore
- prédio

Isso permite entender a cena com muito mais detalhe.



Como funciona:

Diferente da detecção de objetos:

- **detecção** → identifica objetos e suas posições.
- **segmentação semântica** → classifica todos os pixels da imagem.

Exemplo:

em uma foto de rua, o sistema pode separar exatamente:

- calçada
- pista
- carros
- pedestres
- céu

Cada região aparece com uma cor diferente para representar a classe.

Aplicações:

Muito usada em:


- carros autônomos
- imagens médicas
- agricultura
- satélites
- robótica
- monitoramento ambiental

Modelos conhecidos:

- U-Net
- DeepLab
- FCN
- SegNet

Rastreamento de objetos

Rastreamento de objetos é a técnica que acompanha a movimentação de um ou mais objetos em vídeos, mantendo sua identificação e posição ao longo do tempo.



Enquanto a detecção identifica um objeto em uma imagem, o rastreamento acompanha esse objeto quadro a quadro, mantendo sua posição e trajetória.

Como funciona

O sistema:

- detecta o objeto;
- identifica sua posição;
- acompanha o movimento;
- atualiza sua localização continuamente.

Isso permite seguir um ou vários objetos ao mesmo tempo.

Exemplo: em um vídeo de trânsito, o sistema pode rastrear:

- carros
- motos
- pedestres
- bicicletas

Mantendo o acompanhamento de cada um individualmente.

Aplicações:

- monitoramento por câmeras
- trânsito inteligente
- esportes
- segurança
- drones
- robótica

Alguns métodos conhecidos:

- SORT
- Deep SORT
- ByteTrack
- OpenCV

Reconhecimento Facial

Reconhecimento facial é a tecnologia que identifica pessoas por meio da análise das características do rosto, comparando essas informações com registros armazenados.



Como funciona:

Geralmente o processo ocorre em etapas:

- detecção do rosto;
- extração de características faciais;
- geração de representação matemática;
- comparação com banco de dados;
- identificação ou autenticação;

Características analisadas podem incluir:

- distância entre os olhos
- formato do nariz
- contorno do rosto
- posição da boca
- proporções faciais

Tecnologias usadas: modelos modernos utilizam deep learning, principalmente:


- FaceNet
- MTCNN
- OpenCV
- DeepFace

Aplicações:

- desbloqueio de celulares;
- controle de acesso;
- Segurança;
- Aeroportos;
- Monitoramento;
- autenticação digital;
- sistemas bancários.

OCR - Reconhecimento Óptico de Caracteres

OCR é a tecnologia que reconhece caracteres em imagens e converte essas informações em texto digital, permitindo leitura automática de documentos e registros.



Em vez de apenas “ver” a imagem, **o OCR identifica letras, números e símbolos e transforma isso em dados que podem ser pesquisados, copiados ou processados.**

Como funciona: o processo inclui:

- captura da imagem;
- pré-processamento;
- detecção das áreas de texto;
- reconhecimento dos caracteres;
- conversão para texto digital.

Etapas de pré-processamento costumam usar:

- ajuste de contraste;
- remoção de ruído;
- Alinhamento;

Exemplos de uso: OCR é usado para ler:

- documentos
- notas fiscais
- placas de veículos
- formulários
- recibos
- livros digitalizados
- cartões

Ferramentas comuns:

- Tesseract OCR
- EasyOCR
- OpenCV
- PaddleOCR

Atividade 1

Considerando os conceitos apresentados até o momento sobre visão computacional e deep learning, escolham um artigo e vocês devem apresentar seu conteúdo.

Essa atividade deve ser feita em dupla.