



Visão Computacional e Deep Learning

Ma. Cilene Renata Real
cilene.real@facens.br

Segmentação de imagens x. detecção de objetos x classificação de imagens

A **segmentação de imagens** representa uma evolução avançada da classificação de imagens e detecção de objetos.

A ***classificação de imagens*** aplica um rótulo de classe a uma imagem.

A ***detecção de objetos*** combina a classificação de imagens com a localização de objetos, gerando regiões retangulares, chamadas de "caixas delimitadoras", em que os objetos estão localizados

Embora a detecção de objetos possa classificar vários elementos dentro de uma imagem e aproximar a largura e altura de cada elemento, **ela não pode discernir limites ou formas precisas.**

Isso limita a capacidade dos modelos de detecção de objetos convencionais de delinear objetos unidos de perto com caixas delimitadoras sobrepostas.

Segmentação de imagens x. detecção de objetos x classificação de imagens

A ***segmentação de imagens*** processa dados visuais no nível de pixel, usando várias técnicas para anotar pixels individuais como pertencentes a uma classe ou instância específica.

Técnicas de segmentação de imagem "clássicas" determinam anotações por meio da análise de qualidades inerentes de cada pixel (chamadas "heurística"), como cor e intensidade, enquanto modelos de deep learning empregam redes neurais complexas para reconhecimento sofisticado de padrões.

As saídas dessa anotação são ***máscaras de segmentação***, representando o limite pixel a pixel específico e a forma de cada classe (normalmente correspondendo a diferentes objetos, funcionalidades ou regiões) na imagem.

Segmentação de imagens x. detecção de objetos x classificação de imagens

A segmentação de imagens pode ser categorizada como:

- segmentação semântica;
- segmentação de instâncias.

Classes semânticas: “coisas” e “elementos do ambiente”

A diferença entre cada tipo de tarefa de segmentação de imagem reside na forma como tratam classes semânticas: as categorias específicas às quais um determinado pixel pode ser determinado pertencer.

No jargão da visão computacional, existem dois tipos de classes semânticas.

Cada um se presta a diferentes técnicas para segmentação precisa e eficaz.

Classes semânticas: “coisas” e “elementos do ambiente”

Coisas:

Coisas são classes de objetos com formas características, como “carro”, “árvore” ou “pessoa”.

Normalmente, as coisas têm instâncias claramente definidas que são contáveis.

Elas têm relativamente pouca variação de tamanho de uma instância para outra, bem como partes constituintes distintas da coisa em si: por exemplo, todos os carros têm rodas, mas uma roda não é um carro.

Classes semânticas: “coisas” e “elementos do ambiente”

Elementos do ambiente:

Elementos do ambiente se refere a classes semânticas que são amorfas e altamente variáveis em tamanho, como "céu" ou "água" ou "grama".

Normalmente, os elementos do ambiente não têm instâncias individuais contáveis e claramente definidas.

Ao contrário das coisas, os elementos do ambiente não têm partes distintas: uma lâmina de grama e campo de grama são ambas igualmente "grama".

Classes semânticas: “coisas” e “elementos do ambiente”

Algumas classes, sob certas condições de imagens, podem ser *coisas* ou *elementos do ambiente*.

Por exemplo, um grande grupo de pessoas pode ser interpretado como várias "pessoas" (cada uma sendo uma *coisa* de forma distinta e contável) ou uma "multidão" singular, com forma amorfa.

Embora a maioria dos esforços de detecção de objetos se concentre principalmente em classes de objetos, é importante considerar que elementos como céu, paredes, pisos e solo compõem a maioria do nosso contexto visual.

Classes semânticas: “coisas” e “elementos do ambiente”

Algumas classes, sob certas condições de imagens, podem ser *coisas* ou *elementos do*

Os elementos do ambiente são pontos de dados essenciais para identificar objetos, e vice-versa: um objeto metálico na estrada geralmente é um carro; o fundo azul atrás de um barco provavelmente é água, enquanto o fundo azul atrás de um avião provavelmente é céu.

Isto é de particular importância para modelos de deep learning.

Segmentação Semântica

A segmentação semântica é o tipo mais simples de segmentação de imagem.

Um modelo de segmentação semântica atribui uma classe semântica a cada pixel, mas não produz qualquer outro contexto ou informação (como objetos).

A segmentação semântica trata todos os pixels como *elementos do ambiente*; ela não diferencia entre *elementos do ambiente* e *objetos*.

Por exemplo, um modelo de segmentação semântica treinado para identificar certas classes em uma rua da cidade produziria máscaras de segmentação indicando as fronteiras e contornos para cada classe relevante de objetos (como veículos ou postes de luz) e elementos do ambiente (como estradas e calçadas), mas não faria qualquer distinção entre (ou contagem do número de) múltiplas instâncias da mesma classe. Por exemplo, carros estacionados um na frente do outro podem ser simplesmente tratados como um longo segmento de “carro”.

Segmentação Semântica



(a) Source Image



(b) Semantic Segmentation

Segmentação de Instâncias

A segmentação de instâncias inverte as prioridades da segmentação semântica: enquanto os algoritmos de segmentação semântica preveem apenas a classificação semântica de cada pixel (sem considerar instâncias individuais), **a segmentação de instâncias delinea a forma exata de cada instância de objeto separadamente.**

A segmentação por instância isola *objetos de elementos do ambiente*, que ignora e, portanto, pode ser entendida como uma forma evoluída de detecção de objetos que produz uma máscara de segmentação precisa em vez de uma caixa delimitadora aproximada.

Segmentação de Instâncias

É uma tarefa mais difícil do que a segmentação semântica: mesmo quando os objetos da mesma classe estão tocando ou mesmo se sobrepondo, os modelos de segmentação de instância devem ser capazes de separar e determinar a forma de cada um, enquanto os modelos de segmentação semântica podem simplesmente agrupá-los.

Considere, por exemplo, como os dois modelos diferentes tratam os veículos estacionados nesta imagem de uma rua urbana.



Segmentação de Instâncias


Os algoritmos de segmentação de instâncias geralmente adotam uma abordagem de dois estágios ou one-shot para o problema.

Modelos de dois estágios, como redes neurais convencionais (R-CNNs) baseadas na região, realizam a detecção de objetos convencionais para gerar caixas delimitadoras para cada instância proposta e, em seguida, realizam uma segmentação e classificação mais refinadas dentro de cada caixa delimitadora.

Modelos one-shot, como o YOLO (You Only Look Once), alcançam a segmentação de instâncias em tempo real ao realizar a detecção, classificação e segmentação de objetos simultaneamente.

Casos de uso de Segmentação de imagem

Imagens médicas: a segmentação de imagem possui muitas aplicações em radiografia, imagens de ressonância magnética (MRI), ultrassons e tomografia computadorizada (CT), auxiliando em tarefas como detecção de tumores, segmentação cerebral, diagnóstico de doenças e planejamento cirúrgico.



Casos de uso de Segmentação de imagem

Veículos autônomos: a segmentação de imagem permite que carros autônomos evitem obstáculos como pedestres e outros carros, além de identificar faixas e sinais de trânsito.

É usado da mesma forma para informar a navegação em robótica.

Imagem de satélite: a segmentação semântica e de instância automatizam a identificação de diferentes terrenos e feições topográficas.

Casos de uso de Segmentação de imagem

Cidades inteligentes: a segmentação de imagens alimenta tarefas como monitoramento e vigilância de tráfego em tempo real.

Fabricação: além de alimentar tarefas robóticas, a segmentação de imagens alimenta a classificação do produto e a detecção de defeitos.

Agricultura: a segmentação de imagens ajuda os agricultores a estimar os rendimentos das culturas e detectar ervas daninhas para remoção.

Segmentação de imagem na prática

```
import cv2
import numpy as np
import matplotlib.pyplot as plt
```

```
img = cv2.imread('/content/drive/MyDrive/Visao/planta.jpg')
img_rgb = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
```

```
# Converter para HSV e segmentar verde (folha)
hsv = cv2.cvtColor(img, cv2.COLOR_BGR2HSV)
lower_green = np.array([35, 40, 40])
upper_green = np.array([85, 255, 255])
mask = cv2.inRange(hsv, lower_green, upper_green)
```

```
# Limpar ruído
mask = cv2.morphologyEx(mask, cv2.MORPH_OPEN, np.ones((5,5), np.uint8))
mask = cv2.morphologyEx(mask, cv2.MORPH_CLOSE, np.ones((5,5), np.uint8))
```

```
# Encontrar contornos (separa folhas individuais)
contours, _ = cv2.findContours(mask, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)
cv2.drawContours(img_rgb, contours, -1, (0, 255, 0), 2)
```

**Método estatístico,
sem utilizar nenhum
modelo.**

Segmentação de imagem na prática

```
# Visualizar
```

```
plt.figure(figsize=(15, 5))
```

```
plt.subplot(1, 3, 1)
```

```
plt.title("Imagem Original")
```

```
plt.imshow(img_rgb)
```

```
plt.axis('off')
```

```
plt.subplot(1, 3, 2)
```

```
plt.title("Máscara Verde (Folha)")
```

```
plt.imshow(mask, cmap='gray')
```

```
plt.axis('off')
```

```
plt.subplot(1, 3, 3)
```

```
plt.title("Contornos Detectados")
```

```
plt.imshow(img_rgb)
```

```
plt.axis('off')
```

```
plt.show()
```

```
# Estatística simples
```

```
area_folha = np.sum(mask > 0) / (mask.shape[0] *
```

```
mask.shape[1]) * 100
```

```
print(f"Área foliar estimada: {area_folha:.1f}% da imagem")
```

Segmentação com YOLO:

```
results = model.predict(  
    source="/content/drive/MyDrive/Visao/planta.jpg",  
    conf=0.25,  
    save=False  
)
```

Exibindo o resultado:

```
import matplotlib.pyplot as plt  
  
result = results[0]  
  
img_segmentada = result.plot()  
  
plt.figure(figsize=(10,8))  
plt.imshow(img_segmentada[...,:-1])  
plt.axis("off")  
plt.show()
```



Dúvidas?

MUITO OBRIGADA!!!!



cilene.real@facens.br