



Visão Computacional e Deep Learning

Ma. Cilene Renata Real
cilene.real@facens.br

Agenda

- Integração entre Visão Computacional e LLMs
- Deploy com TensorFlow Serving e TorchServe
- Exercício Final

A integração entre Visão Computacional e LLMs (Large Language Models) é uma das principais tendências atuais em IA.

Ela permite que um sistema compreenda imagens e linguagem ao mesmo tempo, em vez de tratar cada modalidade separadamente.

Esse tipo de sistema é chamado de modelo multimodal.

O que é multimodalidade?

Um modelo multimodal é capaz de processar diferentes tipos de dados (modalidades), como:

- Imagens
- Texto
- Áudio
- Vídeo
- Documentos (texto + imagens)
- Sensores (em aplicações industriais e robótica)

Na visão computacional, normalmente a integração ocorre entre imagem + texto.

Integração entre Visão Computacional e LLMs

Aplicações Reais:

Área	Exemplo
Medicina	Interpretar exames e responder perguntas sobre radiografias, tomografias ou lâminas histológicas.
Indústria	Detectar defeitos em peças e gerar relatórios automáticos.
Agricultura	Identificar pragas, doenças e estimar a saúde das plantas a partir de imagens.
Segurança	Descrever automaticamente eventos capturados por câmeras e auxiliar na análise de incidentes.
Varejo	Contagem de produtos, análise de prateleiras e atendimento ao cliente por meio de imagens.
Educação	Explicar diagramas, gráficos, mapas e experimentos enviados pelos alunos.
Acessibilidade	Descrever cenas para pessoas com deficiência visual.

Vantagens:

- Compreensão conjunta de imagem e texto.
- Respostas em linguagem natural, mais fáceis de interpretar.
- Capacidade de raciocinar sobre o conteúdo visual, indo além da simples detecção de objetos.
- Maior flexibilidade para diferentes tarefas sem necessidade de treinar um modelo específico para cada uma.

Desafios:

- Alto custo computacional para treinamento.
- Necessidade de grandes conjuntos de dados multimodais (imagem + texto).
- Possibilidade de "alucinações", em que o modelo descreve elementos inexistentes na imagem.
- Dificuldade em interpretar imagens muito técnicas, médicas ou de baixa qualidade sem treinamento especializado.
- Questões de privacidade e segurança ao processar imagens contendo informações sensíveis.

Deploy com TensorFlow Serving e TorchServe refere-se ao processo de **disponibilizar modelos de Machine Learning ou Deep Learning para uso em produção**, permitindo que aplicações façam previsões por meio de APIs de forma rápida, escalável e confiável.

O que é Deploy de um modelo?

Após treinar um modelo, ele precisa ser disponibilizado para outras aplicações.

Por exemplo, imagine um modelo de visão computacional que identifica defeitos em peças industriais.

Fluxo:

- Uma câmera captura a imagem.
- A imagem é enviada ao servidor.
- O servidor executa o modelo.
- Retorna: um json (exemplo)

Quem faz essa execução é o servidor de modelos.

TensorFlow Serving

O TensorFlow Serving é um sistema desenvolvido pelo Google para servir modelos treinados com o framework TensorFlow.

Seu objetivo é colocar modelos em produção de maneira eficiente.

Características:

- alta performance
- baixa latência
- suporta GPU
- suporta CPU
- escalabilidade
- versionamento automático
- APIs REST e gRPC

TorchServe

O TorchServe é o equivalente para modelos desenvolvidos com PyTorch. Também disponibiliza modelos através de APIs.

Treinamento PyTorch - Modelo (.pt) - TorchServe - REST API - Cliente

Aplicações:

Esses servidores são usados em diversos cenários:

- **Visão computacional:** classificação de imagens, detecção de objetos e segmentação.
- **Medicina:** análise de exames de imagem.
- **Indústria:** inspeção automática de qualidade.
- **Varejo:** reconhecimento de produtos e análise de prateleiras.
- **Segurança:** reconhecimento facial e detecção de eventos.
- **Sistemas de recomendação:** disponibilização de modelos que geram recomendações em tempo real.

Exemplo completo:

Imagine uma fábrica que utiliza um modelo treinado em PyTorch para detectar defeitos em peças.

- Uma câmera captura a imagem da peça.
- A imagem é enviada ao **TorchServe** via uma requisição HTTP.
- O TorchServe carrega o modelo e realiza a inferência.
- A API retorna:
- O sistema da fábrica decide automaticamente se a peça segue para a próxima etapa ou é descartada.

Se o mesmo modelo tivesse sido desenvolvido em TensorFlow, o fluxo seria praticamente idêntico, mas utilizando o **TensorFlow Serving**.

Entrega Final

Considerando o conteúdo agregado, selecione uma imagem ou vídeo e realize pelo menos duas implementações aprendidas.



Dúvidas?

MUITO OBRIGADA!!!!



cilene.real@facens.br