

Especialização em
IA & Machine Learning

IA Generativa & Engenharia de Prompts



Contexto do Encontro

Vamos começar!

- Este encontro promoverá o **entendimento base** para a disciplina, onde iremos discutir sobre fundamentos de **IA Generativa**, aprendizado/produção de **novos conteúdos**, técnicas utilizadas **por trás das respostas geradas** por modelos de linguagem.

Como um modelo generativo consegue receber uma instrução textual e produzir uma resposta nova, coerente e aparentemente inteligente !?

Por que estudar IA Generativa agora?


- A IA Generativa já aparece em educação, desenvolvimento de software, atendimento, marketing, análise documental, design, produção de conteúdo e apoio à decisão.
- Ela não apenas automatiza tarefas repetitivas, mas também apoia atividades ligadas à linguagem, síntese, criatividade e análise.
- O desafio atual não é apenas usar a ferramenta, mas entender seus limites, riscos e formas de avaliação.

O que torna IA Generativa diferente?

- Modelos tradicionais costumam classificar, prever, detectar ou recomendar.
- Modelos generativos produzem novas saídas: textos, imagens, código, resumos, explicações e variações de conteúdo.
- A saída não é apenas uma classe escolhida; é uma nova sequência produzida a partir dos padrões aprendidos.

Exemplo: Classificação *versus* Geração

- Comentário: *"A explicação foi boa, mas os exemplos de código passaram rápido demais."*
- Uma abordagem discriminativa poderia retornar: categoria = ritmo da aula; sentimento = misto; prioridade = média.
- Uma abordagem generativa poderia retornar: **resumo, interpretação, sugestão de melhoria, resposta ao aluno e plano de ação.**



Vocabulário Teórico

Vamos adiantar...

- IA Generativa, IA Discriminativa, Amostra Sintética, Espaço Latente, *Autoencoder*, VAE, GAN, *Diffusion Model*, *Transformer*, LLM, Token, *Tokenizer*, Vocabulário, *Embedding*, *Attention*, Janela de Contexto, Modelo-Base, Inferência, *Temperature*, *Top-P*, *Top-K*, *Seed*, Alucinação...



Conteúdo Programático

Ementa

Conceitos Introdutórios e Fundamentos:

- IA Discriminativa versus IA Generativa: Classificação, Predição e Geração
- Modelos Generativos Clássicos: *Autoencoders*, *VAEs* e *GANs*
- *Diffusion Models* como família moderna para geração de imagens e outras modalidades

Ementa

Entendendo *Large Language Models*

- Arquitetura Transformer e Fundamentos de LLM
- Coleta, Seleção e Classificação de Dados
- Tokenização: Representação Numérica da Linguagem Natural
- Pré-Treinamento para Modelos de LLM
- Características e Limitações de Modelos Base


Ementa

- Ajuste Supervisionado
- Redução de Alucinações e Integrações
- Contexto, Raciocínio e Tokens
- Aprendizado por Reforço
- Avaliação de Modelos e Benchmarks

Programação

Laboratórios

- Plataforma *Hugging Face*
- Primeiros Prompts
- Tecnologias Emergentes



IA Discriminativa *versus* Generativa

IA Discriminativa

- Aprende a distinguir classes ou categorias.
- Utilizada para classificação e predição.
- Responde à pergunta: "*A qual classe este dado pertence?*"

Processo

1. Recebe dados rotulados.
2. Aprende padrões que diferenciam as classes.
3. Prediz uma categoria ou valor para novos dados.

Exemplos

1. Spam / Não Spam.
2. Aprovar ou Negar Crédito.
3. Diagnóstico Médico.
4. Provisão de Vendas.

Algoritmos

1. Regressão Logística.
2. Árvores de Decisão.
3. Redes Neurais Classificadoras.

IA Generativa

- Aprende padrões dos dados para criar novos conteúdos.
- Utilizada para geração de texto, imagens, áudio, vídeo e código.
- Responde à pergunta: "*Como criar algo semelhante ao que aprendi?*"

Processo

1. Analisa grandes volumes de dados.
2. Analisa padrões, estruturas, relações.
3. Produz novos conteúdos semelhantes aos dados de treinamento.

Exemplos

1. Geração de Textos.
2. Criação de Imagens.
3. Produção de Código.
4. Síntese de Voz.
5. Geração de Vídeos.

Algoritmos

1. *Variational Autoencoders (VAE).*
2. *Generative Adversarial Networks (GAN).*
3. *Diffusions, Transformers, LLM.*

A EVOLUÇÃO DA INTELIGÊNCIA ARTIFICIAL

Da Análise à Ação Autônoma

1. IA ANALÍTICA

Anos 1950–1980



Sistemas baseados em regras e lógica simbólica para resolver problemas específicos.




Exemplos

Sistemas especialistas, regras IF-THEN, Lógica Fuzzy.

2. MACHINE LEARNING

Anos 1990–2000



Algoritmos aprendem padrões a partir de dados para fazer previsões ou classificações.



Exemplos

Regressão, Árvores de Decisão, SVM, Redes Neurais Tradicionais.

3. DEEP LEARNING

Anos 2010–2015



Redes neurais profundas aprendem representações complexas de dados não estruturados.



Exemplos

Visão computacional, Reconhecimento de fala, Tradução automática.

4. IA GENERATIVA

Anos 2015–2020



Modelos aprendem a distribuição dos dados e geram novos conteúdos originais.



Exemplos

GANs, VAEs, Diffusion Models, Transformers, LLMs (ex.: GPT).

5. IA AUMENTADA POR CONTEXTO

Anos 2020–2022



Modelos combinados com recuperação de informação, memória e ferramentas externas (RAG).



Exemplos

Chatbots com base de conhecimento, RAG, Pesquisa semântica.

6. MODELOS AGÊNTICOS

2023+



Modelos capazes de planejar, raciocinar, tomar decisões e agir de forma autônoma para alcançar objetivos.

Exemplos

Agentes autônomos, AutoGPT, BabyAGI, Agentes multi-ferramenta, Sistemas colaborativos.



FOCO

Resolver problemas específicos com regras programadas.



FOCO

Aprender padrões e fazer previsões com dados.



FOCO

Aprender representações complexas de dados em grande escala.



FOCO

Gerar novos conteúdos com base no que foi aprendido.



FOCO

Usar contexto e informação externa para respostas mais precisas.




FOCO

Agir autonomamente no mundo real para alcançar objetivos.



O FUTURO É AGÊNTICO

➤ A próxima fronteira é a colaboração entre humanos e agentes de IA autônomos, confiáveis e alinhados a objetivos.



Modelos Generativos Clássicos: *Autoencoders*, *VAEs* e *GANs*

O que são?

Autoencoders (AE)

- Aprendem uma representação comprimida dos dados.
- Utilizados para redução de dimensionalidade e reconstrução.

Variational Autoencoders (VAE)

- Evolução dos *Autoencoders*.
- Permitem gerar novos exemplos semelhantes aos dados originais.


Generative Adversarial Networks (GAN)

- Dois modelos competem entre si.
- Produzem imagens extremamente realistas.

Antes dos LLMs e dos modelos de difusão, a geração de conteúdo era realizada por arquiteturas neurais especializadas em aprender padrões dos dados.

AUTOENCODER: ETAPAS DO PROCESSO

O autoencoder aprende a comprimir (codificar) e reconstruir a entrada.



COMO FUNCIONA:



OBJETIVO



Minimizar a diferença entre a imagem original e a reconstruída.

(Função de perda)

VAE (VARIATIONAL AUTOENCODER)

ETAPAS DO PROCESSO



Diferente do Autoencoder tradicional, o VAE aprende uma **distribuição probabilística** do espaço latente e pode gerar novos exemplos.

1 ENTRADA


Imagem original



28 x 28
(784 pixels)


2 ENCODER

A rede comprime a imagem e gera dois vetores: média (μ) e log variância ($\log \sigma^2$)



3 ESPAÇO LATENTE

Representação probabilística (distribuição)



Cada ponto no espaço latente representa uma possível versão da imagem.

4 SAMPLING

Amostragem usando o Reparameterization Trick


Reparameterization Trick

$$z = \mu + \sigma \odot \epsilon$$
 onde $\epsilon \sim N(0, I)$
 e $\sigma = \exp(0.5 * \log \sigma^2)$

Resultado
Vetor latente z

5 DECODER

A rede reconstrói a imagem a partir do vetor z



6 SAÍDA


Imagem reconstruída



28 x 28
(784 pixels)

COMO FUNCIONA O ESPAÇO LATENTE PROBABILÍSTICO

Distribuição aprendida



O encoder aprende μ e σ^2 para cada imagem.

Amostragem



Um ponto z é amostrado dessa distribuição.

Decodificação



O decoder transforma z em uma imagem.

Imagem gerada



Podemos gerar novas imagens amostrando novos pontos z.

FUNÇÃO DE PERDA DO VAE

O VAE otimiza duas partes:

- 1 Reconstrução**
Mede o erro entre a imagem original e a reconstruída.
- 2 KL Divergence**
Regulariza a distribuição latente para ficar próxima da distribuição normal padrão $N(0, I)$.

$$\text{Loss} = \text{Reconstrução} + \beta * \text{KL Divergence}$$

(β geralmente = 1)

VANTAGENS DO VAE



Espaço latente contínuo e organizado.



Geração de novos exemplos.



Permite interpolação entre imagens.






Base para muitos modelos gerativos modernos.



RESUMO: O VAE aprende uma distribuição no espaço latente (μ e σ), amostra pontos dessa distribuição e os decodifica para gerar novas imagens.

GAN (GENERATIVE ADVERSARIAL NETWORK)

Duas redes neurais competem entre si: o **Gerador** cria imagens falsas e o **Discriminador** tenta descobrir se são reais ou falsas.



RESULTADO

O gerador aprende a produzir imagens extremamente realistas que se tornam indistinguíveis das imagens reais.



APLICAÇÕES



Geração de rostos



Edição de imagens



Aumento de dados sintéticos



Jogos e arte digital



Cinema e efeitos especiais

Referências (*Kaggle*)

Autoencoders (AE)

- <https://www.kaggle.com/code/arnrob/autoencoders-and-vae>
- <https://www.kaggle.com/code/theblackmamba31/denoising-mnist-images-using-autoencoder>


Variational Autoencoders (VAE)

- <https://www.kaggle.com/code/redpen12/variational-autoencoders>
- <https://www.kaggle.com/code/rvislaywade/visualizing-mnist-using-a-variational-autoencoder>

Referências (*Kaggle*)

Generative Adversarial Networks (GAN)

- <https://www.kaggle.com/code/kirkdco/auto-encoder-vae-gan-part-i-auto-encoder>
- <https://www.kaggle.com/code/shivamb/dcgan-on-mnist>



Diffusion Models como família moderna para geração de imagens e outras modalidades

Conceito

- *Diffusion Models* são modelos generativos capazes de criar novos conteúdos a partir de ruído aleatório.
- Seu princípio fundamental consiste em aprender a reconstruir padrões removendo ruído gradualmente até gerar uma nova imagem.
- Atualmente é a principal tecnologia por trás de ferramentas como *Stable Diffusion*, *DALL-E* e *Midjourney*.

Objetivos: gerar imagens inéditas, criar conteúdo visual realista, produzir dados sintéticos, apoiar aplicações multimodais.

Como funcionam?

O treinamento ocorre em duas etapas principais.

Forward Process

- Consiste em adicionar ruído progressivamente a uma imagem até que toda a informação original seja perdida.

Reverse Process

- O modelo aprende a realizar o processo inverso, removendo o ruído gradualmente até reconstruir uma imagem coerente. Em outras palavras, o modelo aprende a transformar ruído em conteúdo estruturado.

Analogia: imagine uma fotografia completamente coberta por tinta - o *Diffusion Model* aprende como remover essa tinta camada por camada até revelar uma nova imagem.

Vantagens e Aplicações

Principais Vantagens:

- Maior estabilidade de treinamento.
- Imagens mais realistas.
- Maior diversidade de resultados.
- Melhor controle por meio de prompts.
- Capacidade de edição e transformação de imagens.

Aplicações: design e publicidade, produção de conteúdo digital, jogos e entretenimento, arquitetura e moda, medicina e pesquisa científica, geração de dados sintéticos.

Diffusion Models revolucionaram a geração de imagens ao aprenderem a criar conteúdo visual de alta qualidade por meio da remoção gradual de ruído. Eles representam o estado da arte em geração de imagens na IA moderna.

DIFFUSION MODELS

GERAÇÃO DE CONTEÚDO REMOVENDO RUÍDO PASSO A PASSO




Ideia central: o modelo aprende a transformar ruído aleatório em conteúdo estruturado, invertendo um processo no qual o ruído é adicionado gradualmente à imagem.



Analogia: imagine uma imagem sendo coberta por várias camadas de estática de TV. O modelo aprende a remover essas camadas.


1. FORWARD PROCESS (ADIÇÃO DE RUÍDO)

Durante o treinamento, ruído é adicionado gradualmente à imagem real.




2. REVERSE PROCESS (REMOÇÃO DE RUÍDO / GERAÇÃO)

O modelo aprende a inverter o processo, removendo o ruído passo a passo.




COMO FUNCIONA?



CARACTERÍSTICAS PRINCIPAIS

- Geração de alta qualidade:** Produz imagens muito realistas e com grande diversidade.
- Treinamento mais estável:** Não possui os problemas de instabilidade típicos das GANs.
- Melhor controle:** Permite guiar a geração com prompts, condições e edição.
- Multimodal:** Além de imagens, pode gerar áudio, vídeos, 3D, texto e mais.

ARQUITETURA TÍPICA



VANTAGENS VS OUTROS MODELOS

Modelo	Qualidade	Diversidade	Estabilidade	Controle
Autocoder	🟡 Média	🟡 Baixa	✅ Alta	🟡 Baixo
VAE	🟡 Média	🟡 Média	✅ Alta	🟡 Médio
GAN	✅ Alta	🟡 Média	❌ Baixa	🟡 Médio
Diffusion	✅ Muito Alta	✅ Alta	✅ Alta	✅ Alto

✅ Melhor 🟡 Médio ❌ Desafiador

EXEMPLOS DE MODELOS

-  Stable Diffusion (Latent Diffusion)
-  DALL-E 3 (OpenAI)
-  Midjourney
-  Adobe Firefly
-  Imagen (Google)
- E muitos outros...

★ **RESUMO:** Diffusion Models aprendem a remover ruído gradualmente para revelar uma nova imagem. Essa abordagem revolucionou a geração de imagens e hoje é a base de modelos como Stable Diffusion, DALL-E e Midjourney.

Referências (*Kaggle*)

Train a Diffusion Model

- <https://www.kaggle.com/code/simonedegasperis/train-a-diffusion-model>

Stable Diffusion from Scratch

- <https://www.kaggle.com/code/takihasan/stable-diffusion-from-scratch>

- O que é um *Diffusion Model*
- *Forward Process*
- *Reverse Process*
- Adição de ruído
- Remoção de ruído
- Geração de imagens a partir de ruído

- *Prompt*
- *Text Encoder*
- Espaço Latente
- *U-Net*
- Processo de *Denoising*
- *Pipeline do Stable Diffusion*



Arquitetura Transformer e Fundamentos de LLM

LLM e NLP

- As *Large Language Models* (**LLMs**) fazem parte da área de *Natural Language Processing* (**NLP**), dedicada a criar métodos para que máquinas possam lidar com a linguagem humana.
- Durante muito tempo, essa área foi dominada por modelos como as **RNNs** (*Recurrent Neural Networks*), que tentavam interpretar texto de forma sequencial.

Attention is All you Need

- A mudança decisiva chegou em 2017, com a publicação de “*Attention Is All You Need*”, do Google Brain.
- Esse trabalho apresentou a arquitetura **Transformer**, que rompeu com a lógica sequencial das RNNs e colocou o mecanismo de **atenção** como elemento central.

A partir dessa nova base, surgiram modelos como **BERT**, **GPT**, **GPT-2**, **GPT-3**, e mais tarde o **ChatGPT**, que popularizou o acesso a LLMs em 2022. Esse momento marcou o início da adoção massiva de IA generativa.

Attention is All you Need





Figure 1: The Transformer - model architecture.

Scaled Dot-Product Attention



Multi-Head Attention




Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

- *Ashish Vaswani, 2017*
- Clique [aqui](#) para acessar.

Por que o Transformer mudou tudo?

- Ele captou melhor a estrutura da linguagem porque consegue analisar o texto de forma global, identificar relações amplas e perceber padrões que técnicas anteriores simplesmente não conseguiam capturar.
- Essa capacidade faz os modelos parecerem que “raciocinam”, no sentido de gerar respostas que estabelecem conexões, interpretam nuances e mantêm coerência ao longo de muitos parágrafos.
- Esse avanço é o alicerce de tudo que vemos hoje em agentes inteligentes e sistemas conversacionais modernos.



Coleta, Seleção e Classificação de Dados

Contextualizando

- Antes que uma LLM seja capaz de dialogar, responder perguntas ou executar tarefas complexas, ela precisa passar por uma fase inicial de aprendizado em larga escala.
- Essa etapa, chamada de **pré- treinamento**, tem um objetivo muito específico: expor o modelo a uma quantidade massiva de textos reais para que ele aprenda, por conta própria, como a linguagem funciona.
- O foco não está em **decorar** informações da web, mas em **internalizar padrões**.

A Matéria-Prima



The Data ▾ Resources ▾ Commun

Common Crawl maintains a **free, open repository** of web crawl data that can be used by anyone.

Common Crawl is a 501(c)(3) non-profit founded in 2007.

We make wholesale extraction, transformation and analysis of open web data accessible to researchers.

Overview

Over **300 billion** pages spanning 19 years.

Free and open corpus since 2007.

Common Crawl

- <https://commoncrawl.org>

Limpando e Refinando o Conteúdo

FineWeb

- <https://huggingface.co/spaces/HuggingFaceFW/blogpost-fineweb-v1>



The FineWeb pipeline


Resultado

- Depois de filtrado, todo esse conteúdo é convertido em **uma sequência contínua de tokens**, como se fosse um único conjunto de dados gigantesco que atravessa diferentes temas, estilos e formatos textuais.
- Essa fase é a **fundação** sobre a qual todo o restante é construído. Sem esse grande mergulho na linguagem, nenhuma LLM seria capaz de produzir respostas úteis ou comportamentos complexos nas etapas seguintes.

This is a sample text



Tokenization



Tokenização: Representação Numérica da Linguagem Natural

Contextualizando

- Depois de reunir e limpar o conjunto de textos que servirá de base para o treinamento, encontramos uma limitação fundamental: modelos não conseguem trabalhar diretamente com palavras.
- Computadores operam com números, não com frases, letras ou sinais de pontuação.
- Da linguagem humana ao binário; BPE (*Byte Pair Encoding*).

1 TEXTO ORIGINAL

2 PRÉ-PROCESSAMENTO

- a ia está transformando o desenvolvimento de software.

3 TOKENIZAÇÃO (BPE)

```

graph TD
    Root[Gestãõ] --> a[a]
    Root --> G[G]
    Root --> Gestã[Gestã]
    G --> Gtransformando[Gtransformando]
    G --> Gõ[Gõ]
    Gestã --> Gdesenvolvimento[Gdesenvolvimento]
    Gestã --> Gde[Gde]
    Gdesenvolvimento --> Gsoftware[Gsoftware]
    Gdesenvolvimento --> dot[.]
  
```

($\tilde{G}$ representa espaço no início do token)

4 CONVERSÃO PARA IDS

64	29871	1823	16542
317	4021	286	6432
13			

5 EMBEDDINGS

O BPE começa com caracteres e, iterativamente, funde os pares mais frequentes até formar o vocabulário.

Vocabulário final (exemplo)
Cada token tem um ID único.

ID	Token
64	a
29871	ia
1823	está
16542	transformando
317	o
4021	desenvolvimento
286	de
6432	software
13	.

1. Aprendizado do vocabulário

O BPE é treinado em um grande corpus de texto para identificar quais pares de caracteres/subpalavras são mais frequentes e construir o vocabulário.

2. Mapeamento

Cada token do vocabulário recebe um ID numérico.

3. Representação numérica

Os IDs são convertidos em vetores densos (embeddings) que o modelo usa para entender o contexto e gerar respostas.

Resumo do processo



Por que subpalavras?

- ✓ Lida bem com palavras raras ou desconhecidas;
- ✓ Reduz o tamanho do vocabulário;
- ✓ Mantém significado de partes de palavras.

Exemplificando

Tiktokenizer

System

You are a helpful assistant

×

User

Content

×

Assistant

Content

×

Add message

```
<|im_start|>system
You are a helpful assistant<|im_end|>
<|im_start|>user
<|im_end|>
<|im_start|>assistant
<|im_end|>
<|im_start|>assistant
```

gpt-3.5-turbo


Token count
23

Price per prompt
\$0.000046

```
<|im_start|>system
You are a helpful assistant<|im_end|>
<|im_start|>user
<|im_end|>
<|im_start|>assistant
<|im_end|>
<|im_start|>assistant
```

```
[100264, 9125, 198, 2675, 527, 264, 11190, 18328, 100
265, 198, 100264, 882, 198, 100265, 198, 100264, 7819
1, 198, 100265, 198, 100264, 78191, 198]
```

<https://tiktokenizer.chatgptcn.com>



Pré-Treinamento para Modelos de LLM

Contextualizando

- Com a tokenização estabelecida, podemos detalhar o mecanismo central que permite a um modelo de linguagem produzir texto: **a previsão sequencial de tokens.**
- Embora a interação pareça dialogada, uma LLM opera de maneira puramente estatística.

Mecanismo de Geração

- O processo de geração começa convertendo a entrada do usuário em tokens.
- Cada palavra, fragmento de palavra, pontuação ou espaço vira um identificador numérico.
- Essa sequência é enviada ao Transformer, que calcula uma distribuição de probabilidade para todos os tokens do vocabulário com dezenas ou centenas de milhares de possibilidades.
- O modelo nunca produz uma resposta fixa.

A Função do Pré-Treinamento

- O modelo inicia o treinamento com parâmetros aleatórios e, portanto, incapaz de produzir qualquer previsão útil. O pré-treinamento consiste em ajustar esses parâmetros, bilhões deles, até que a rede consiga aproximar as distribuições previstas da sequência real observada nos dados.
- O Transformer pode ser imaginado como um sistema com uma quantidade massiva de graus de liberdade.

Janela de Contexto

- Seleciona-se uma janela de tokens do conjunto de dados.
- O modelo calcula a distribuição de probabilidade para o token seguinte.
- A previsão é comparada ao token real.
- Um algoritmo de otimização ajusta os parâmetros para reduzir o erro.
- O procedimento é repetido com outra janela.

Ajuste dos Parâmetros

- Durante o pré-treinamento, o modelo erra o tempo todo.
- A comparação com o token correto aciona o mecanismo de ajuste, que modifica os parâmetros para: aumentar a probabilidade do token certo, reduzir a probabilidade dos incorretos, reorganizar as relações internas envolvidas na previsão.
- Essas pequenas correções, aplicadas em escala massiva, fazem com que o modelo aprenda a estrutura da linguagem humana.

Modelo Base

- Quando os parâmetros atingem desempenho estável, o treinamento produz o modelo base. Esse modelo tem domínio estatístico da estrutura da linguagem, mas ainda não está adaptado para seguir instruções, interagir de forma controlada ou apresentar comportamento alinhado aos objetivos de uso.



Características e Limitações de Modelos Base

Modelo Base

- Após as etapas de coleta, preparação dos dados, tokenização e pré-treinamento, obtemos o que se denomina **modelo base** (*base model*). Nesse estágio, a LLM ainda não opera como um assistente.
- O modelo base é essencialmente um **mecanismo de continuação de sequência**: ele prevê o próximo token com base nos padrões estatísticos presentes nos dados de treinamento. Por isso, costuma ser descrito como um **modelo de simulação textual**, refletindo a regularidade dos conteúdos que processou.

Para saber mais

- Comportamentos
- Alucinações
- *In-Context Learning* (aprendendo a partir do próprio *prompt*)
- Simulações
- **O modelo base não é um assistente!**


Hyperbolic

THE OPEN-ACCESS AI CLOUD


Hyperbolic gives 250,000+ builders affordable on-demand GPUs to train fast, serve via an OpenAI-compatible API, and scale to production.

Deploy GPU Clusters

Schedule a Call



<https://www.hyperbolic.ai>



Ajuste Supervisionado


Contextualizando

- Após o pré-treinamento, o modelo base possui apenas a capacidade de prever continuação de sequência, sem qualquer noção de tarefa, instrução ou papel conversacional.
- Ele não está configurado para atuar como assistente, apenas replica padrões linguísticos do material de treinamento.
- O *Supervised Fine-Tuning* (SFT) é a primeira etapa que converte esse mecanismo genérico em um sistema capaz de seguir instruções e adotar um comportamento específico.

Artigo: OpenAI

Training language models to follow instructions with human feedback

- <https://arxiv.org/abs/2203.02155>



Construção de dados para instrução

- Para habilitar esse comportamento, é necessário expor o modelo a exemplos explícitos de como um assistente deve interagir.
- A abordagem consistiu em construir um dataset especializado, muito menor que o material original, mas altamente qualificado.
- A coleta desse material foi realizada por freelancers contratados, com o objetivo de fornecer amostras de comportamento ideal, servindo como referência explícita do que se espera de um assistente instrucional.

Padronização Formal (Estrutura de Diálogo)

Para que o modelo reconheça a dinâmica conversacional e diferencie os papéis envolvidos, são introduzidos tokens especiais usados como marcadores estruturais. Esses tokens determinam:

- Onde começa e termina uma mensagem.
- Qual agente está falando.
- Como separar metadados do conteúdo.
- Quando interromper a geração.

Marcadores:

- *im_start*
- *im_sep*
- *im_end*

Em resumo...

- O *Supervised Fine-Tuning* transforma o modelo base em um sistema orientado a instruções, estabelece padrões de resposta e papéis conversacionais, reduz a variabilidade em interações comuns, define estilo e comportamento e cria a fundação necessária para etapas de alinhamento mais avançadas.



Redução de Alucinações e Integrações

Alucinações: Consequência do Modelo Base

- Mesmo após o SFT, o modelo continua baseado em previsão de tokens.
- Isso significa que, quando não tem dados suficientes sobre um assunto, ele naturalmente tenta “**completar**” o texto com algo que pareça possível, mesmo que esteja errado.
- Em modelos menores, esse problema é ainda mais comum devido à capacidade reduzida de armazenar padrões e conhecimento.

Alucinações: Consequência do Modelo Base

Para reduzir esse comportamento, o modelo é treinado com exemplos que mostram como agir quando não sabe algo. O processo é simples:

- São criadas perguntas para as quais o modelo normalmente inventaria uma resposta.
- Para essas perguntas, é produzida uma resposta correta e segura, como **“Não tenho informações suficientes sobre isso”**.
- O modelo é ajustado para imitar esse comportamento.

Assim, ele aprende um padrão: **quando a confiança é baixa, a resposta deve ser conservadora.**



Contexto, Raciocínio e Tokens

Contextualizando

- Para entender como modelos de linguagem “pensam”, é importante lembrar que eles não elaboram uma resposta completa internamente para só depois escrevê-la.
- Em vez disso, **o raciocínio do modelo acontece enquanto ele gera tokens.**
- Cada token produzido é influenciado pelo que veio antes, formando uma cadeia que funciona como a própria linha de pensamento. Esse princípio é fundamental para compreender por que certas abordagens aumentam a precisão das respostas.

Reinforcement Learning

- Os modelos de linguagem continuam apresentando erros mesmo após o pré-treinamento e o SFT porque tendem a encurtar o raciocínio, pular etapas e priorizar respostas rápidas, produzindo conclusões sem construir o processo intermediário.
- Esse comportamento é problemático em tarefas que exigem lógica ou cálculos, já que pequenos saltos podem comprometer todo o resultado.
- Para lidar com isso, o *Reinforcement Learning* (RL) foi desenvolvido como uma forma de reforçar padrões de resposta mais completos.

Logo...

- O raciocínio não é um acessório, ele é parte do processo de previsão. Quanto mais raciocínio o modelo gera, maior a precisão.
- O raciocínio do modelo é a sequência de tokens que ele produz. Ele não pensa antes de gerar tokens, ele pensa gerando tokens.
- **Tokens formam o pensamento do modelo!**

Efeitos na Engenharia de Prompts: expressões como “*explique o raciocínio*”, “*mostre o cálculo*” ou “*resolva passo a passo*” funcionam não por magia, mas porque aumentam a quantidade de tokens úteis que sustentam o resultado.



Aprendizado por Reforço

Contextualizando

- Uma comparação com o aprendizado humano.
- Como identificar uma boa resposta?
- Deixando o modelo resolver sozinho.
- O papel estratégico do *Reinforcement Learning*.



Avaliação de Modelos e Benchmarks

Para saber mais...

- <https://arena.ai>
- <https://news.smol.ai>
- <https://www.latent.space>
- <https://github.com/trending>



Hugging Face e Laboratórios



Facens

AQUI TEM ENGENHARIA