

Especialização em
IA & Machine Learning

IA Generativa & Engenharia de Prompts



Contexto do Encontro

IA Generativa: quando a máquina começa a criar

Durante décadas, os computadores foram excelentes em **processar informações estruturadas**:

- Dados Numéricos
- Regras de Negócio
- Consultas
- Sistemas Especialistas

*Com a evolução dos modelos generativos, surge uma nova capacidade: **máquinas capazes de criar novos conteúdos a partir de padrões aprendidos.***

IA Generativa: quando a máquina começa a criar

Hoje, modelos de IA conseguem gerar:

- Textos
- Vídeos
- Imagens
- Áudios
- Códigos
- Interfaces

*A próxima fronteira não é apenas responder perguntas. É **compreender e criar utilizando múltiplas formas de comunicação humana.***

Por que estudar IA Generativa Multimodal?

- Grande parte da informação humana não está em textos. Nós interpretamos o mundo através de **visão, áudio, linguagem, documentos, vídeos, contexto**.
- Um modelo verdadeiramente inteligente precisa compreender diferentes modalidades.

Um médico não analisa apenas um texto de um paciente. Ele combina:

- Histórico clínico
- Exames de imagem
- Sintomas descritos
- Dados laboratoriais

Um engenheiro não analisa apenas documentação. Ele combina:

- Projetos
- Diagramas
- Fotos
- Sensores

A inteligência humana é multimodal. A próxima geração de IA também.

A revolução da criação de IA

(**Antes**) Criar conteúdo dependia de:

- Conhecimento técnico especializado
 - Ferramentas complexas
 - Tempo elevado de produção
 - Equipes multidisciplinares
-
- Exemplo: criar uma campanha publicitária (designer, redator, fotógrafo, editor, *videomaker*).

A revolução da criação de IA

(**Agora**) Uma pessoa pode descrever uma ideia, e a IA transforma essa intenção em:

- Imagens
- Conceitos visuais
- Variações criativas
- Materiais publicitários

A linguagem natural tornou-se **uma nova interface** de criação.

Onde a IA Generativa está sendo aplicada?


- Design e Criatividade
- Engenharia e Indústria
- Saúde
- Educação

O novo papel do *Prompt Engineering*

De descrever comandos para projetar intenções !!

E a pergunta é...

*Estamos criando **ferramentas** ou novas formas de **comunicação**?*



Vocabulário Teórico

Vamos adiantar...

- *Latent Diffusion, CLIP, Modelos Multimodais, ControlNet, LoRA...*



Conteúdo Programático

Ementa

Primeiro, vamos entender os conceitos:

- Geração de Imagens
- Prompts Visuais
- *Latent Diffusion*
- *CLIP*
- Modelos Multimodais
- *ControlNet e LoRA*
- Acessibilidade
- Avaliação Multimodal


Ementa

Agora, vamos conhecer algumas ferramentas:

- *CloudFlare – Workers AI, N8N, Ethereum...*

E trabalhar um pouco:

- Laboratório Multimodal: Imagem para Texto; Texto para Imagem.
- Fluxos Básicos com N8N.



Geração de Imagens

Geração de Imagens com IA

- Durante muito tempo, sistemas computacionais atuavam principalmente na **manipulação de imagens existentes**: recordar, redimensionar, aplicar filtros, remover elementos, melhorar a qualidade.
- A IA Generativa muda esse paradigma: a máquina **deixa de apenas modificar** imagens existentes e passa a criar **novos conteúdos visuais** a partir de uma **intenção** humana.
- Modelos generativos aprendem padrões presentes em grandes conjuntos de imagens: formas, cores, texturas, objetos, estilos, relações.
- Depois, utilizam esse **conhecimento** para criar **novas combinações**.

Como uma IA aprende a gerar imagens?

- Um modelo de geração de imagens é treinado com milhões de exemplos: imagem + descrição, aprendizado de padrões, representação matemática, nova imagem gerada.

Durante o treinamento, o modelo aprende relações como:

- *"Cachorros possuem quatro patas"*
- *"Um céu possui determinadas características visuais"*
- *"Um rosto possui estruturas específicas"*

Porém, a IA não armazena imagens. Ela aprende uma **representação estatística e matemática dos conceitos visuais**.

Exemplo

Ao receber:

"Uma casa moderna na praia durante o pôr do sol"

O modelo combina conceitos aprendidos: casa moderna + pôr do sol + praia + estilo visual + composição.

A evolução dos modelos para geração de imagem

Modelos Tradicionais

- *Computer Graphics* (baseados em regras explícitas): modelagem 3D, renderização, texturas definidas manualmente.
- Dependiam de grande intervenção humana.

A evolução dos modelos para geração de imagem

Redes Generativas (GANs)

- Introduziam a ideia de: “*uma rede neural capaz de criar imagens novas*”.
- Arquitetura baseada em Gerador (cria imagens) x Discriminador (avalia se parecem reais).

A evolução dos modelos para geração de imagem

Modelos de Difusão

- Modelos como ***Stable Diffusion*** introduziram uma nova abordagem: maior qualidade, controle através de texto, geração em alta resolução, personalização.
- O usuário deixa de **editar**, e passa a descrever uma **intenção**.

*A geração de imagens por IA representa uma mudança fundamental: saímos de sistemas que executam instruções visuais para sistemas capazes de interpretar intenções e criar novos conteúdos. **Mas como uma máquina consegue transformar uma frase em uma imagem?***



Prompts Visuais

Comunicando uma intenção com a IA

- Um prompt visual não é apenas uma frase. Ele é uma especificação composta por: **objeto principal, contexto, estilo visual, composição, iluminação, câmera, detalhes técnicos**

Exemplos:

- “*Um carro futurista.*” (resultado: uma interpretação genérica).
- “*Um carro esportivo elétrico futurista, estacionado em uma cidade inteligente à noite, arquitetura cyberpunk, iluminação neon, fotografia cinematográfica, lente 35mm, alta definição.*” (resultado: a IA recebe mais direcionamentos visuais).

UM PROMPT VISUAL BEM CONSTRUÍDO TEM ELEMENTOS-CHAVE:



DA IDEIA AO RESULTADO

PROMPT SIMPLES

"Um cachorro na praia"



RESULTADO:

Genérico, com muitas possibilidades de interpretação.

PROMPT INTERMEDIÁRIO

"Um golden retriever correndo na praia ao pôr do sol"



RESULTADO:

Mais específico, melhor, mas ainda pode variar bastante.

PROMPT AVANÇADO

"Um golden retriever correndo na areia molhada de uma praia tropical durante o pôr do sol, gotas de água no pelo, fotografia profissional, lente 85mm, profundidade de campo, iluminação cinematográfica, alta resolução"



RESULTADO:

Imagem muito mais alinhada à intenção, com alto nível de controle visual.

DICAS RÁPIDAS



Seja descritivo quanto a elementos visuais.



Especifique estilos, cores, materiais e texturas.



Defina ângulo, enquadramento e perspectiva.



Use referências de iluminação e clima (ao pôr do sol, noite, névoa, etc).




Itere e refine: ajuste o prompt até chegar ao resultado desejado.

LEMBRE-SE:



O prompt é sua intenção. Quanto mais clara ela for, melhor a IA poderá visualizá-la.



Latent Diffusion

Latent Diffusion Models

- São modelos de IA que geram imagens (ou áudio/vídeo) "limpando" o ruído de uma imagem borrada, mas fazem isso em uma versão "compactada" da imagem.
- Antes do LDM, a IA tentava desenhar pixel por pixel em alta resolução. Isso exigia supercomputadores e demorava muito.
- O LDM trabalha em um "espaço latente" (uma versão zipada/compactada da imagem). Ele faz todo o trabalho pesado no tamanho pequeno e só descompacta a imagem no final.
- Foi o modelo LDM que permitiu rodar geradores de imagens incríveis (como o ***Stable Diffusion***) em computadores normais e placas de vídeo comuns.

Como funcionam na prática?

O "Zipador" de Imagens (*VAE - Autoencoder*):

- Pega uma imagem pesada (ex.: 512 x 512 pixels) e compacta para um tamanho x menor (ex.: 64 x 64).
- É como transformar um arquivo pesado em um ZIP para a IA trabalhar mais rápido, e no final descompactar para ver o resultado em alta definição.

O "Desenhista / Limpador de Ruído" (U-Net):

- Começa com uma imagem totalmente borrada (só ruído/estática de TV) e vai tirando a sujeira aos poucos em vários passos (ex.: 20 a 30 passos).
- Ele não limpa a imagem original pesada, ele limpa o arquivo "ZIP" no espaço latente.

Como funcionam na prática?

O "Tradutor do Prompt" (Mecanismo de Condicionamento / *Cross-Attention*):

- Pega o texto que você digitou (ex.: *"Um gato astronauta"*) e traduz para a linguagem matemática da IA.
- Funciona como um guia que diz para o "Limpador" em cada passo: *"Olha, a sujeira que você está limpando aqui precisa virar um capacete espacial!"*.

Principais características e vantagens

Tópico	Descritivo
Velocidade e Economia	Como trabalha com dados 64x menores que a imagem final, consome muito menos memória RAM e GPU.
Qualidade Visual	A IA não gasta tempo tentando adivinhar detalhes invisíveis ao olho humano; ela foca na estrutura da imagem e nas formas principais.
Versatilidade Total	O mesmo "motor" pode ser controlado por texto, por um rascunho desenhado à mão, por uma foto de pose ou por outra imagem de referência.
Democratização	Transformou a IA generativa avançada em algo acessível para desenvolvedores, designers e empresas no dia a dia.

Exemplos Práticos

Tópico	Descritivo
Geração de Imagem por Texto (<i>Text-to-Image</i>)	<u>Uso</u> : Digitar um comando e criar ilustrações, fotos conceituais ou arte para jogos (ex.: <i>Stable Diffusion</i> , <i>Flux</i> , <i>SDXL</i>).
Edição e Restauração de Fotos	<u>Uso</u> : Selecionar só uma pessoa em uma foto e trocar a roupa dela, ou expandir as bordas de uma foto que ficou muito cortada.
Controle de Pose e Geometria (<i>ControlNet</i>)	<u>Uso</u> : Desenhar um boneco de palito e fazer a IA gerar uma pessoa real exatamente na mesma pose e ângulo.
Personalização de Marcas e Estilos (<i>LoRA / Fine-Tuning</i>)	<u>Uso</u> : Ensinar o modelo a reconhecer um produto específico da sua empresa com apenas 10 fotos e gerar anúncios novos usando esse produto.



Vamos Praticar



CLIP

Contrastive Language-Image Pre-Training

- É uma IA desenvolvida pela OpenAI (2021) que aprendeu a relacionar imagens e textos da mesma forma que os humanos fazem.
- **O Problema Antigo:** As IA's de visão computacional clássicas eram "cegas" para contexto. Elas só sabiam classificar categorias fixas (ex.: "*é um gato*" ou "*é um cachorro*").
- O CLIP não foi treinado para adivinhar rótulos engessados. Ele aprendeu lendo **400 milhões de pares de imagens e textos da internet**, entendendo conceitos complexos, nuances de estilo, cores e contextos.
- Sem o CLIP (ou modelos similares), os modelos de difusão não conseguiriam entender o que você digita no prompt.

Como funcionam na prática?

Os Dois Encoders (Os "Tradutores"):

- **Text Encoder:** Pega o texto (ex.: *"um gato preto de óculos"*) e transforma em uma lista de números (vetor/embedding).
- **Image Encoder:** Pega uma imagem e transforma essa imagem em uma lista de números da mesma dimensão.

Como funcionam na prática?

O Espaço Vetorial Compartilhado (O "*Lugar Geométrico*"):

- O CLIP coloca textos e imagens dentro de um **mesmo espaço matemático**.
- Se a frase "*um gato de óculos*" e a foto de "*um gato de óculos*" forem passadas ao CLIP, os dois vetores resultantes vão apontar quase para o **mesmo lugar** nesse espaço.

Como funcionam na prática?

O Aprendizado Contrastivo (*Contrastive Learning*):

- Durante o treinamento, a IA pega um lote com várias fotos e várias frases.
- **Objetivo:** Aproximar ao máximo os pares corretos (imagem A com texto A) e afastar ao máximo os pares errados (imagem A com texto B).

O Papel do CLIP nos Modelos de Difusão

Tópico	Descritivo
O Guia do <i>Denoising</i>	No <i>Stable Diffusion</i> , o CLIP atua como o " <i>diretor de arte</i> ".
A Injeção de Contexto (<i>Cross-Attention</i>)	• Você digita o prompt. • O Text Encoder do CLIP transforma seu prompt no vetor de contexto. • A U-Net do modelo de difusão consulta esse vetor a cada passo de remoção de ruído para saber o <i>que</i> desenhar em cada região.
Alinhamento Semântico	É o CLIP que garante que se você pedir " <i>estilo Van Gogh</i> ", a U-Net ajuste as pinceladas para remeter ao artista.

Principais Características e Vantagens

Tópico	Descritivo
Zero-Shot Learning (Classificação Sem Treino Específico)	O CLIP consegue identificar objetos inéditos para os quais nunca foi treinado especificamente. Basta passar a foto e perguntar: <i>"Isso é um guacamole ou um taco?"</i> .
Ponte Multimodal Nativa	Conecta o mundo das palavras (linguagem natural) ao mundo dos pixels (visão computacional).
Robustez a Variações	Funciona incrivelmente bem com fotos reais, desenhos, rascunhos, diagramas ou arte digital.



Vamos Praticar



Modelos Multimodais

Contextualizando

- São sistemas de IA capazes de processar, compreender e relacionar informações vindas de **múltiplas modalidades de dados** ao mesmo tempo (como texto, imagens, áudio, vídeo e tabelas).
- *Unimodal*: O GPT-3 clássico que só lia e escrevia texto, ou uma ResNet que só classificava imagens.
- *Multimodal*: Modelos que conseguem ver uma foto, ler o texto contido nela, responder a perguntas sobre a imagem ou até gerar uma música/vídeo a partir de um comando.

Como funcionam?

Alinhamento de Espaço Latente (Late Fusion / Cross-Attention):

- Modelos especializados separados (um para texto, outro para imagem) transformam suas entradas em vetores de números e são alinhados em um espaço matemático comum.
- O **CLIP** (usado no *Stable Diffusion*), onde a frase "*um carro vermelho*" e a foto de "*um carro vermelho*" apontam para a mesma coordenada no espaço de *embeddings*.

Como funcionam?


Multimodalidade Nativa (*Early Fusion / Unified Architecture*):

- Um único modelo Transformer gigante processa todos os tipos de mídia. As imagens, áudios ou textos são divididos em pequenos pedaços (*tokens*) e tratados do mesmo jeito na entrada.
- Modelos da família **Gemini**, **GPT-4o** e **Llama 3 Vision**, que compreendem texto e pixels nativamente na mesma rede.

Principais Famílias

- **Vision-Language Models (VLM):** Focados em entender imagens e responder em texto (ex: *GPT-4o*, *Gemini*, *Claude 3.5 Sonnet*, *LLaVA*).
- **Text-to-Media (Modelos Generativos):** Focados em transformar texto em mídias visuais ou sonoras (ex: *Stable Diffusion*, *Flux*, *Sora*, *Bark*, *MusicGen*).
- **Any-to-Any (Multimodais Totais):** Arquiteturas capazes de receber qualquer combinação de entradas (texto/imagem/áudio) e devolver qualquer combinação de saídas.

ControlNet & LoRA



ControlNet & LoRA

Contextualizando

Estes dois conceitos são fundamentais para mostrar como a indústria transformou o *Latent Diffusion* de uma ferramenta de "geração aleatória" em uma tecnologia de **precisão profissional e personalização corporativa**.

O que são *ControlNet* e *LoRA*?

- **O Problema do LDM Puro:** O prompt de texto por si só é "vago". Pedir *"uma pessoa correndo em uma rua"* deixa a pose da pessoa, o ângulo da câmera e a iluminação totalmente ao acaso.
- **ControlNet (Controle Estrutural):** Adiciona uma "rédea" de precisão espacial ao modelo. Permite controlar **onde** os objetos ficam e **qual pose** eles devem ter, usando mapas visuais (rascunhos, poses, bordas ou profundidade).
- **LoRA – Low-Rank Adaptation (Personalização de Conceitos):** Permite ensinar a IA a desenhar um **objeto, produto, pessoa ou estilo específico** (ex: o mascote da sua empresa ou a estética de uma marca) sem precisar re-treinar o modelo inteiro de 5 GB.

ControlNet - A Cópia de Segurança com Tranca

- O *ControlNet* faz uma **cópia dos blocos de codificação da U-Net** e congela o modelo original (para ele não esquecer o que já sabe).
- Ele pega uma imagem de controle (ex.: um desenho de palito via *OpenPose* ou linhas de borda via *Canny*).
- Essa condição espacial é injetada na U-Net congelada em cada passo do *denoising*.
- **Resultado:** A IA gera a imagem mantendo a pose exata do desenho, mas aplicando o estilo e o realismo do seu prompt de texto.

LoRA - O "Post-it" de Memória Eficiente

- Re-treinar um modelo de difusão exige modificar bilhões de parâmetros (pesado e caro).
- O LoRA introduz **pequenas matrizes matemáticas extras** (de baixo posto / *low-rank*) ao lado dos pesos originais da U-Net e do CLIP.
- Durante o treino, o modelo original fica congelado e a IA aprende **apenas essas pequenas matrizes** (geralmente arquivos leves de 10 MB a 100 MB).
- **Resultado:** Você pode carregar ou descarregar o "estilo/personagem" em milissegundos apenas plugando o arquivo LoRA no pipeline.

Tabela Comparativa


Característica	Modelo Base (ex: SDXL)	ControlNet	LoRA
O que controla?	O tema geral via texto	A estrutura, pose, geometria	O objeto, estilo, identidade
Entrada extra	Prompt de texto	Imagem de guia (mapa de pose/borda)	Pesos treinados adicionais (arquivo .safetensors)
Tamanho típico	2 GB a 6 GB	~1.4 GB	10 MB a 150 MB
Caso de uso	Criar do zero	Manter composição e enquadramento	Manter consistência de personagem/marca

Exemplos Práticos

Tópico	Descritivo
Arquitetura e Design de Interiores (ControlNet)	• O arquiteto desenha um croqui em linhas pretas e brancas no papel. • O ControlNet (modo <i>Depth/Canny</i>) lê o rascunho e gera uma renderização 3D fotorrealista mantendo a planta exata.
Moda e E-commerce (ControlNet + LoRA)	• O ControlNet define a pose do modelo fotográfico. • O LoRA ensina a IA a vesti-lo com a estampa real de uma coleção de roupas específica.
Publicidade e <i>Branding</i> (LoRA)	• Treinamento do LoRA com 15 fotos da embalagem de um refrigerante para gerar fotos publicitárias do produto em qualquer cenário (praia, neve, cidade) sem alterar o logotipo.



Vamos Praticar



Acessibilidade & Avaliação Multimodal

Acessibilidade Baseada em IA Multimodal

- É o uso de modelos multimodais para quebrar barreiras de comunicação e autonomia para pessoas com deficiências visuais, auditivas, motoras ou cognitivas.

Transformação de Mídias (*Cross-Modal Accessibility*)

- Visão → Texto/Áudio: Descrição detalhada de ambientes, leitura de rótulos de remédios, cardápios e geração automática de texto alternativo (Alt Text) de alta qualidade para web.
- Áudio → Texto/Libras: Transcrição em tempo real de aulas e palestras para pessoas surdas, ou tradução de texto/áudio para avatares de Língua de Sinais.
- Texto/Imagem → Interface Simplificada: Reorganização de layouts complexos e simplificação textual para pessoas com neurodivergência ou baixa visão.

Autonomia no Mundo Real

Aplicativos como *Be My AI* (integrado ao GPT-4o) permitem que pessoas cegas apontem a câmera do celular e perguntem: "*O que tem nesta lata de comida?*" ou "*Qual é o caminho para a porta de saída?*".

<https://www.bemyeyes.com/>

Avaliação Multimodal

- Avaliar um modelo multimodal é muito mais complexo do que avaliar texto puro. Uma imagem gerada pode ser bonita, mas não ter relação com o prompt; ou uma resposta em texto pode estar correta, mas ignorar um detalhe crítico da imagem.
- As 3 dimensões principais de avaliação são: Alinhamento Semântico (***Text-to-Image Alignment***), Qualidade Perceptual e Fator Estético, Fidelidade e Alucinação Visual (***Visual Hallucination***).

Métricas e Benchmarks

Para Modelos Generativos (Ex: Stable Diffusion, FLUX, Sora):

- **FID (Fréchet Inception Distance):** Mede a distância estatística entre o conjunto de imagens reais e as imagens geradas pela IA. *Quanto menor o número, mais realista é a geração.*
- **CLIP Score:** Usa o próprio CLIP para calcular a similaridade de vetor entre o texto do prompt e a imagem gerada. Mede o quão bem a IA "entendeu" o pedido.
- **Human Preference (Ex: ImageReward, PickScore):** Modelos treinados com preferências de especialistas humanos para prever se uma imagem gerada será considerada bonita e correta por pessoas reais.


Métricas e Benchmarks

Para Modelos de Visão e Linguagem (Ex: GPT-4o, LLaVA, Gemini):

- **MMMU (Massive Multi-discipline Multimodal Understanding):** Avalia os modelos em tarefas acadêmicas complexas (gráficos universitários, diagramas de engenharia, provas médicas).
- **POPE (Polling-based Object Probe Evaluation):** Benchmark criado especificamente para medir a taxa de **alucinação visual** do modelo.



Vamos Praticar



Laboratórios

Só vamos!

- Conhecendo a plataforma *CloudFlare*.
- Criando um projeto multimodal no Cursor AI com Python.
- Criando um fluxo com a ferramenta N8N.



Facens

AQUI TEM ENGENHARIA