



Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br



Séries temporais: modelos clássicos

Cronograma

Modelos Clássicos

- Definição e componentes de séries temporais (Tendência, Sazonalidade e Ruído)
- Estacionariedade e testes (ADF, KPSS).
- Função de Autocorrelação (FAC) e Autocorrelação Parcial (FACP).
- Modelo SARIMA (diferenciação ordinária e sazonal)
- Validação de resíduos (Ruído Branco).
- Exercícios resolvidos.
- Atividade prática


Série temporais

Definição do Objeto de Estudo

Uma **Série Temporal** é um conjunto de dados ordenados no tempo $Y_t = \{y_1, y_2, \dots, y_T\}$, onde $t \in T$ representa o índice temporal contínuo ou discreto. Diferente de amostras independentes e identicamente distribuída do aprendizado de máquina tradicional, a **dependência temporal** (y_t correlacionado com y_{t-k}) é a principal fonte de informação para a modelagem

Série temporais


AirPassengers - Passageiros de Linha Aérea Internacional (1949-1960)



Série temporais

1. Varejo e E-commerce (Demanda de Produtos)


- **Exemplo:** Vendas diárias ou semanais de um supermercado.
- **Padrão:** Apresenta forte sazonalidade semanal (picos nos fins de semana) e sazonalidade anual (picos na Black Friday e Natal).
- **Aplicação:** Gestão de estoque, planejamento de suprimentos e precificação dinâmica.



Série temporais

2 Economia e Finanças

- **Exemplo:** Preços de fechamento de ações na bolsa (ex: PETR4), taxa de câmbio (Dólar/Real) ou inflação mensal (IPCA).
- **Padrão:** Alta volatilidade, comportamentos não-estacionários e alta sensibilidade a eventos externos (ruídos).
- **Aplicação:** Gestão de risco de carteira, detecção de anomalias no mercado e modelos de *trading*.



Série temporais

3. Energia

Exemplo: Consumo de energia elétrica medido a cada 15 minutos em uma cidade.

Padrão: Sazonalidade múltipla (variação ao longo do dia com picos no fim da tarde, variação entre dias úteis vs. fins de semana e variação anual entre verão e inverno).

Aplicação: Despacho de usinas geradoras, prevenção de sobrecargas na rede e otimização de custos operacionais.




Série temporais

4. Clima e Meio Ambiente


Exemplo: Temperatura diária, volume de chuva mensal ou níveis de poluição do ar.

Padrão: Sazonalidade anual clara combinada com tendências de longo prazo (como o aquecimento global).

Aplicação: Previsão do tempo, planejamento agrícola e monitoramento de desastres naturais.



Série temporais



Série temporais

Definição

Uma **Série Temporal** é um conjunto de dados ordenados no tempo $Y_t = \{y_1, y_2, \dots, y_T\}$, onde $t \in T$ representa o índice temporal contínuo ou discreto. Diferente de amostras independentes e identicamente distribuída do aprendizado de máquina tradicional, a **dependência temporal** (y_t correlacionado com y_{t-k}) é a principal fonte de informação para a modelagem

Os Componentes de uma Série Temporal

Pela teoria clássica de decomposição qualquer série temporal Y_t pode ser representada pela combinação de quatro componentes:

$$\text{Modelo Aditivo: } Y_t = T_t + S_t + R_t$$

$$\text{Modelo Multiplicativo: } Y_t = T_t \times S_t \times R_t$$

Série temporais

Sendo:

- **Tendência (T_t)** : A direção de longo prazo da série. Reflete mudanças estruturais subjacentes, como crescimento populacional, evolução tecnológica ou alterações econômicas.
- **Sazonalidade (S_t)**: Padrões periódicos fixos e conhecidos que se repetem em intervalos regulares (diário, semanal, mensal, anual).
- **Resíduo (R_t)**: **Conceito**: A componente aleatória ou estocástica imprevisível. Representa choques exógenos, erros de medição e variações que não podem ser explicadas por tendência, sazonalidade ou ciclo.

Série temporais

**Como criar uma
série temporal em Python?**



Série temporais

Implementando



Série temporais

Voltando as definições



Série temporais

Sendo:

- **Tendência (T_t)** : A direção de longo prazo da série. Reflete mudanças estruturais subjacentes, como crescimento populacional, evolução tecnológica ou alterações econômicas.
- **Sazonalidade (S_t)**: Padrões periódicos fixos e conhecidos que se repetem em intervalos regulares (diário, semanal, mensal, anual).
- **Resíduo (R_t)**: **Conceito**: A componente aleatória ou estocástica imprevisível. Representa choques exógenos, erros de medição e variações que não podem ser explicadas por tendência, sazonalidade ou ciclo.

Série temporais

AirPassengers

O conjunto de dados **AirPassengers** (também conhecido como *International Airline Passengers*) é o *benchmark* clássico para o estudo de séries temporais na literatura de estatística e ciência de dados.



Série temporais

Características do Dataset

- **Período:** Registrado mensalmente de janeiro de 1949 a dezembro de 1960 (12 anos, totalizando 144 observações).
- **Variável:** Número total de passageiros de companhias aéreas internacionais (em milhares).
- **Origem:** Publicado originalmente por Box e Jenkins no livro de 1970 *Time Series Analysis: Forecasting and Control*



Série temporais

Por que é usada como Benchmark?

Esta série é ideal para praticar técnicas fundamentais de séries temporais:

Transformação Logarítmica: Como a sazonalidade é multiplicativa, aplica-se frequentemente a transformação logarítmica ($\log(Y_t)$) para estabilizar a variância e tornar a sazonalidade aditiva.



Série temporais

Por que é usada como Benchmark?


Diferenciação para Estacionariedade: A série não é estacionária (tem tendência e sazonalidade). É necessário aplicar uma diferenciação simples para remover a tendência e uma diferenciação sazonal ($lag = 12$) para remover o padrão anual.

Modelos Típicos de Teste: É o dataset padrão para demonstrar o funcionamento de modelos como **SARIMA** (Seasonal ARIMA), **Decomposição Clássica/STL**, **Holt-Winters** e redes **LSTM**



Série temporais

AirPassengers - Passageiros de Linha Aérea Internacional (1949-1960)




Série temporais

Tendência (T_t)

Conceito: A direção de longo prazo da série. Reflete mudanças estruturais subjacentes, como crescimento populacional, evolução tecnológica ou alterações econômicas.

Exemplo na AirPassengers: O aumento contínuo no número total de passageiros mensais entre 1949 (112 mil) e 1960 (605 mil), impulsionado pela popularização e expansão da aviação comercial após a Segunda Guerra Mundial.




Série temporais

Sazonalidade (S_t)

Conceito: Padrões periódicos fixos e conhecidos que se repetem em intervalos regulares (diário, semanal, mensal, anual).

Exemplo na AirPassengers: Picos consistentes nos meses de **julho e agosto** (férias de verão no Hemisfério Norte) e quedas acentuadas nos meses de **novembro e fevereiro** (baixa temporada de viagens).




Série temporais

Ruído ou Resíduo (R_t)

Conceito: A componente aleatória ou estocástica imprevisível. Representa choques exógenos, erros de medição e variações que não podem ser explicadas por tendência, sazonalidade ou ciclo.

Exemplo na AirPassengers: Variações não explicadas resultantes de eventos atípicos, como intempéries climáticas em determinados meses ou greves pontuais no setor aéreo.



Série temporais

Implementando



Série temporais

Construindo uma série temporal sintética

A abordagem didática mais simples baseia-se no **Modelo Aditivo**, em que a série observada Y_t é a soma direta de três componentes em cada instante de tempo t :

$$Y_t = \text{Tendência}(T_t) + \text{Sazonalidade}(S_t) + \text{Ruído}(R_t)$$

Série temporais

1. **Eixo Temporal (t):** Um índice de tempo ordenado (ex: dias ou meses sequenciais).
2. **Tendência (T_t):** Uma função matemática de longo prazo, geralmente linear ($T_t = a + b \cdot t$).
3. **Sazonalidade (S_t):** Uma função periódica repetitiva, modelada por ondas senoidais ou cosseno diárias, semanais ou anuais: $S_t = A \cdot \sin\left(\frac{2\pi t}{P}\right)$, onde A é a amplitude e P é o período.
4. **Ruído / Erro (R_t):** Choques aleatórios gerados a partir de uma Distribuição Normal com média zero: $R_t \sim \mathcal{N}(0, \sigma^2)$.

Série temporais

Implementando




Série temporais

O Conceito de Normalidade

O conceito de **normalidade** em séries temporais refere-se à propriedade de os dados (ou os erros/resíduos de um modelo) seguirem uma **Distribuição Normal** (também conhecida como Distribuição Gaussiana, a famosa curva em formato de sino).

Embora o termo pareça indicar que a série é "comum" ou "sem anomalias", no contexto estatístico a normalidade traz implicações fundamentais para a **modelagem, inferência estatística e precisão de previsões**.



Série temporais

O Conceito de Normalidade


1. Onde a Normalidade se Aplica numa Série Temporal?

Existem duas formas de analisar a normalidade em uma série temporal:

A. Normalidade da Série (Série em si ou suas Diferenças)

Analisa se os valores observados Y_t (ou a série diferenciada ΔY_t) seguem uma distribuição normal.

Na prática, **difícilmente uma série temporal bruta é normal**, pois costuma apresentar tendência, sazonalidade, agrupamentos de volatilidade (*volatility clustering*) ou assimetrias.



Série temporais


Normalidade dos Resíduos (O Ponto Mais Importante)

Nos modelos de séries temporais (como AR, MA, ARMA, ARIMA, SARIMA), assume-se que o termo de erro (ou resíduo) ϵ_t seja um **Ruído Branco Gaussiano**:

$$\epsilon_t \sim \mathcal{N}(0, \sigma^2)$$

Isso significa que, após o modelo extrair toda a estrutura temporal (tendência, autocorrelação e sazonalidade), o que sobra (o resíduo) deve ser:

- Média igual a zero ($\mu = 0$).
- Variância constante (σ^2).
- Distribuição Normal.




Série temporais

Por que a Normalidade é Importante?

Intervalos de Confiança Válidos:

- A construção dos intervalos de confiança para previsões futuras (ex: a faixa de 95% nas projeções ARIMA) baseia-se na premissa de erro normal.
- Se os resíduos não forem normais, os intervalos de confiança projetados podem ser **estritos demais ou incorretos**, subestimando o risco de eventos extremos.




Série temporais

Como Avaliar a Normalidade?

A avaliação da normalidade combina **testes estatísticos formais** e **diagnósticos visuais**

Diagnósticos Gráficos

- **Histograma com Curva de Densidade:** Permite observar visualmente se os resíduos formam a curva em sino simétrica.




Série temporais

Como Avaliar a Normalidade?

A avaliação da normalidade combina **testes estatísticos formais** e **diagnósticos visuais**


Diagnósticos Gráficos

- **Gráfico Q-Q (Quantil-Quantil Plot):** Plota os quantis dos resíduos contra os quantis teóricos da distribuição normal. Se os pontos estiverem alinhados sobre a linha diagonal de 45°, os resíduos são normais. Desvios nas extremidades indicam "caudas pesadas" ou *outliers*.



Série temporais

Como saber se os dados de uma série temporal se distribuem normalmente?



Série temporais

Teste de Shapiro-Wilk

O **Teste de Shapiro-Wilk** é um dos métodos estatísticos mais robustos e populares para verificar a **hipótese de normalidade** de uma amostra. Ele avalia se um conjunto de dados observados provém de uma população com Distribuição Normal (Gaussiana).

Foi desenvolvido em 1965 pelos estatísticos Samuel Shapiro e Martin Wilk e é amplamente recomendado para amostras de tamanho pequeno a moderado ($N < 2000$).



HYPTOHEISIS TESTING

Série temporais

Teste de Shapiro-Wilk

Hipóteses do Teste

O teste estrutura-se sob duas hipóteses fundamentais:

Hipótese Nula (H_0): Os dados **seguem** uma distribuição normal.

Hipótese Alternativa (H_1): Os dados **NÃO seguem** uma distribuição normal.



HYPTOHESES TESTING

Série temporais

Como Interpretar o p-valor?

A decisão estatística é tomada com base no nível de significância α adotado (geralmente 0,05 ou 5%):

- $p\text{-valor} > 0,05$: **Não rejeitamos** H_0 . Não há evidências estatísticas suficientes para afirmar que os dados desviam da distribuição normal (a suposição de normalidade é aceita).
- $p\text{-valor} \leq 0,05$: **Rejeitamos** H_0 . Existe evidência estatística de que os dados **não** seguem uma distribuição normal (assimetria, caudas pesadas ou presença de *outliers*)



HYPTOHEISIS TESTING

Série temporais

Implementando



Série temporais

O Conceito de Estacionariedade

A **Estacionariedade** é uma das propriedades fundamentais no estudo de séries temporais. O entendimento deste conceito é crucial, pois a maioria dos modelos estatísticos clássicos (como ARMA e ARIMA) assume que a série subjacente é estacionária ou que foi tornada estacionária por meio de diferenciações.

Séries não-estacionárias apresentam tendências de longo prazo ou variâncias que mudam ao longo do tempo, o que pode levar a regressões espúrias.

Série temporais

Matematicamente, uma série temporal Y_t é dita **Estritamente Estacionária** se a sua distribuição de probabilidade conjunta não se altera com o deslocamento no tempo.

Na prática aplicada, utiliza-se o conceito de **Estacionariedade Fraca** (ou de Segunda Ordem), que exige o cumprimento de três condições formais:

- **Média Constante:** $\mathbb{E}[Y_t] = \mu, \quad \forall t$
- **Variância Constante:** $\text{Var}(Y_t) = \sigma^2 < \infty, \quad \forall t$
- **Autocovariância Dependente Apenas do Lag (k):** $\text{Cov}(Y_t, Y_{t-k}) = \gamma_k, \quad \forall t, k$

Série temporais

A **covariância em séries temporais** mede o grau em que duas observações (seja entre duas variáveis diferentes ou entre a própria série em tempos distintos) variam juntas.

Em séries temporais, dividimos o conceito em dois contextos principais: a **Autocovariância** (dentro da própria série) e a **Covariância Cruzada** (entre duas séries diferentes).

Série temporais

Autocovariância (Dentro da própria série)

Refere-se à covariância entre os valores de uma mesma série temporal Y_t no instante de tempo t e no instante de tempo $t - k$ (atrasado por k períodos, chamado de *lag*):

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = \mathbb{E}[(Y_t - \mu_t)(Y_{t-k} - \mu_{t-k})]$$

O que indica:

- $\gamma_k > 0$: Se o valor passado Y_{t-k} estava acima da média, o valor atual Y_t também tende a estar acima da média (relação direta).
- $\gamma_k < 0$: Se o valor passado Y_{t-k} estava acima da média, o valor atual Y_t tende a estar abaixo da média (relação inversa).
- $\gamma_k = 0$: Não há relação linear entre os valores separados pelo intervalo k .

Série temporais

Importância para a Estacionariedade (Estacionariedade em Sentido Fraco)


Para que uma série temporal seja **estacionária em sentido fraco (ou de 2ª ordem)**, a covariância precisa cumprir uma regra estrita:

- A média μ_t e a variância σ_t^2 devem ser constantes ao longo do tempo.
- A **autocovariância** γ_k **deve depender apenas do desfasamento k** e **NÃO** do instante no tempo t .
- **Exemplo:** A covariância entre os meses **de Janeiro e Fevereiro** deve depender apenas do facto de estarem separados por 1 mês ($k = 1$), e ser rigorosamente igual à covariância entre **Julho e Agosto**. Se a covariância mudar dependendo do ano ou do mês analisado, a série não é estacionária

Série temporais


Estacionária: Oscila em torno de um valor central fixo (linha vermelha em 0) com amplitude de variação constante ao longo de todo o período.

Série Temporal Estacionária (Média e Variância Constantes no Tempo)



Série temporais

Não-Estacionária: Apresenta uma clara inclinação ascendente (média muda com o tempo) e ciclos repetitivos de oscilação, exigindo transformações ou diferenciação ($d = 1$) antes da aplicação de modelos de previsão clássicos.



Série temporais

Implementando



Série temporais

Como decidir sobre a estacionaridade ou não de uma série temporal?



Série temporais

Sim, os testes de raiz unitária e de estacionaridade assumem papel imprescindível como ferramentas diagnósticas.



Série temporais

O Teste de Dickey-Fuller Aumentado (ADF)

O teste de Dickey-Fuller Aumentado (ADF) constitui um procedimento estatístico amplamente consolidado na econometria para a verificação da presença de raiz unitária em séries temporais.



HYPTOHEISIS TESTING

Série temporais

O Teste de Dickey-Fuller Aumentado (ADF)

A raiz unitária indica que a série não é estacionária, ou seja, que seus momentos estatísticos — média, variância e covariância — não permanecem constantes ao longo do tempo, caracterizando um processo conhecido como *random walk* (caminhada aleatória).



HYPTOHESES TESTING

Série temporais

O Teste de Dickey-Fuller Aumentado (ADF)

Tal propriedade implica que choques aleatórios sobre a série produzem efeitos permanentes, inviabilizando a previsão de longo prazo e comprometendo a inferência estatística convencional..



HYPTOHESES TESTING

Série temporais

A. Teste de Dickey-Fuller Aumentado (ADF)

- **Objetivo:** Identificar a presença de **Raiz Unitária** na série.
- **Hipótese Nula (H_0):** A série **possui raiz unitária** (não é estacionária).
- **Hipótese Alternativa (H_1):** A série **não possui raiz unitária** (é estacionária).
- **Decisão:** Se $p\text{-valor} < 0,05$, rejeita-se $H_0 \Rightarrow$ A série é Estacionária.



HYPTOHESES TESTING

Série temporais

Interpretação dos resultados

- Se o valor da estatística ADF for inferior (mais negativo) ao valor crítico para um dado nível de significância (usualmente 1%, 5% ou 10%), rejeita-se a hipótese nula, concluindo-se que a série é estacionária.
- Caso contrário, não se rejeita a hipótese nula, sugerindo-se que a série apresenta raiz unitária, sendo necessário recorrer a transformações, como a diferenciação, para torná-la estacionária.



HYPTOHESES TESTING

Série temporais

Implementando



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

O teste KPSS, proposto por Kwiatkowski, Phillips, Schmidt e Shin em 1992, constitui um procedimento estatístico alternativo e complementar aos testes de raiz unitária, como o ADF.



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

Sua principal distinção reside na formulação das hipóteses: enquanto o ADF parte do pressuposto de não estacionaridade como hipótese nula, o KPSS estabelece, como hipótese nula, que a série temporal é estacionária — seja em torno de uma média constante, seja em torno de uma tendência determinística.



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

Tal inversão de perspectiva confere ao KPSS um papel simétrico e indispensável na análise de séries temporais, uma vez que permite confrontar evidências provenientes de diferentes testes e, assim, aumentar a confiabilidade da conclusão.



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

- **Objetivo:** Avaliar se a série é estacionária em torno de um nível ou tendência.
- **Hipótese Nula (H_0):** A série é estacionária.
- **Hipótese Alternativa (H_1):** A série não é estacionária (possui raiz unitária).
- **Decisão:** Se $p\text{-valor} < 0,05$, rejeita-se $H_0 \Rightarrow$ A série é **Não-Estacionária**.



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

- **Objetivo:** Avaliar se a série é estacionária em torno de um nível ou tendência.
- **Hipótese Nula (H_0):** A série é estacionária.
- **Hipótese Alternativa (H_1):** A série não é estacionária (possui raiz unitária).
- **Decisão:** Se $p\text{-valor} < 0,05$, rejeita-se $H_0 \Rightarrow$ A série é **Não-Estacionária**.



Série temporais

B. Teste KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

Interpretação dos resultados

- Se o valor da estatística LM for inferior ao valor crítico, não se rejeita a hipótese nula, concluindo-se que a série é estacionária (em nível ou em torno de uma tendência).
- Se o valor da estatística LM for superior ao valor crítico, rejeita-se a hipótese nula, sugerindo-se que a série apresenta raiz unitária e, portanto, é não estacionária



Série temporais

Matriz de Decisão: Quando Usar Cada Um dos teste anteriores?

Recomenda-se aplicar **ambos os testes simultaneamente** para obter um diagnóstico confirmatório rigoroso:

Série temporais

Resultado do ADF (H_0 : Não Estacionária)	Resultado do KPSS (H_0 : Estacionária)	Conclusão e Diagnóstico
Rejeita $H_0(p < 0,05)$	Não Rejeita $H_0(p \geq 0,05)$	Série Estacionária (Ambos concordam).
Não Rejeita $H_0(p \geq 0,05)$	Rejeita $H_0(p < 0,05)$	Série Não-Estacionária (Ambos concordam — requer diferenciação).
Rejeita $H_0(p < 0,05)$	Rejeita $H_0(p < 0,05)$	Estacionária em Torno da Tendência (Trend-Stationary). A série possui tendência determinística, mas não raiz unitária. Requer remoção de tendência (detrending).
Não Rejeita $H_0(p \geq 0,05)$	Não Rejeita $H_0(p \geq 0,05)$	Inconclusivo / Baixo Poder Estatístico. Ocorre frequentemente em séries curtas ou com ruído elevado.

Série temporais

Implementando



Série temporais

Autocorrelação

A autocorrelação no desfasamento $k(\rho_k)$ é obtida padronizando a **autocovariância** (γ_k) pela variância total da série (γ_0):

$$\rho_k = \frac{\text{Cov}(Y_t, Y_{t-k})}{\text{Var}(Y_t)} = \frac{\gamma_k}{\gamma_0}$$

O resultado é um coeficiente adimensional que varia estritamente entre -1 e $+1$:

$\rho_k \approx +1$ (**Autocorrelação Positiva Forte**): Se o valor no passado estava alto, o valor atual tende a estar alto.

$\rho_k \approx -1$ (**Autocorrelação Negativa Forte**): Se o valor no passado estava alto, o valor atual tende a estar baixo (comportamento oscilatório).


$\rho_k \approx 0$ (**Ausência de Autocorrelação**): Os valores passados não fornecem informação sobre os valores atuais (característica de ruído branco).

Série temporais

Função de Autocorrelação (ACF)

A **ACF** mede a correlação entre a série temporal Y_t e a sua versão atrasada Y_{t-k} (no desfasamento ou *lag* k).


- O efeito "**Cascata**": A ACF inclui a **influência indireta** dos *lags* intermédios. Por exemplo, a autocorrelação no desfasamento $k = 3$ mede a relação de Y_t com Y_{t-3} , mas essa relação carrega o efeito indireto de Y_t passar por Y_{t-1} e Y_{t-2} .



Série temporais


Padrões Típicos na ACF:

- **Série Não Estacionária (com Tendência):** As barras da ACF começam muito altas e decrescem **muito lentamente** ao longo dos *lags*.
- **Sazonalidade:** Apresenta "picos" recorrentes e significativos em intervalos fixos (ex: picos nos *lags* 12, 24, 36 indicam sazonalidade mensal/anual).
- **Processo de Média Móvel — $MA(q)$:** A ACF corta abruptamente (vai para zero) após o *lag* q .



Série temporais

Nota sobre as faixas azuis (Limites de Confiança): A área sombreada (geralmente com 95% de confiança) representa o limiar de significância estatística. Barras que ultrapassam essa faixa azul são estatisticamente **diferentes de zero** (possuem correlação real).




Série temporais

PACF (Função de Autocorrelação Parcial)

A PACF mede a correlação **direta** entre Y_t e Y_{t-k} , **removendo a influência de todos os desfasamentos intermédios** ($Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$).


Isolamento do efeito: Responde à pergunta: *"Existem evidências de que o valor de há 3 dias atrás (Y_{t-3}) afeta diretamente o valor de hoje (Y_t), ignorando o que aconteceu nos dias 1 e 2?"*.



Série temporais

Padrões Típicos na PACF:


- **Processo Autoregressivo** — $AR(p)$: A PACF corta abruptamente (vai para zero) após o *lag* p .
- **Série com Tendência**: Geralmente apresenta um primeiro *lag* próximo de 1.0e os restantes caem vertiginosamente para a zona de insignificância.



Série temporais

Diferença entre Autocorrelação (ACF) e Autocorrelação Parcial (PACF)


- **ACF (Função de Autocorrelação):** Mede a correlação total entre Y_t e Y_{t-k} , **incluindo** os efeitos indiretos de todos os desfasamentos intermédios ($Y_{t-1}, Y_{t-2}, \dots$).



Série temporais

Diferença entre Autocorrelação (ACF) e Autocorrelação Parcial (PACF)

- **PACF (Função de Autocorrelação Parcial):**
Isolada e mede apenas a relação direta entre Y_t e Y_{t-k} , **removendo** a influência dos *lags* intermédios.



Série temporais

Implementando



Série temporais

**Como todo este ferramental
vai nos ajudar no futuro deste
curso?**



Série temporais

Após garantir que a série é **estacionária** (aplicando diferenciações se necessário), utilize o comportamento conjunto de ambos os gráficos para determinar os parâmetros:

Padrão na ACF	Padrão na PACF	Modelo Indicado
Decai exponencialmente ou em onda senoidal	Corta abruptamente após o lag p	$AR(p)$
Corta abruptamente após o lag q	Decai exponencialmente ou em onda senoidal	$MA(q)$
Decai exponencialmente	Decai exponencialmente	$ARMA(p, q)$
Todas as barras dentro da faixa sombreada	Todas as barras dentro da faixa sombreada	Ruído Branco (sem padrão)

Série temporais

Ruído Branco

O **Ruído Branco** (*White Noise*) é o conceito fundamental que representa uma série temporal **puramente aleatória**, sem qualquer estrutura de padrão, tendência, sazonalidade ou memória temporal.

Na modelação



Série temporais

Ruido Branco

Na modelação estatística (como em modelos ARIMA ou LSTMs), o ruído branco representa o **estado ideal para os resíduos (erros de previsão): indica que o modelo conseguiu extrair toda a informação útil dos dados, restando apenas variação aleatória imprevisível.**



Série temporais

Definição Matemática

Uma série temporal ϵ_t é definida como Ruído Branco se cumprir três condições estritas:

- **Média Nula (Constante):** $\mathbb{E}[\epsilon_t] = 0$ para todo o tempo t .
- **Variância Constante (Homocedasticidade):** $\text{Var}(\epsilon_t) = \sigma^2$ para todo o tempo t .
- **Autocovariância Nula:** $\text{Cov}(\epsilon_t, \epsilon_{t-k}) = 0$ para qualquer desfasamento $k \neq 0$.
- **Ruído Branco Gaussiano:** Se, além das três propriedades acima, os dados seguirem uma distribuição normal ($\epsilon_t \sim \mathcal{N}(0, \sigma^2)$), a série é chamada de *Ruído Branco Gaussiano*.

Série temporais

Implementando



Série temporais

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.



Facens

AQUI TEM ENGENHARIA