



# Séries temporais e sistemas de recomendação

Fabio Santiago  
[fabio.santiago@facens.br](mailto:fabio.santiago@facens.br)



---

**Séries temporais: modelos clássicos**

# Cronograma

---

## Nesta aula você irá estudar:

- Decomposição de séries temporais
- Transformação e Diferenciação
- Suavização por Média Móvel (*Moving Average*)

# Série temporais

---

## Decomposição de Séries Temporais

**Conceito:** Consiste em separar a série temporal observada ( $Y_t$ ) nas suas componentes fundamentais não observáveis:

- **Tendência ( $T_t$ ):** A direção de longo prazo da série (crescimento ou declínio).
- **Sazonalidade ( $S_t$ ):** Padrões repetitivos que ocorrem em intervalos fixos (diário, mensal, anual).
- **Resíduo/Ruído ( $R_t$ ):** A componente aleatória e imprevisível que sobra após remover tendência e sazonalidade.

A decomposição pode ser **aditiva** ( $Y_t = T_t + S_t + R_t$ ), usada quando a **variação sazonal é constante**, ou **multiplicativa** ( $Y_t = T_t \times S_t \times R_t$ ), usada quando a amplitude da **sazonalidade cresce proporcionalmente** ao nível da tendência

# Série temporais

---

**Implementando**



# Série temporais

---

## Transformação e Diferenciação

**Conceito:** São técnicas prévias à modelação para tornar a série **estacionária** (média e variância constantes ao longo do tempo), premissa básica da maioria dos modelos clássicos.

- **Transformação (ex: Logarítmica ou Box-Cox):** Estabiliza a **variância** da série ao longo do tempo. Quando as oscilações aumentam de amplitude, o logaritmo achata essas variações.
- **Diferenciação ( $Y_t' = Y_t - Y_{t-1}$ ):** Remove a **tendência** ao subtrair o valor atual pelo valor do período anterior (diferenciação de 1ª ordem). Para remover a sazonalidade, aplica-se a diferenciação sazonal ( $Y_t' = Y_t - Y_{t-m}$ , onde  $m$  é o período sazonal).

# Série temporais

---

**Implementando**



# Série temporais

---

## Suavização por Média Móvel (*Moving Average*)

**Conceito:** É uma técnica de filtragem usada para atenuar o ruído aleatório de alta frequência e evidenciar a tendência subjacente dos dados. Consiste em substituir cada ponto da série pela média dos *janelas* pontos anteriores (ou ao redor).

- **Simple Moving Average (SMA):** Atribui pesos iguais a todas as observações dentro da janela temporal.
- **Efeito da Janela ( $k$ ):** Janelas maiores suavizam mais a série, mas introduzem um atraso (*lag*) na resposta a mudanças reais de direção.

# Série temporais

---

**Implementando**



# Série temporais

---

## **BIBLIOGRAFIA BÁSICA**

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

## **BIBLIOGRAFIA COMPLEMENTAR**

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLIE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.



# Facens

AQUI TEM ENGENHARIA