



Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br



Séries temporais: modelos clássicos

Cronograma

Modelo Prophet



Série temporais

O **Prophet** é um modelo de previsão de séries temporais desenvolvido pelo **Facebook** (Meta) em 2017, projetado para ser **robusto, automático e amigável** para analistas de negócios. Ele foi criado para lidar com séries do mundo real que possuem:

- **Sazonalidades múltiplas** (diária, semanal, anual)
- **Feriados** e eventos especiais
- **Tendências com mudanças** (changepoints)
- **Dados faltantes** e outliers



Série temporais

Estrutura do modelo

O Prophet decompõe a série em três componentes principais:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Onde:

$g(t)$ — **Tendência (*Trend*)**: Modela o crescimento não periódico da série.

- *Linear*: Tendência com crescimento constante.
- *Logística*: Tendência com saturação (capacidade máxima/mínima).



Série temporais

Estrutura do modelo

O Prophet decompõe a série em três componentes principais:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Onde:

$g(t)$ — **Tendência** (*Trend*): Modela o crescimento não periódico da série.

- Inclui **changepoints** (pontos de mudança), permitindo que a tendência altere sua inclinação automaticamente ao longo do tempo.



Série temporais

Estrutura do modelo

O Prophet decompõe a série em três componentes principais:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Onde:

$s(t)$ — **Sazonalidade** (*Seasonality*): Modela mudanças periódicas (diárias, semanais, anuais) usando **Séries de Fourier**.



Série temporais

Estrutura do modelo

O Prophet decompõe a série em três componentes principais:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Onde:

$h(t)$ — **Feriados e Eventos (*Holidays*)**: Incorpora o impacto de dias festivos ou eventos específicos (como a Black Friday) informados pelo usuário.



Série temporais

Estrutura do modelo

O Prophet decompõe a série em três componentes principais:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$



Onde:

ϵ_t — **Erro / Ruído:** Representa a variação aleatória não explicada pelo modelo (assumido como ruído branco).

Série temporais

Vantagens e limitações Prophet



Vantagens

Automático e robusto

Lida bem com dados faltantes

Intervalos de incerteza nativos

Fácil de usar

Suporta feriados e regressores



Limitações

Não captura relações de causa-efeito (a menos com regressores)

Assume sazonalidade fixa (não muda com o tempo)

Menos preciso que SARIMA em séries puramente ARMA


Pode ser lento com muitas séries

Não modela volatilidade

Série temporais

Quando usar Prophet?

- Dados **diários ou semanais** com padrões sazonais complexos
- Presença de **feriados** relevantes
- Séries com **outliers** e gaps
- Quando se quer **rapidez e pouco tuning**
- Previsões de **negócio** (vendas, demanda, acessos)



Série temporais

Implementando



Série temporais

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.



Facens

AQUI TEM ENGENHARIA