




Redes neurais recorrentes

Fabio Santiago
fabio.santiago@facens.br


Redes neurais recorrentes

As **Redes Neurais Recorrentes (RNNs - Recurrent Neural Networks)** são uma classe de redes neurais artificiais projetadas para processar dados sequenciais, onde a ordem dos elementos é importante.



Redes neurais recorrentes

Elas são amplamente utilizadas em tarefas como processamento de linguagem natural (NLP), reconhecimento de fala, previsão de séries temporais e muito mais.



Redes neurais recorrentes

Aplicações das redes neurais recorrentes

- **Texto e Linguagem Natural:** Tradução automática, geração de texto, análise de sentimentos.
- **Caracteres ou palavras** Sequências de tokens para prever a próxima palavra.



Redes neurais recorrentes

Aplicações das redes neurais recorrentes

- **Financeiro:** Preços de ações, criptomoedas ou indicadores econômicos ao longo do tempo.
- **Meteorológico:** Temperatura, umidade ou pressão atmosférica registradas hora a hora.




SUN	MON	TUE	WED	THU	FRI	SAT
						
°C °F	°C °F	°C °F	°C °F	°C °F	°C °F	°C °F
▲ 25 ▼ 19	▲ 27 ▼ 20	▲ 24 ▼ 16	▲ 21 ▼ 15	▲ 22 ▼ 16	▲ 25 ▼ 20	▲ 23 ▼ 18

Redes neurais recorrentes

Conceitos Fundamentais das RNNs


- **Recorrência (Feedback Loop):** A principal característica das RNNs é a **presença de loops**, onde a saída de um passo anterior é realimentada como entrada para o passo atual.



Redes neurais recorrentes

Recorrência(Feedback Loop)

- Isso permite que a rede mantenha uma **memória interna** (estado oculto - *hidden state*) sobre informações passadas na sequência.




Redes neurais recorrentes

O estado oculto (Hidden State)

Representa a "**memória**" da rede em um passo de tempo (**t**).

- Atualizado a cada novo elemento da sequência.
- Calculado com base na entrada atual $x_{(t)}$ e no estado anterior $h_{(t-1)}$



Redes neurais recorrentes


Fórmula básica

$$h_t = f(W_{xh} \cdot x_t + W_{(hh)} \cdot h_{(t-1)} + b_h)$$

$W_{(x,h)}$ $W_{(h,h)}$ Pesos treináveis

$b_{(h)}$ Viés


f Função de ativação



Redes neurais recorrentes

Parâmetros Compartilhados


Os mesmos pesos $W_{(x,h)}$, $W_{(h,h)}$ são reutilizados em cada passo temporal, reduzindo o número total de parâmetros e permitindo generalização para sequências de tamanhos variados.



Redes neurais recorrentes

Parâmetros Compartilhados

- Os **mesmos pesos** são reutilizados em **todos os passos temporais**.
- **Vantagens:** Reduz o número de parâmetros. Permite processar sequências de **comprimento variável**.



Redes neurais recorrentes

Processamento Passo a Passo

Uma RNN desenrolada (**unrolled**) equivale a uma rede profunda com uma camada por passo de tempo:

1. Recebe entrada $x_{(t)}$ e estado oculto $h_{(t-1)}$
2. Calcula novo estado $h_{(t)}$
3. Gera saída y_t :

$$y_t = g(W_{hy} \cdot h_t + b_y)$$


Redes neurais recorrentes

Passo (t)	Entrada (x_t)	Estado Oculto (h_t)
$t = 0$	"O"	$h_0 = \tanh(W_{xh} \cdot "O" + \dots)$
$t = 1$	"gato"	$h_1 = f(W_{xh} \cdot "gato" + W_{hh} \cdot h_0)$
$t = 2$	"pula"	$h_2 = f(W_{xh} \cdot "pula" + W_{hh} \cdot h_1)$

Redes neurais recorrentes

Treinamento: Backpropagation Through Time (BPTT)

- Adaptação do backpropagation para sequências.




Redes neurais recorrentes

Desafio:

Gradientes podem **desaparecer** (*vanishing gradient*) ou **explodir** (*exploding gradient*) em sequências longas.

Soluções comuns:


Uso de **LSTM** ou **GRU** (arquiteturas avançadas que mitigam esses problemas).



Redes neurais recorrentes

Limitações das RNNs Básicas

- **Memória de curto prazo:** Dificuldade em aprender dependências temporais distantes (>10 passos).
- **Ineficiência em sequências longas:** Cálculos sequenciais impedem paralelização






Rede Neural Long Short-Term Memory


Redes neurais LSTM (Long Short-Term Memory)

As LSTMs são uma evolução das RNNs tradicionais, projetadas para resolver o **problema do desaparecimento do gradiente** e capturar **dependências de longo prazo** em sequências. Sua arquitetura é baseada em "células de memória" e "portas" que controlam o fluxo de informações.




[Understanding LSTM and its diagrams | by Shi Yan | ML Review](#)

Redes neurais LSTM (Long Short-Term Memory)



Redes neurais LSTM (Long Short-Term Memory)



[Understanding LSTM and its diagrams | by Shi Yan | ML Review](#)

Redes neurais LSTM (Long Short-Term Memory)

Componentes Chaves da LSTM

Porta	Função	Equação
Porta de Esquecimento (<i>Forget Gate</i>)	Decide quais informações descartar do estado anterior.	$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$
Porta de Entrada (<i>Input Gate</i>)	Decide quais novas informações armazenar na célula de memória.	$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$ $\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$
Porta de Saída (<i>Output Gate</i>)	Decide quais informações enviar para a saída com base no estado atual.	$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$

Redes neurais LSTM (Long Short-Term Memory)

Atualização do Estado da Célula

Célula de Memória: Armazena informações relevantes ao longo do tempo.

$$C_{(t)} = f_{(t)} \odot C_{(t-1)} + i_{(t)} \odot \widetilde{C}_{(t)}$$

$\odot$. Produto do elemento

$\widetilde{C}_{(t)}$ Candidatos de novos valores para célula

Redes neurais LSTM (Long Short-Term Memory)

Atualização do Estado da Célula

Estado oculto $h_{(t)}$

Saída visível da célula, filtrada pela porta de saída:

$$h_{(t)} = o_t \odot \tanh(C_t)$$

Memória de longo prazo: Informações cruciais podem ser mantidas por centenas de passos (ex: em textos longos).

Redes neurais LSTM (Long Short-Term Memory)

Por que LSTMs funcionam?

Controle fino de memória: As portas aprendem **quando lembrar, quando esquecer e quando atualizar** informações.

Proteção contra desaparecimento do gradiente: A atualização aditiva do estado $C_{(t)} = C_{(t)} + \textit{ajuste}$ permite que gradientes fluam sem atenuação.

Redes neurais LSTM (Long Short-Term Memory)

Aplicações Práticas

- **Tradução automática:** Memoriza contexto de frases longas (ex: Google Translate).
- **Geração de legendas para imagens:** Combina CNN (para extrair features) + LSTM (para gerar texto).
- **Previsão de séries temporais:** Captura padrões sazonais em dados financeiros ou climáticos.

Redes neurais LSTM (Long Short-Term Memory)

Comparação com RNNs Tradicionais

Característica	RNN Tradicional	LSTM
Memória de longo prazo	Limitada (curto prazo)	Alta (centenas de passos)
Problema do gradiente	Sofre com vanishing/exploding	Mitigado
Complexidade	Simples	Mais parâmetros (portas)
Custo computacional	Baixo	Moderado/Alto

TensorFlow

O **TensorFlow** é uma biblioteca de código aberto (open-source) desenvolvida pelo **Google Brain Team** para **computação numérica de alto desempenho**, especialmente focada em **aprendizagem de máquina (machine learning)** e **deep learning**.



TensorFlow

Seu nome deriva de "**tensor**" (estrutura de dados multidimensional) e "**flow**" (fluxo de dados através de grafos computacionais).



O que é o TensorFlow?

1. Plataforma Abrangente:

- Fornece ferramentas para construir, treinar, implantar e monitorar modelos de machine learning.
- Suporta desde redes neurais simples até arquiteturas complexas de deep learning.
(CNNs, RNNs, transformers, etc.).



O que é o TensorFlow?

2 Grafos Computacionais:

- Modela cálculos como grafos onde nós representam operações e arestas representam tensores (dados multidimensionais).
- Permite otimizações automáticas e execução paralela.



O que é o TensorFlow?

3 Multiplataforma:

- Funciona em CPUs, GPUs, TPUs (Unidades de Processamento Tensor) e dispositivos móveis (via TensorFlow Lite).
- Suporta Python, C++, JavaScript (TensorFlow.js), Java e até Swift.



TensorFlow e Redes neurais LSTM

Vantagem	Explicação
Eficiência	TensorFlow acelera cálculos matriciais do LSTM usando GPUs/TPUs.
Facilidade de Uso	API do Keras simplifica a criação de redes complexas com poucas linhas.
Escalabilidade	Treina modelos em grandes volumes de dados sequenciais (ex: séries temporais).
Aplicações Práticas	Usado em Siri, Google Translate, previsão de ações, etc.

Aplicação LSTM :Air Passenger

Série Temporal "Air Passengers"

A série temporal "Air Passengers" é um dos conjuntos de dados mais clássicos e amplamente utilizados em análise de séries temporais.



Aplicação LSTM :Air Passenger

Série Temporal "Air Passengers"

Ela representa o número total mensal de passageiros de uma companhia aérea internacional (em milhares) de janeiro de 1949 a dezembro de 1960.





Aplicação LSTM :Air Passenger

Implementando



Aplicação LSTM: Apple Inc. (AAPL) Dataset

Dados históricos de preços (abertura, fechamento, alta, baixa, volume) para diversas ações da Apple Inc.



Aplicação LSTM: Apple Inc. (AAPL) Dataset

Implementando



Referências

- FACELI, K; LORENA, A. C.; GAMA, J.; CARVALHO, A.C.P.L.F. **Inteligência Artificial Uma abordagem de Aprendizado de Máquina**. LTC, 2011
- GOODFELLOW, I; BENGIO, Y.; COURVILLE, A. **Deep Learning**. MIT Press, 2016.
- GULLI, A.; PAL, S. **Deep Learning with Keras**. Packt Publishing, 2017.
- HAYKIN, S. **Neural Networks and Learning Machines** 3. ed. Pearson, 2009.
- HOPE, T.; RESHEFF, Y.; LIEDER, I. **Learning TensorFlow**. O'Reilly, 2017.
- JAMES, G; WITTEN, D.; HASTIE, T; TIBSHIRANI, R. **An Introduction to Statistical Learning**. Springer, 2017.
- MITCHELL, T. M. **Machine Learning**. McGraw-Hill Education, 1997.
- RUSSEL, S.; NORVIG, P. **Inteligência Artificial**. 3. ed. Campus, 2013.



Facens

AQUI TEM ENGENHARIA