

# Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br




# Sistemas de recomendação

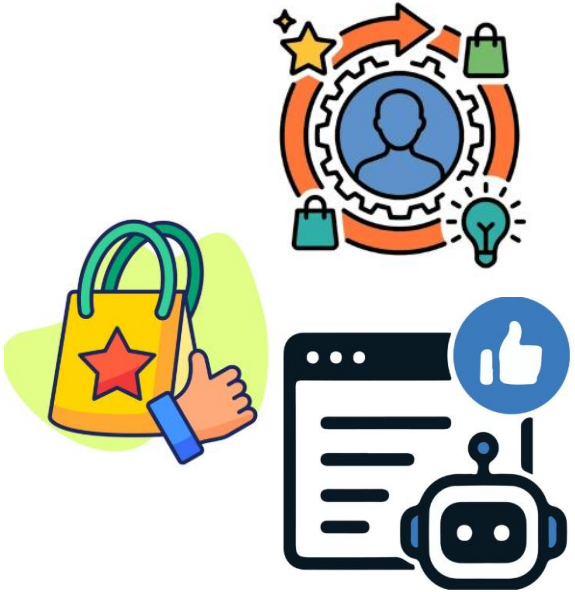
# Cronograma

1. O que é o KNN?
2. A Filosofia do KNN
3. Como funciona na prática
4. Conceitos Fundamentais
5. Papel do K
6. Votação e Ponderação
7. Métricas de Distância
8. Passo a Passo do Algoritmo
9. Cenários ideais
10. Sistemas de Recomendação

# O que é o KNN?

**O que é o KNN?**

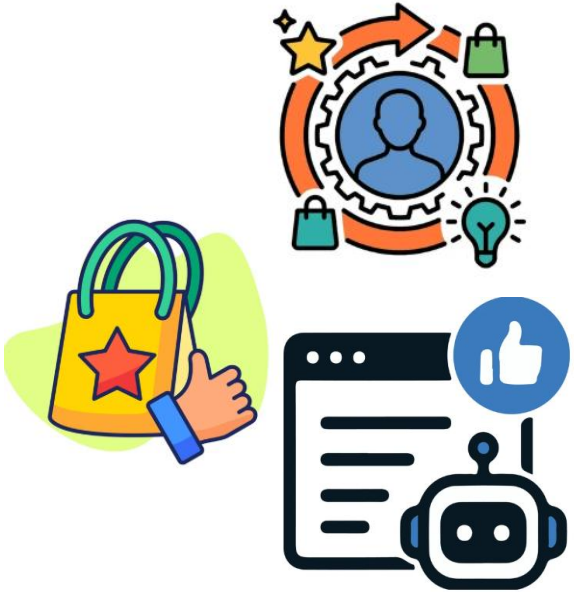
O **K-Nearest Neighbors** (K-Vizinhos Mais Próximos) é um dos algoritmos mais intuitivos e simples do aprendizado de máquina. Ele é um algoritmo de aprendizado **supervisionado** e **baseado em instâncias** (lazy learning), o que significa que ele **não constrói um modelo explícito** durante o treinamento. Em vez disso, ele "memoriza" todos os dados de treino e só faz o trabalho pesado no momento da previsão.



# A Filosofia do KNN

## A Filosofia do KNN

**"Diga-me com quem andas, que eu te direi quem és."**

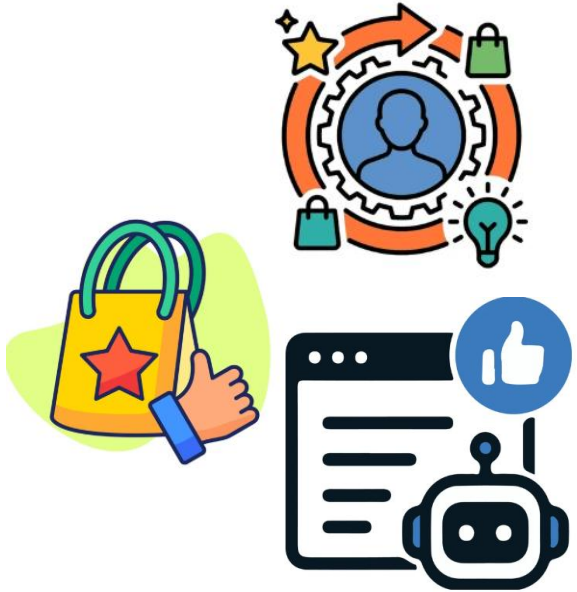


Essa frase resume perfeitamente o KNN. A premissa central é que **pontos de dados com características semelhantes tendem a pertencer à mesma classe** (ou ter valores próximos, no caso de regressão).

# Como funciona na prática

## Como funciona na prática

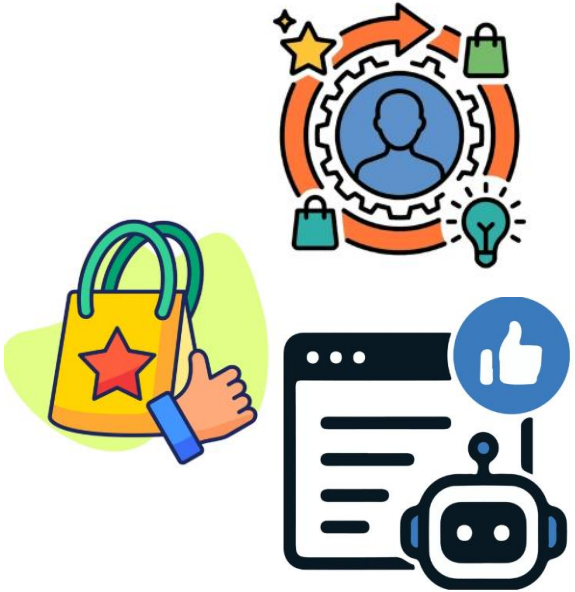
Imagine que você tem um conjunto de dados com frutas classificadas como "Maçã" ou "Laranja", baseado em duas características: **peso** e **diâmetro**. Agora, surge uma fruta nova, sem rótulo, e você precisa classificá-la.



# Como funciona na prática

O KNN faz o seguinte:

1. **Calcula a distância** entre a nova fruta e todas as frutas do conjunto de treino.
2. **Seleciona os K vizinhos mais próximos** (os K pontos com menor distância).
3. **Vota**: a classe mais frequente entre esses K vizinhos é a classe predita para a nova fruta.



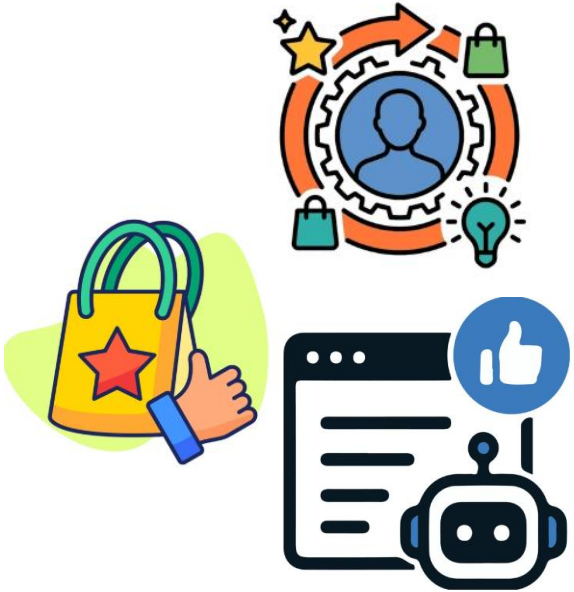
# Conceitos Fundamentais

**Conceitos Fundamentais**

**Aprendizado Lazy (Preguiçoso)**

Diferente de algoritmos como Regressão Logística ou SVM, que aprendem uma função de decisão durante o treino, o KNN:

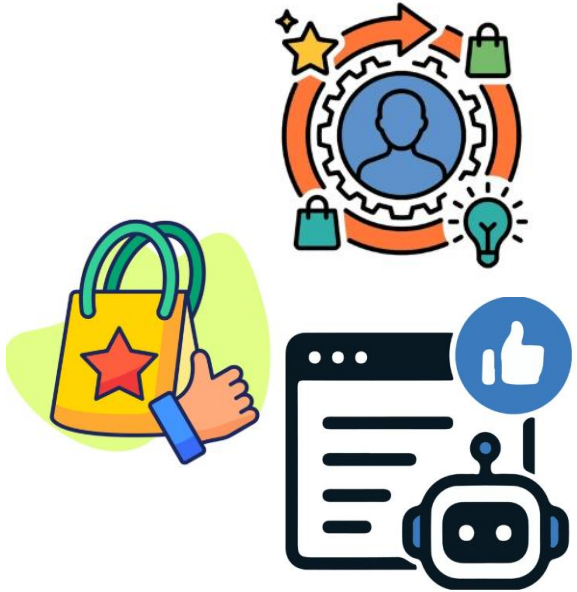
- **Fase de treino**: praticamente inexistente (apenas armazena os dados).
- **Fase de predição**: computacionalmente custosa (calcula distâncias para todos os pontos).



# Conceitos Fundamentais

**Conceitos Fundamentais**

**Consequência prática**: KNN é ruim para bases de dados gigantescas, pois cada predição exige varredura completa do conjunto de treino.

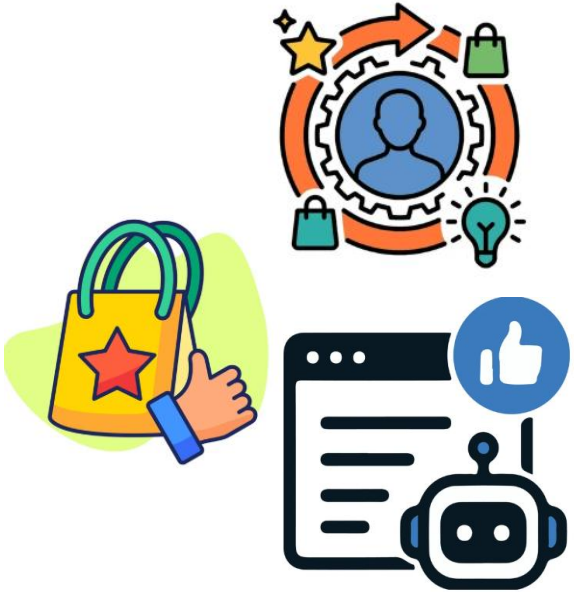


# Conceitos Fundamentais

**Papel do K**

O parâmetro **K** é o número de vizinhos consultados. Ele é crítico:

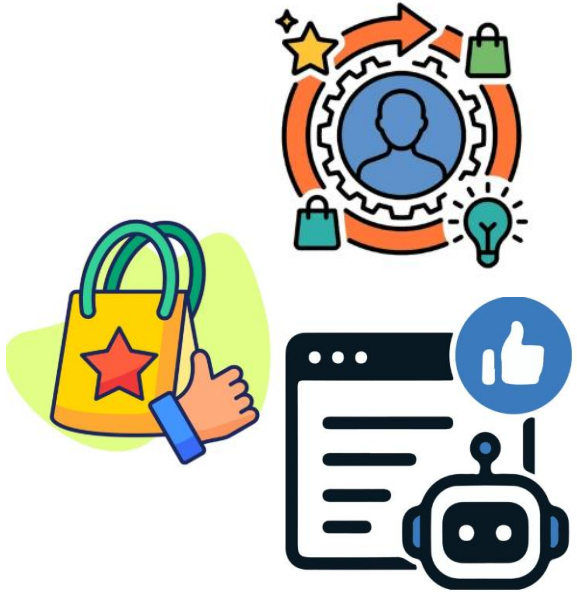
- **K = 1**: o modelo se ajusta demais aos dados (overfitting). Qualquer ruído é capturado. A fronteira de decisão é extremamente irregular.
- **K muito grande**: o modelo se torna excessivamente genérico (underfitting). Ele ignora padrões locais e tende a prever sempre a classe majoritária.
- **K ímpar**: em problemas binários, evita empates na votação.



# Sistemas de recomendação

**Votação e Ponderação**

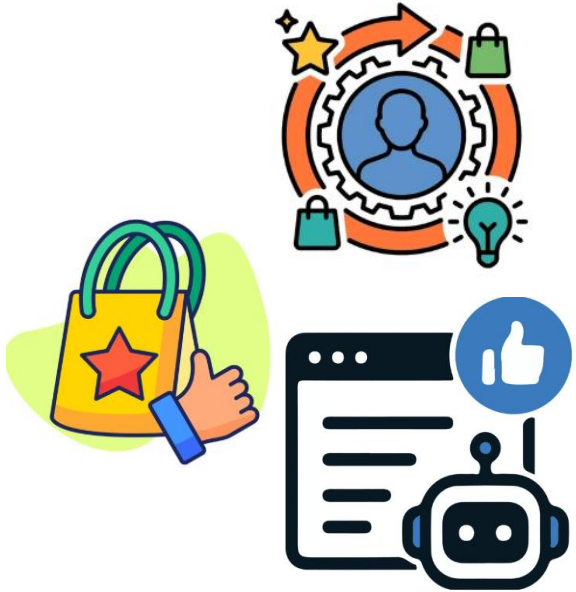
- **Votação majoritária simples**: cada vizinho vale 1 voto.
- **Votação ponderada pela distância**: vizinhos mais próximos têm peso maior. Isso é útil quando K é grande e vizinhos distantes não deveriam ter o mesmo peso dos próximos.



# Métricas de Distância

**Métricas de Distância**

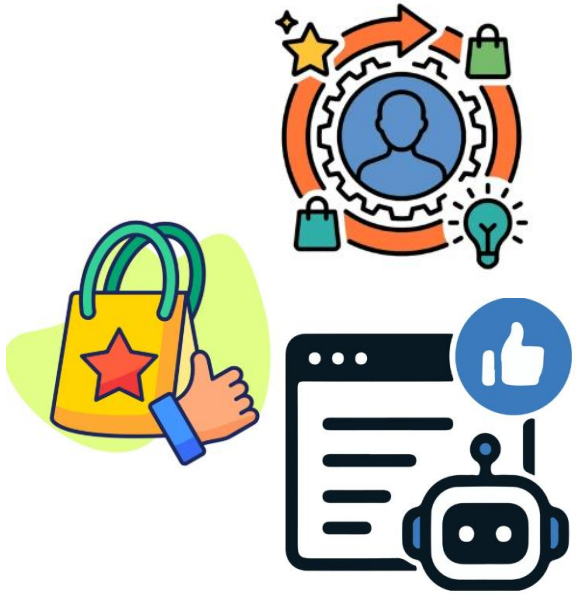
A escolha da métrica de distância é **crucial** no KNN. Ela define o que significa "estar próximo".



# Métricas de Distância

**Distância Euclidiana (mais comum)**

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

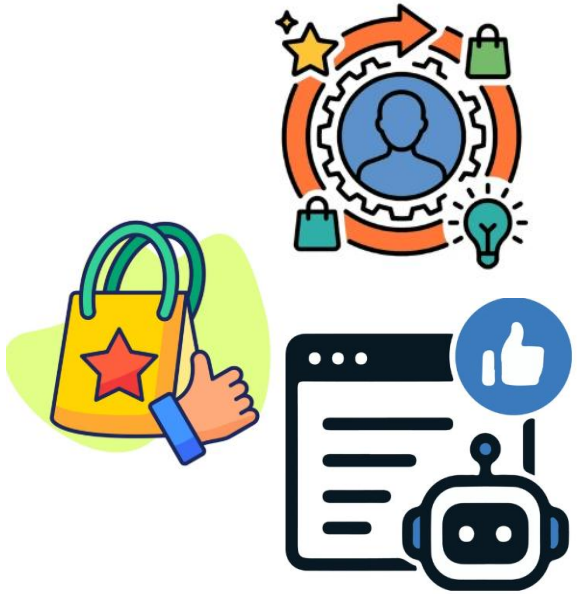


- **Uso**: dados contínuos, sem relação de dependência entre atributos.
- **Cuidado**: extremamente sensível à escala das variáveis.

# Métricas de Distância

**Distância Euclidiana (mais comum)**

$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

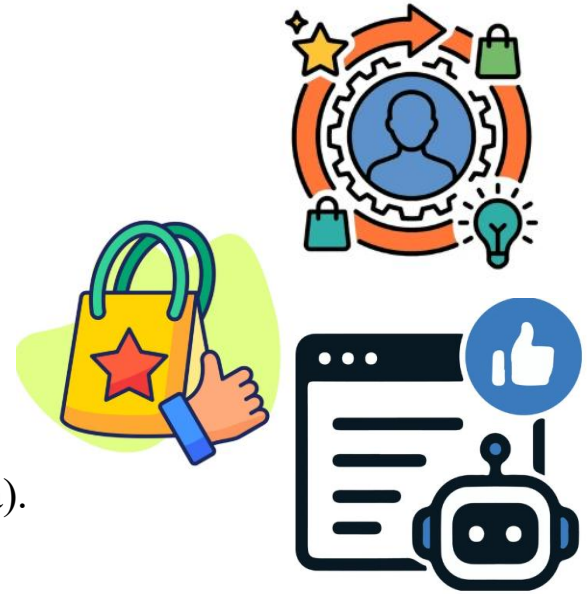


- **Uso**: dados contínuos, sem relação de dependência entre atributos.
- **Cuidado**: extremamente sensível à escala das variáveis.

# Métricas de Distância

**Distância Manhattan (City Block)**

$$d(x, y) = \sum_{i=1}^{n} | x_i - y_i |$$



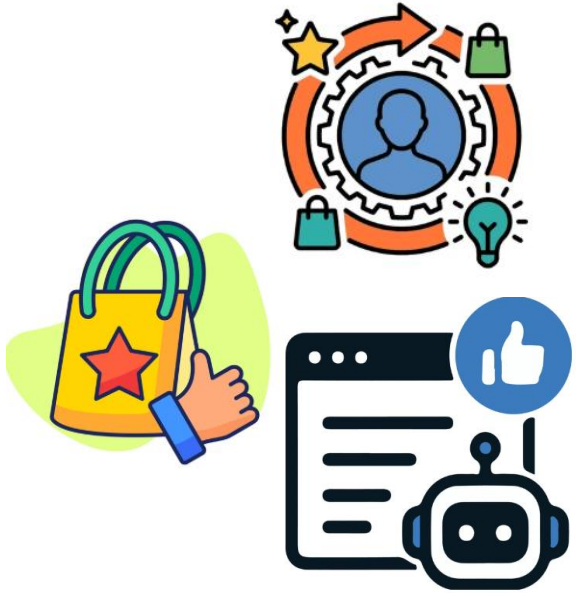
- **Uso**: quando o deslocamento não é "em linha reta" (ex: grade urbana).
- **Vantagem**: mais robusta a outliers que a Euclidiana.

# Métricas de Distância

**Distância de Minkowski**

Generalização das duas anteriores:

$$d(x,y) = \left( \sum_{i=1}^{n} | x_i - y_i |^p \right)^{1/p}$$

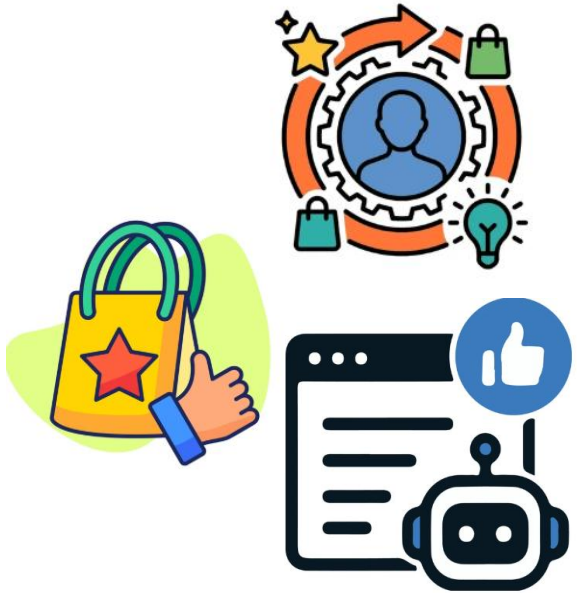


- **p = 1** → Manhattan
- **p = 2** → Euclidiana
- **p** → ∞ → Chebyshev (diferença máxima em qualquer dimensão)

# Métricas de Distância

**Similaridade de Cosseno (não é distância, mas usado)**

$$\text{sim}(x, y) = \frac{x \cdot y}{||\ x\ ||\cdot||\ y\ ||}$$

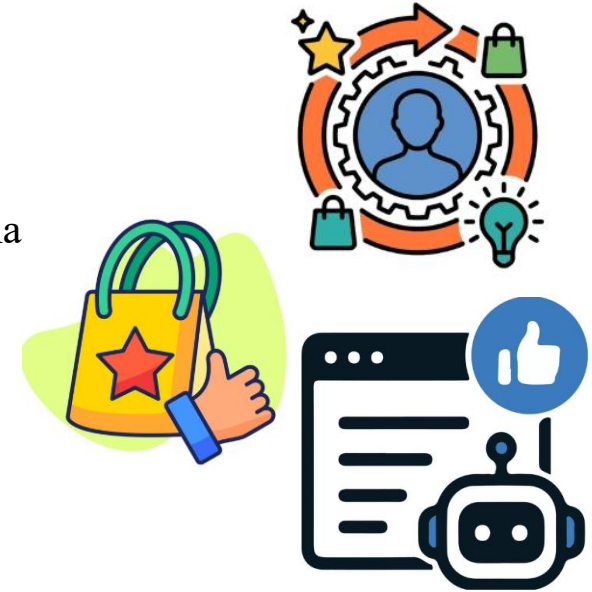


- **Uso**: texto, recomendação, dados de alta dimensionalidade.
- **Vantagem**: ignora magnitude, foca na direção.

# Normalização

**Normalização é obrigatória**

Se uma variável varia de 0 a 1 e outra de 0 a 1000, a segunda domina distância.



**Sempre** aplique:

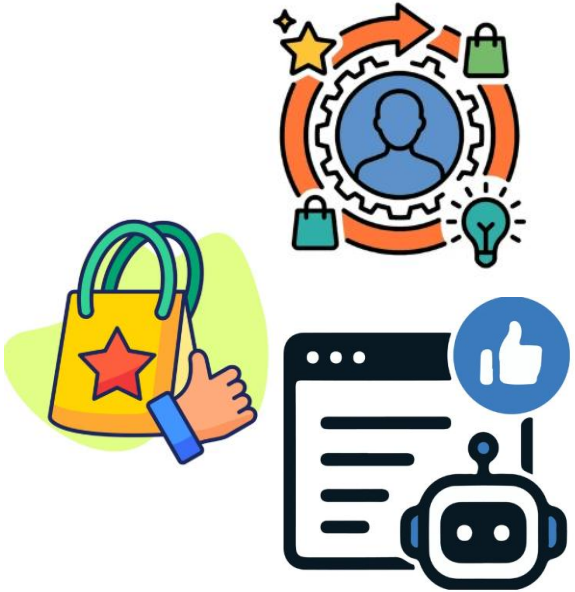
- **Min-Max**: $(x - min)/(max - min)$
- **Z-score**: $(x - \mu)/\sigma$

# Passo a Passo do Algoritmo

**Passo a Passo do Algoritmo**

**Fase de Treino**

- Armazenar todos os pontos de treino com seus rótulos.

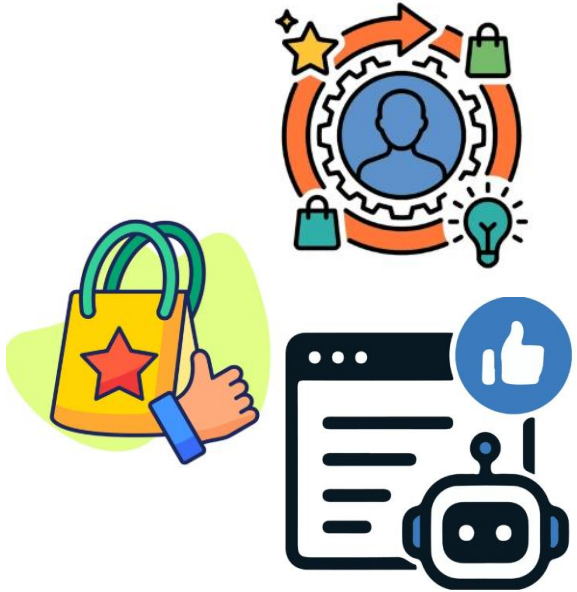


# Passo a Passo do Algoritmo

**Passo a Passo do Algoritmo**

**Fase de Predição (para um novo ponto x)**

- Calcular a distância de x a **todos** os pontos de treino.
- Ordenar as distâncias em ordem crescente.
- Selecionar os **K** pontos com menores distâncias.
- Para classificação: **votação majoritária** entre os rótulos desses K pontos.
- Para regressão: **média** (ou média ponderada) dos valores desses K pontos.



# Cenários

## Cenários ideais

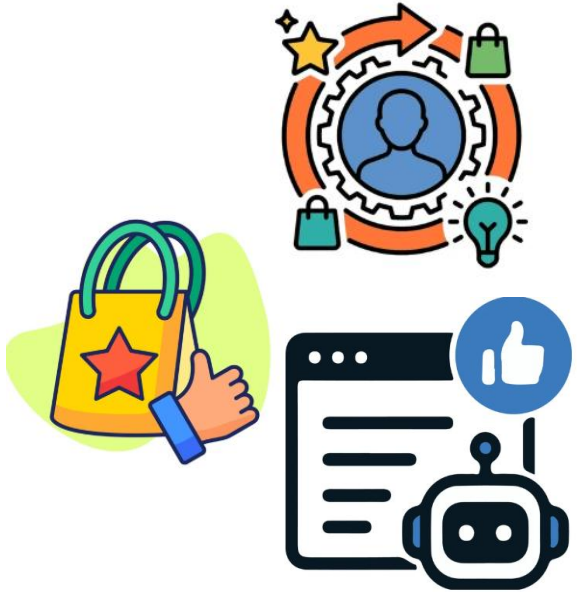
| Situação | Por quê |
|---|---|
| Bases pequenas ou médias | O custo de predição é aceitável |
| Fronteiras de decisão irregulares | KNN não assume forma específica |
| Dados com muitos rótulos (multiclasse) | Funciona naturalmente |
| Prototipagem rápida | Fácil de implementar e entender |
| Recomendação | "Usuários parecidos gostaram de..." |



# Sistemas de recomendação

**Sistemas de Recomendação**

- **Filtragem colaborativa item-based**: "Filmes parecidos com este".
- **User-based**: "Usuários parecidos com você gostaram de...".



# Implementando

Implementando .....



# Sistemas de recomendação


**BIBLIOGRAFIA BÁSICA**

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

**BIBLIOGRAFIA COMPLEMENTAR**

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.


Facens
AQUI TEM ENGENHARIA