

Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br



Sistemas de recomendação

Cronograma

- Definição
- Interpretação geométrica
- Auto valores e valores sigulares
- Teorema de Eckart-Young
- Aplicações
- Exemplo

Decomposição SVD

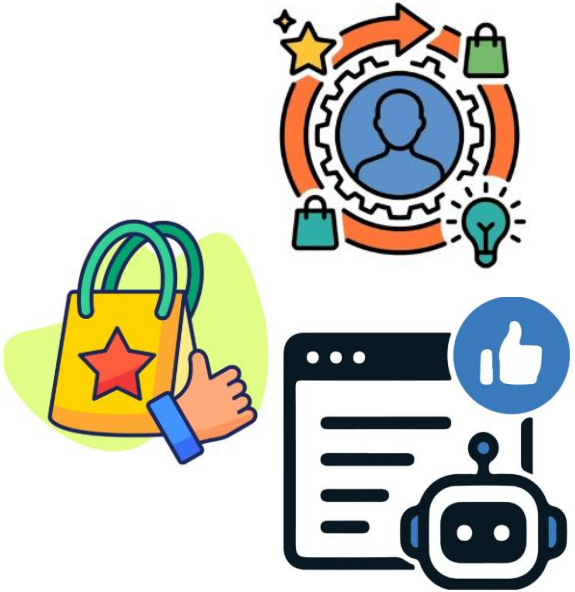
Definição

Para qualquer matriz Ade dimensões $m \times n$, a SVD a fatora como:

$$A = U\Sigma V^T$$

Onde:

- $\boldsymbol{U}$**:** matriz ortogonal $m \times m$(colunas ortonormais). Suas colunas são chamadas de **vetores singulares à esquerda**.
- $\boldsymbol{\Sigma}$: matriz diagonal $m \times n$contendo os **valores singulares** $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$, onde $r = \text{rank}(A)$.
- $\boldsymbol{V}$**:** matriz ortogonal $n \times n$(colunas ortonormais). Suas colunas são chamadas de **vetores singulares à direita**.

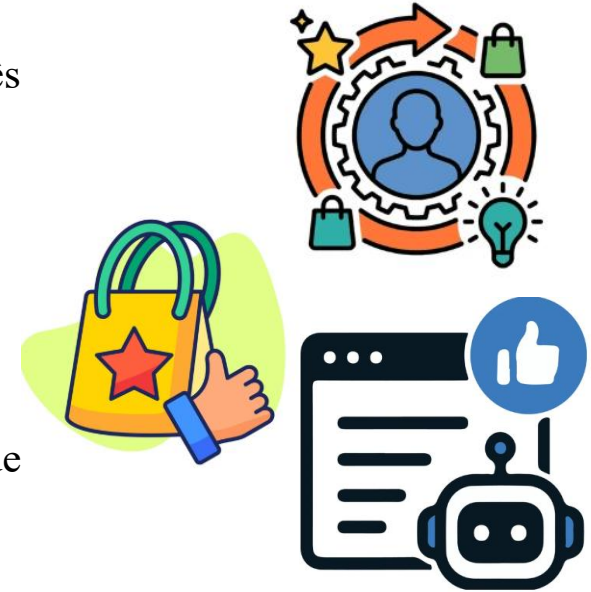


Interpretação geométrica

A SVD diz que **toda transformação linear** pode ser vista como três operações simples em sequência:

1. **Rotação/reflexão** (multiplicação por V^T)
2. **Escala** ao longo dos eixos (multiplicação por Σ)
3. **Outra rotação/reflexão** (multiplicação por U)

Ou seja, mesmo que uma matriz pareça "bagunçada", ela sempre pode ser decomposta em rotação → alongamento → rotação

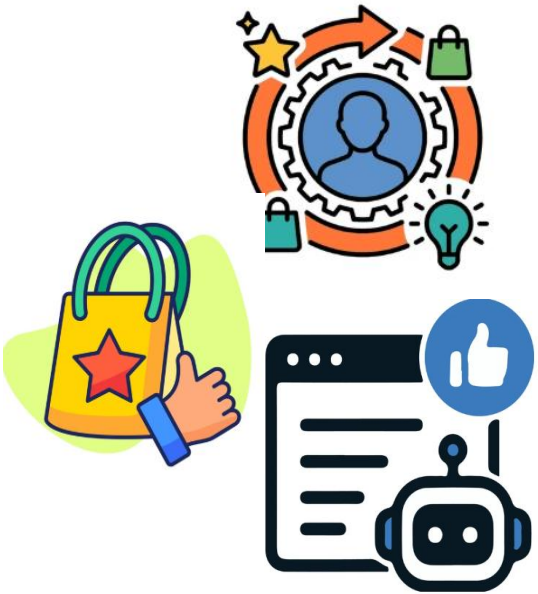


Autovalores e valores singulares

Os valores singulares de Asão as raízes quadradas dos autovalores de $A^T A$(ou de AA^T):

$$\sigma_i = \sqrt{\lambda_i(A^T A)}$$

Os vetores singulares à direita (V) são os autovetores de $A^T A$, e os vetores singulares à esquerda (U) são os autovetores de AA^T

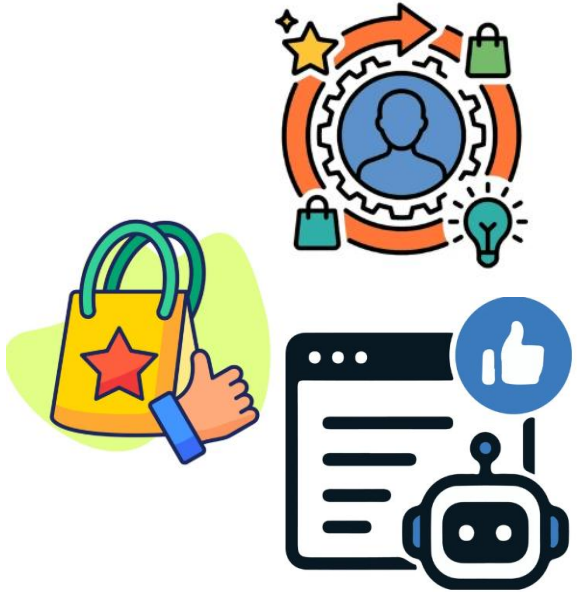


Teorema de Eckart–Young

Se mantivermos apenas os k maiores valores singulares:

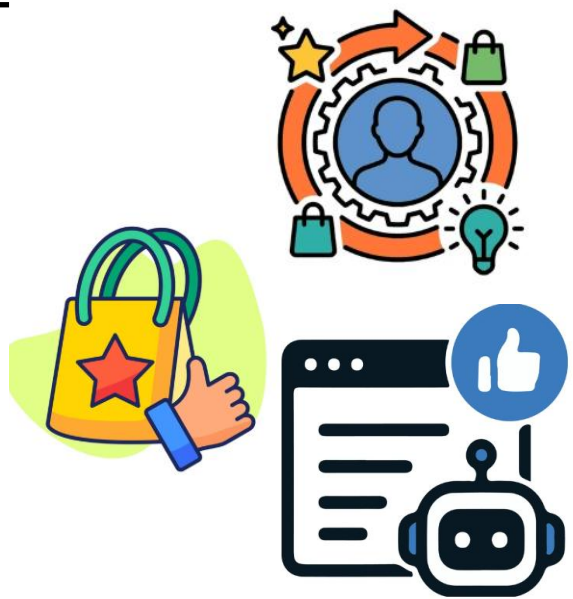
$$A_k = U_k \Sigma_k V_k^T$$

então A_k é a **melhor aproximação de posto** k de A (na norma de Frobenius e na norma espectral). Isso é a base da compressão de dados via SVD.



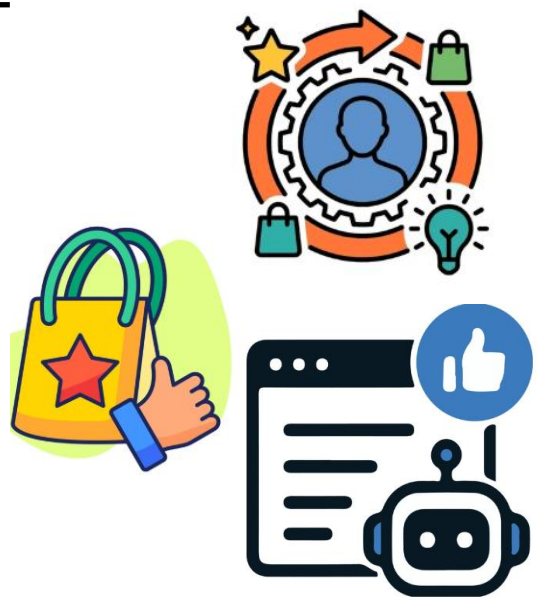
Aplicações

Área	Aplicação
Compressão de imagens	Manter apenas os k maiores valores singulares (aproximação de baixo posto)
Redução de dimensionalidade	PCA (Análise de Componentes Principais) é essencialmente SVD de dados centralizados



Aplicações

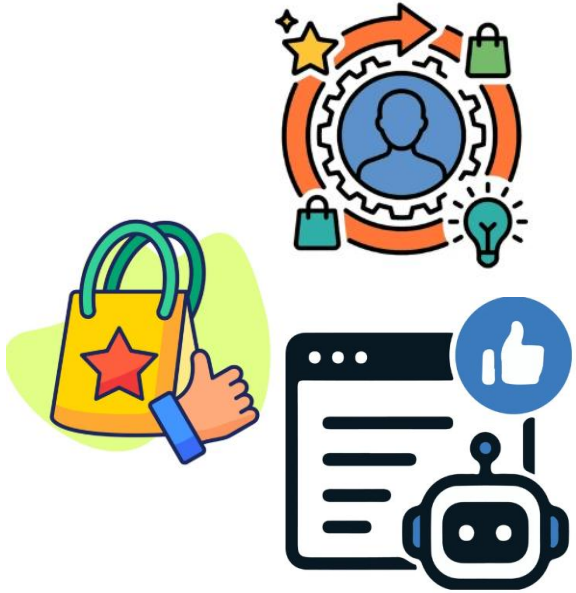
Área	Aplicação
Sistemas de recomendação	Fatoração de matrizes de avaliações (ex.: Netflix Prize)
Processamento de linguagem	LSA (Latent Semantic Analysis)
Solução de mínimos quadrados	Pseudoinversa de Moore-Penrose: $A^{+} = V\Sigma^{+}U^{T}$
Ruído e filtragem	Descarte de valores singulares pequenos associados a ruído



Decomposição SVD passo a passo

Considere a matriz

$$A^T = \begin{bmatrix} 3 & -1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$



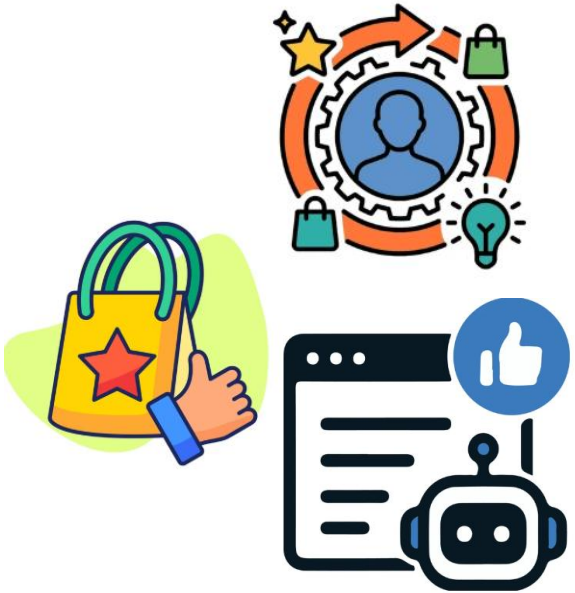
Agora multiplicamos $A^T A$:

$$A^T A = \begin{bmatrix} 3 & -1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix} \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix}$$

Decomposição SVD passo a passo

Calculando cada entrada:

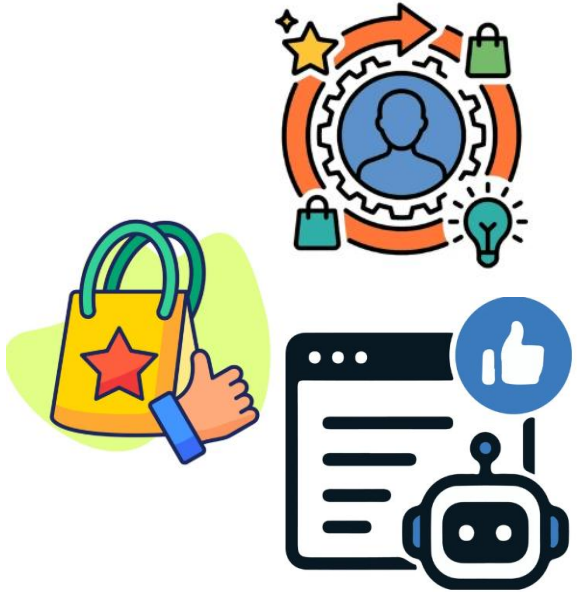
- $(1,1) : 3 \cdot 3 + (-1)(-1) + 1 \cdot 1 = 9 + 1 + 1 = 11$
- $(1,2) : 3 \cdot 1 + (-1)(3) + 1 \cdot 1 = 3 - 3 + 1 = 1$
- $(1,3) : 3 \cdot 1 + (-1)(1) + 1 \cdot 3 = 3 - 1 + 3 = 5$
- $(2,1) : 1 \cdot 3 + 3(-1) + 1 \cdot 1 = 3 - 3 + 1 = 1$
- $(2,2) : 1 \cdot 1 + 3 \cdot 3 + 1 \cdot 1 = 1 + 9 + 1 = 11$
- $(2,3) : 1 \cdot 1 + 3 \cdot 1 + 1 \cdot 3 = 1 + 3 + 3 = 7$
- $(3,1) : 1 \cdot 3 + 1(-1) + 3 \cdot 1 = 3 - 1 + 3 = 5$
- $(3,2) : 1 \cdot 1 + 1 \cdot 3 + 3 \cdot 1 = 1 + 3 + 3 = 7$
- $(3,3) : 1 \cdot 1 + 1 \cdot 1 + 3 \cdot 3 = 1 + 1 + 9 = 11$



Decomposição SVD passo a passo

Portanto

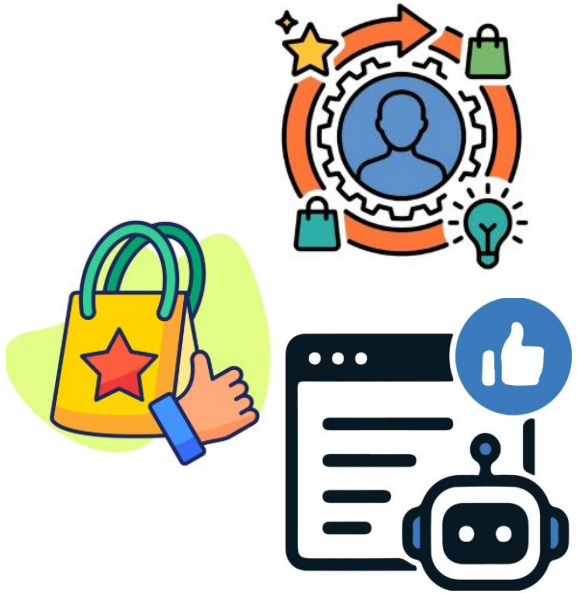
$$A^T A = \begin{bmatrix} 11 & 1 & 5 \\ 1 & 11 & 7 \\ 5 & 7 & 11 \end{bmatrix}$$



Decomposição SVD passo a passo

A fim de encontrar os autovalores de $A^T A$, devemos calcular $\det(A^T A - \lambda I) = 0$

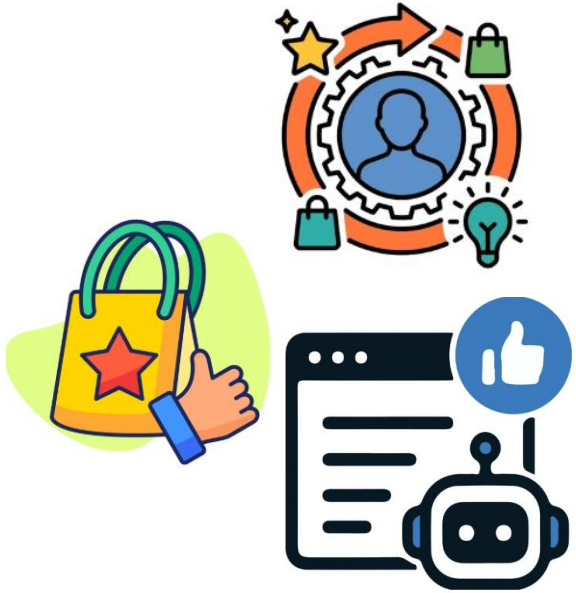
$$\begin{vmatrix} 11-\lambda & 1 & 5 \\ 1 & 11-\lambda & 7 \\ 5 & 7 & 11-\lambda \end{vmatrix} = 0$$



Decomposição SVD passo a passo

Expandindo o determinante , se obtém o seguinte polinômio característico

$$-\lambda^3 + 33\lambda^2 - 336\lambda + 1024 = 0$$



Cujas raízes são:

$$\lambda_1 = 16, \quad \lambda_2 = \frac{17 + \sqrt{33}}{2} \approx 11{,}372, \quad \lambda_3 = \frac{17 - \sqrt{33}}{2} \approx 5{,}628$$

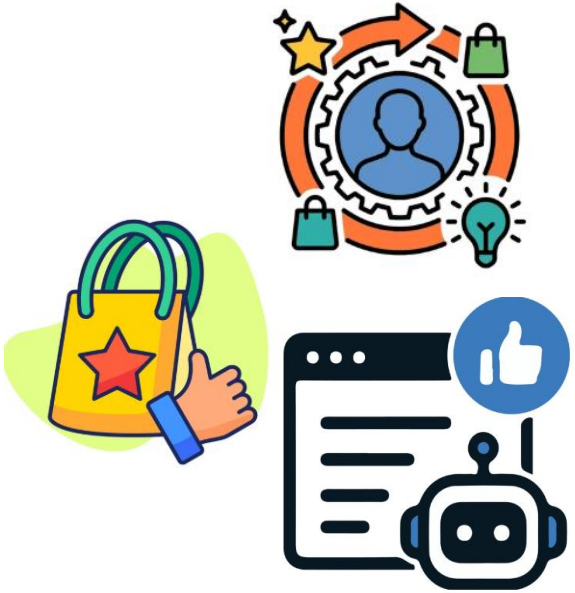
Decomposição SVD passo a passo

Obtenção dos valores singulares$\sigma_i = \sqrt{\lambda_i}$

$$\sigma_1 = \sqrt{16} = 4$$

$$\sigma_2 = \sqrt{\frac{17 + \sqrt{33}}{2}} \approx \sqrt{11{,}372} \approx 3{,}372$$

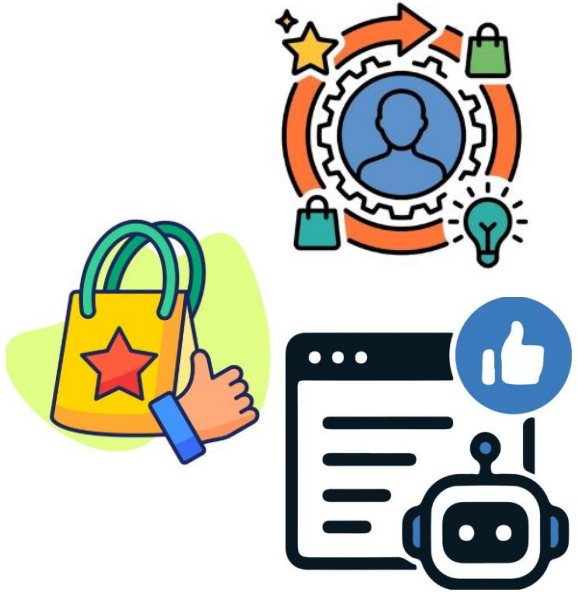
$$\sigma_3 = \sqrt{\frac{17 - \sqrt{33}}{2}} \approx \sqrt{5{,}628} \approx 2{,}372$$



Decomposição SVD passo a passo

Portanto,

$$\Sigma = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 3{,}372 & 0 \\ 0 & 0 & 2{,}372 \end{bmatrix}$$



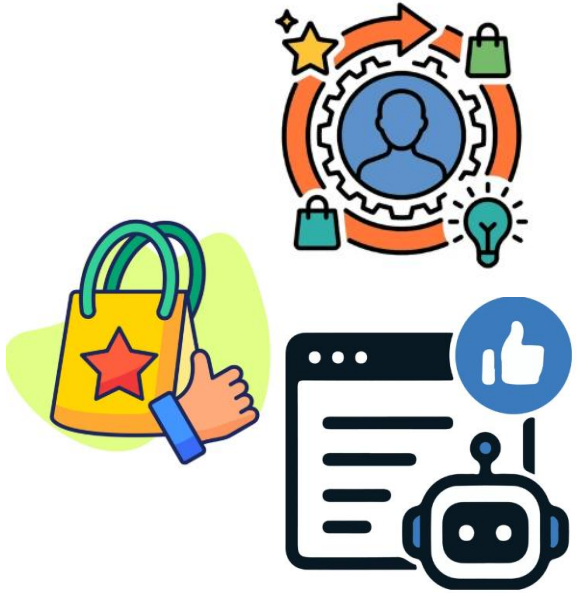
Decomposição SVD passo a passo

Autovetores de $A^T A$, a fim de se obter a matriz V

- Para $\lambda_1 = 16$, tem-se:

$$(A^T A - 16I)v = 0$$

$$\begin{bmatrix} -5 & 1 & 5 \\ 1 & -5 & 7 \\ 5 & 7 & -5 \end{bmatrix} v = 0$$



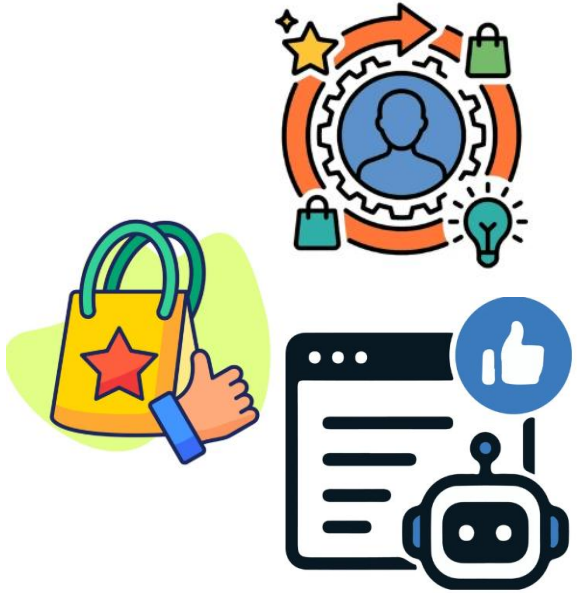
Decomposição SVD passo a passo

Autovetores de $A^T A$, a fim de se obter a matriz V

- Para $\lambda_1 = 16$, tem-se:

$$(A^T A - 16I)v = 0$$

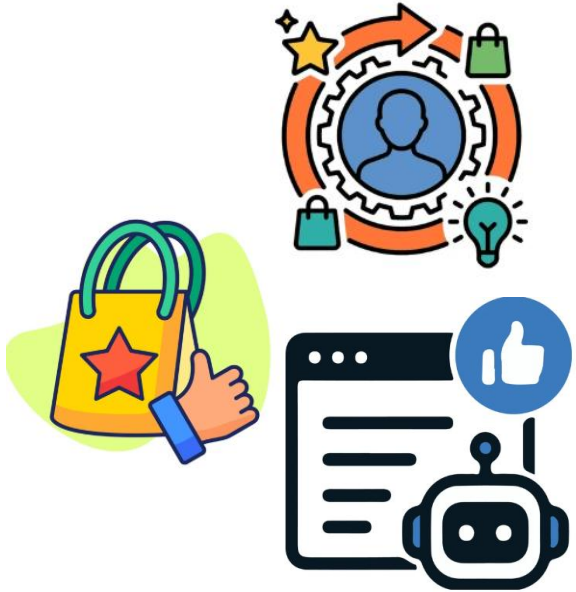
$$\begin{bmatrix} -5 & 1 & 5 \\ 1 & -5 & 7 \\ 5 & 7 & -5 \end{bmatrix} v = 0$$



Decomposição SVD passo a passo

Resolvendo o sistema linear anterior, tem-se:

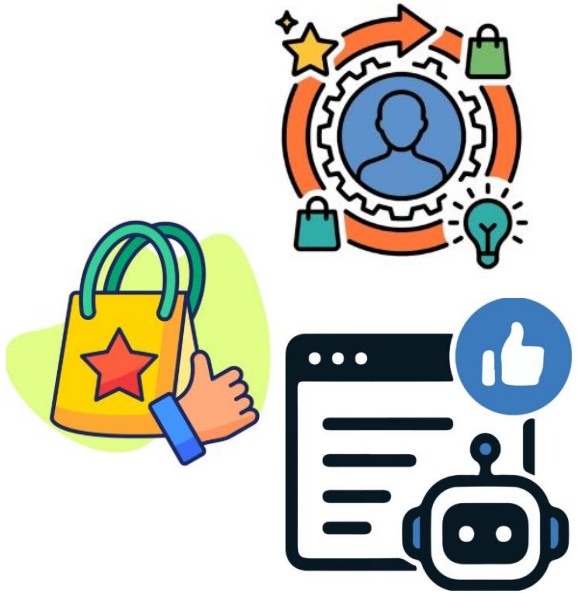
$$v_1 = \frac{1}{5\sqrt{2}}(4, 5, 3) \approx (0{,}566;\ 0{,}707;\ 0{,}424)$$



Decomposição SVD passo a passo

Para $\lambda_2 = \frac{17+\sqrt{33}}{2}$:

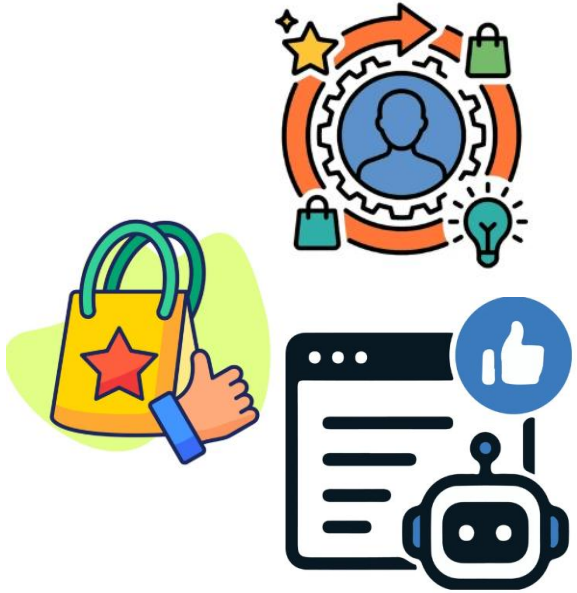
$$v_2 \approx (0{,}707;\ -0{,}000;\ -0{,}707)$$



Decomposição SVD passo a passo

Para $\lambda_3 = \frac{17-\sqrt{33}}{2}$:

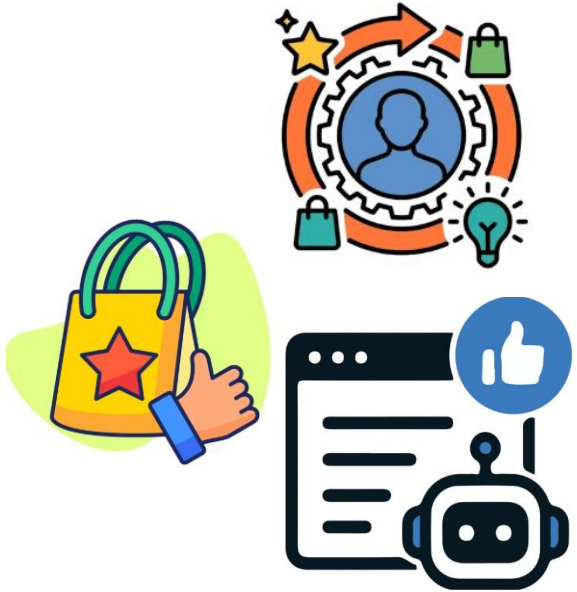
$$v_3 \approx (0{,}424;\ -0{,}707;\ 0{,}566)$$



Decomposição SVD passo a passo

Portanto

$$V \approx \begin{bmatrix} 0{,}566 & 0{,}707 & 0{,}424 \\ 0{,}707 & 0 & -0{,}707 \\ 0{,}424 & -0{,}707 & 0{,}566 \end{bmatrix}$$

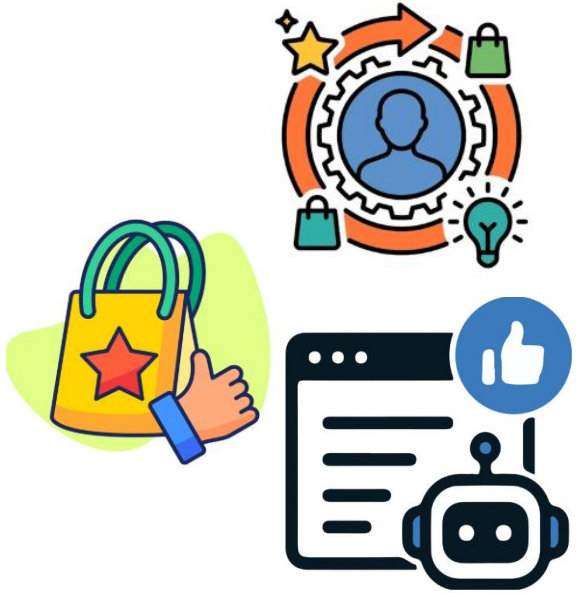


Decomposição SVD passo a passo

Obtenção dos vetores singulares aa esquerda, matriz U.

Seja $u_i = \frac{1}{\sigma_i} A\, v_i$, então para $\boldsymbol{i = 1}$, tem-se:

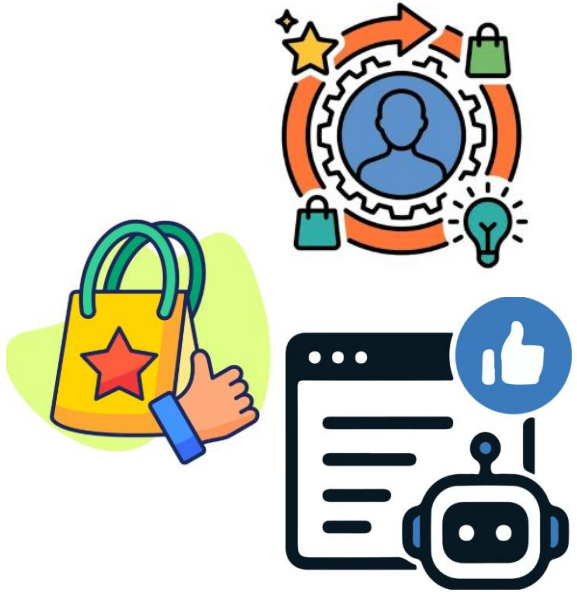
$$Av_1 = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix} \frac{1}{5\sqrt{2}} \begin{bmatrix} 4 \\ 5 \\ 3 \end{bmatrix}$$



Decomposição SVD passo a passo

Obtenção dos vetores singulares aa esquerda, matriz U.

Seja $u_i = \frac{1}{\sigma_i} A\, v_i$, então para $\boldsymbol{i = 1}$, tem-se:



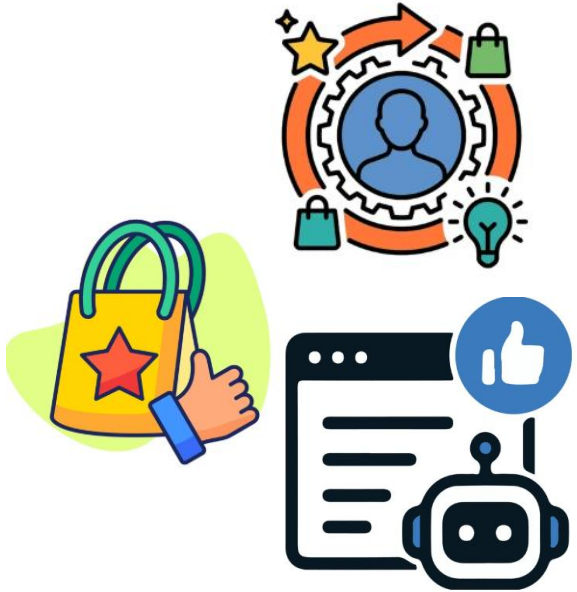
$$Av_1 = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix} \frac{1}{5\sqrt{2}} \begin{bmatrix} 4 \\ 5 \\ 3 \end{bmatrix}$$

$$Av_1 = \frac{1}{5\sqrt{2}}(20, 14, 18).$$

Decomposição SVD passo a passo

Dividindo por $\sigma_1 = 4$.

$$u_1 = \frac{1}{20\sqrt{2}}(20, 14, 18) = \frac{1}{10\sqrt{2}}(10, 7, 9)$$

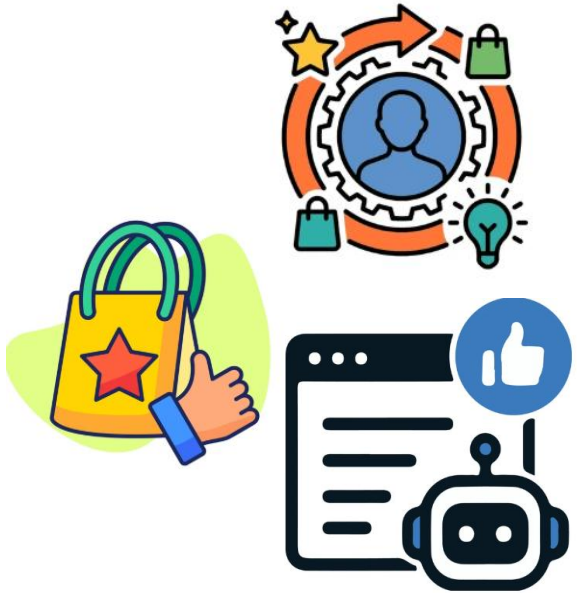


Decomposição SVD passo a passo

Analogamente para $i = 2$ e $i = 3$, tem-se:

$$u_2 \approx (0{,}707;\ -0{,}495;\ -0{,}636)$$

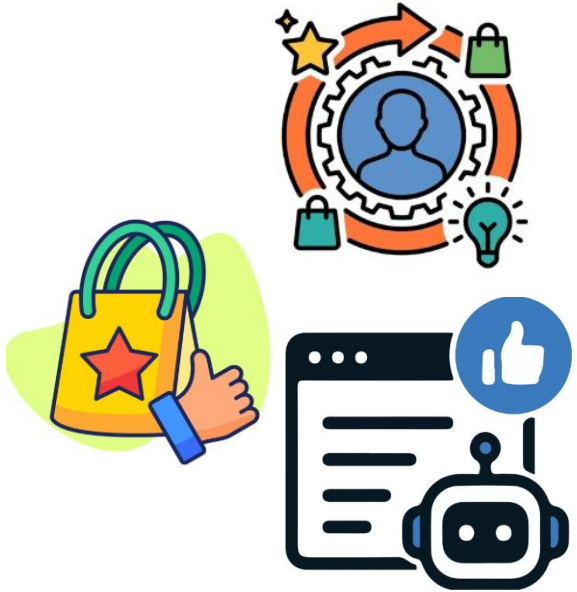
$$u_3 \approx (0;\ 0{,}707;\ -0{,}707)$$



Decomposição SVD passo a passo

Portanto,

$$U \approx \begin{bmatrix} 0{,}707 & 0{,}707 & 0 \\ 0{,}495 & -0{,}495 & 0{,}707 \\ 0{,}636 & -0{,}636 & -0{,}707 \end{bmatrix}$$



Decomposição SVD passo a passo

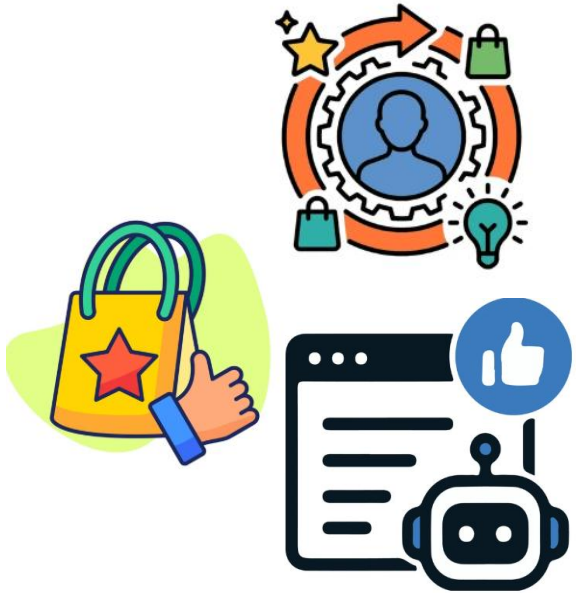
Portanto, a decomposição final é:

$$A = U\Sigma V^T$$

$$\underbrace{\begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \\ 1 & 1 & 3 \end{bmatrix}}_{A} = \underbrace{\begin{bmatrix} 0{,}707 & 0{,}707 & 0 \\ 0{,}495 & -0{,}495 & 0{,}707 \\ 0{,}636 & -0{,}636 & -0{,}707 \end{bmatrix}}_{U} \underbrace{\begin{bmatrix} 4 & 0 & 0 \\ 0 & 3{,}372 & 0 \\ 0 & 0 & 2{,}372 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} 0{,}566 & 0{,}707 & 0{,}424 \\ 0{,}707 & 0 & -0{,}707 \\ 0{,}424 & -0{,}707 & 0{,}566 \end{bmatrix}}_{V^T}$$

Decomposição SVD passo a passo

Passo	O que fazer
1	Calcular $A^T A$
2	Achar autovalores de $A^T A$
3	Valores singulares: $\sigma_i = \sqrt{\lambda_i}$
4	Autovetores de $A^T A$ → colunas de V
5	$u_i = \frac{1}{\sigma_i} A v_i$ → colunas de U
6	Montar $A = U \Sigma V^T$ e verificar



Sistemas de recomendação

Implementando .....



Sistemas de recomendação

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.


Facens
AQUI TEM ENGENHARIA