

Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br

Facens



Sistema de recomendação FunkSVD

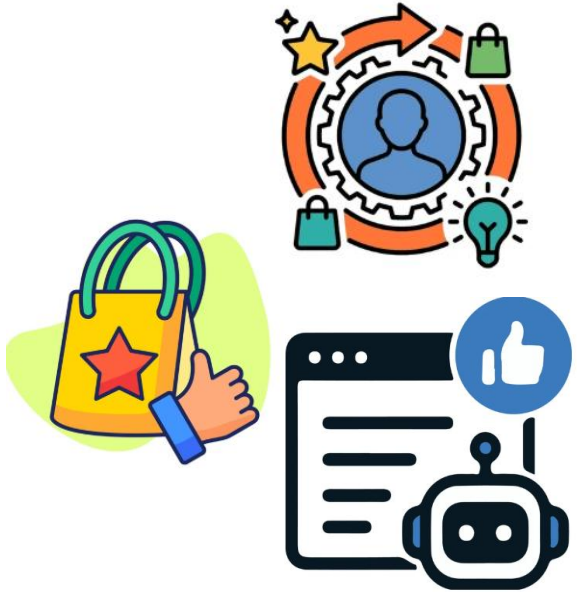
Cronograma

- Origem do FunkSVD
- O problema do SVD tradicional
- Conceituação do FUNKSVD
- O que cada componente captura
- Otimização via SGD
- Aprimoramentos
- Vantagens
- Desvantagens
- Em síntese

A origem de FUNKSVD

O Netflix Prize (2006–2009)

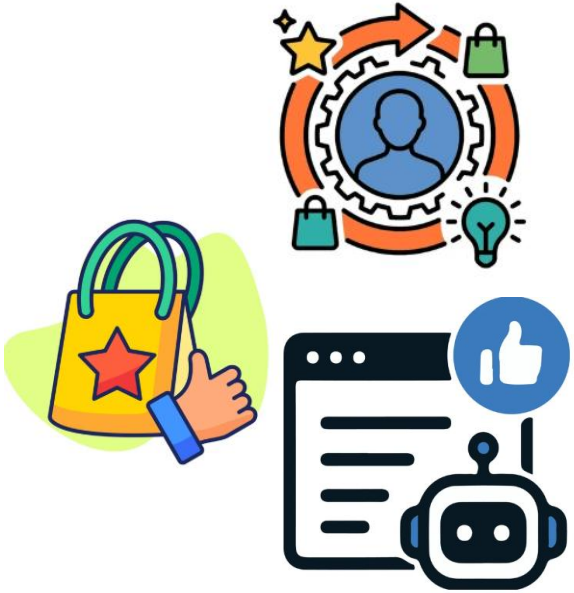
Em outubro de 2006, a Netflix lançou um desafio: **1 milhão de dólares** para quem melhorasse seu algoritmo de recomendação em **10%** (medido por RMSE). O dataset tinha **100 milhões de ratings**, **480 mil usuários** e **17 mil filmes**.



A origem de FUNKSVD

O Netflix Prize (2006–2009)

O que aconteceu a seguir mudou para sempre os sistemas de recomendação:

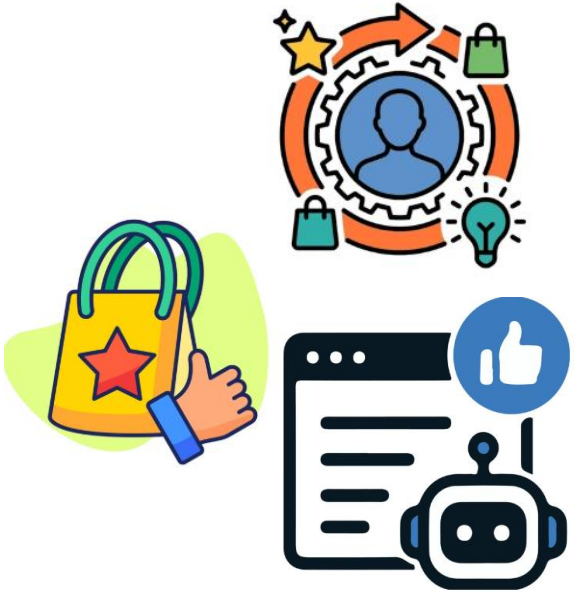


- **Times de todo o mundo** competiram por 3 anos.
- As técnicas vencedoras **não foram** vizinhança (user-based/item-based), mas sim **fatoração de matrizes**.
- Um blogueiro chamado **Simon Funk** publicou, em 2006, uma série de posts descrevendo uma técnica simples e poderosa: o **SVD incremental via SGD**.

A origem de FUNKSVD

Por que "Funk"SVD?

- **Funk** = sobrenome do autor (Simon Funk).
- **SVD** = inspirado na decomposição em valores singulares.
- **Mas atenção**: FunkSVD **não é** uma SVD algébrica! É uma **fatoração de matrizes treinada por SGD**. O nome é uma homenagem/analogia.



A origem de FUNKSVD

Curiosidade: Simon Funk ficou famoso não por ganhar o prêmio, mas por **compartilhar abertamente** sua abordagem. O nome "FunkSVD" é uma homenagem a ele. A Netflix nunca usou o algoritmo vencedor em produção (complexo demais), mas adotou técnicas derivadas do FunkSVD.



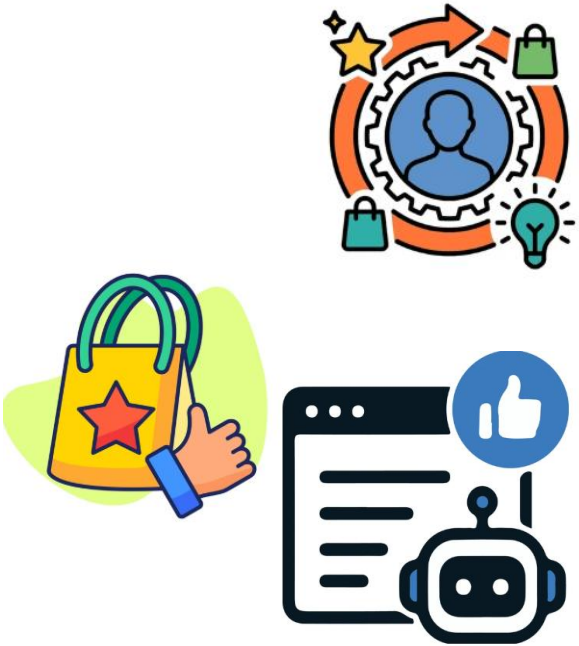
O problema do SVD tradicional

A Singular Value Decomposition (SVD) clássica, decompõe uma matriz $R \in \mathbb{R}^{mxn}$

$$R = U\Sigma V^T$$

sendo:

- $U \in \mathbb{R}^{m \times m}$: vetores singulares à esquerda (usuários).
- $\Sigma \in \mathbb{R}^{m \times n}$: valores singulares (importância de cada fator).
- $V \in \mathbb{R}^{n \times n}$: vetores singulares à direita (itens)



O problema do SVD tradicional

O problema: missing values

Ponto crítico: A SVD clássica **exige uma matriz completa**. Mas nossa matriz *R* tem 99% de valores ausentes!



O problema do SVD tradicional

O problema: missing values

1. **Imputação distorce**: preencher ausentes com a média global (ou zero) cria **padrões falsos**. O algoritmo "aprende" com dados que não existem.
2. **Perde a estrutura**: ao imputar, tratamos ausentes como se fossem avaliações reais — o que **enviesa os fatores latentes**.
3. **Overfitting**: o modelo se ajusta ao ruído da imputação, não à preferência real!



O problema do SVD tradicional

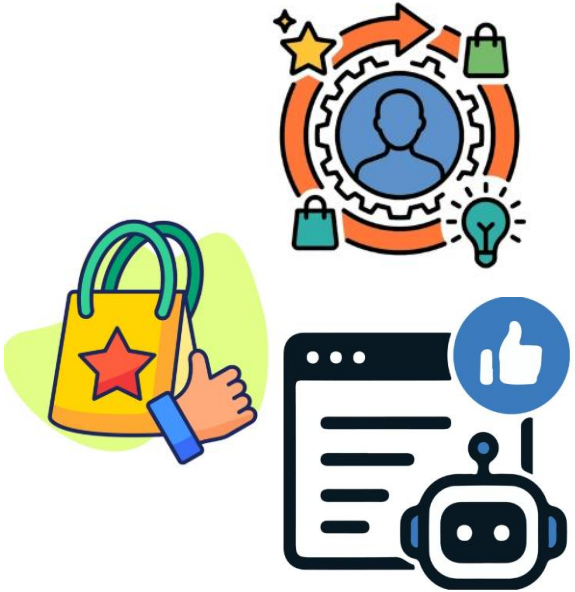
Insight crucial: "não avaliou" **não é** "não gostou". São coisas completamente diferentes. A SVD clássica não distingue isso.



Conceituação do FunkSVD

Definição formal

O FunkSVD é um modelo de **fatoração de matrizes** que aprende vetores latentes $\mathbf{p}_u \in \mathbb{R}^k$(usuário) e $\mathbf{q}_i \in \mathbb{R}^k$(item) minimizando o erro quadrático **apenas sobre as interações observadas**, com regularização.



A previsão é:

Conceituação do FunkSVD

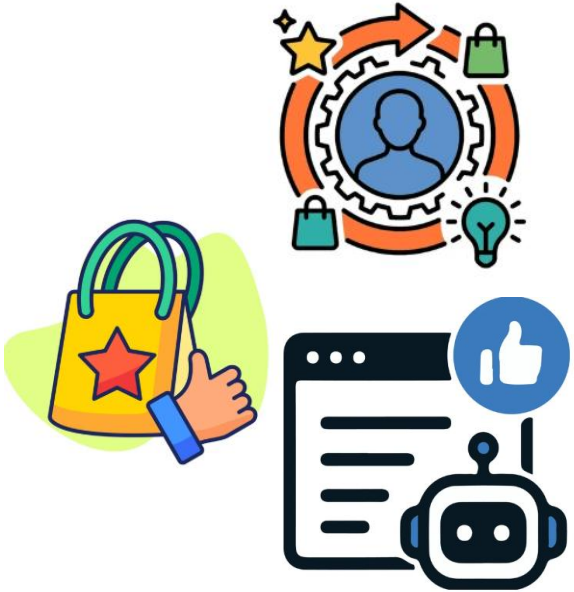
Definição formal

A previsão é:

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u^T \mathbf{q}_i$$

onde:

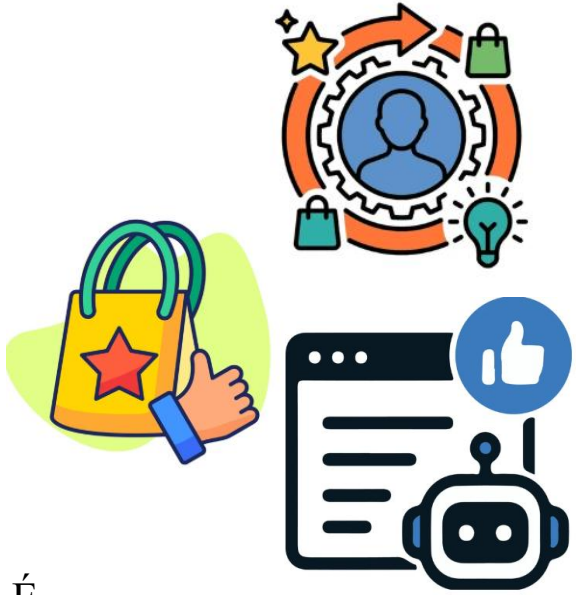
- μ: média global dos ratings observados.
- b_u: viés do usuário (tendência a dar notas altas/baixas).
- b_i: viés do item (tendência a ser bem/mal avaliado).
- $\mathbf{p}_u^T \mathbf{q}_i$: interação latente entre usuário e item.



Conceituação do FunkSVD

Função objetivo

$$\min_{\mathbf{P},\mathbf{Q},\mathbf{b}} \sum_{(u,i)\in\mathcal{K}} \left(r_{ui} - \mu - b_u - b_i - \mathbf{p}_u^T \mathbf{q}_i\right)^2 + \lambda \left(\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2 + b_u^2 + b_i^2\right)$$



onde:

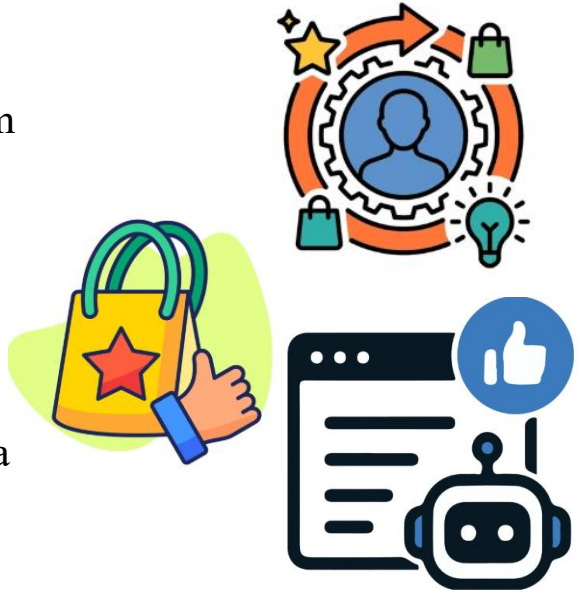
$\mathcal{K}$: conjunto de **interações observadas** (apenas elas!).

λ: parâmetro de **regularização** (evita overfitting)

Diferença crucial: o somatório é sobre $\mathcal{K}$, **não sobre toda a matriz**. É isso que resolve o problema dos missing values.

O que cada componente captura?

Componente	Significado	Exemplo
μ	Média global	"Em média, filmes recebem 3.5"
b_u	Viés do usuário	"Ana tende a dar notas 0.5 acima da média"
b_i	Viés do item	"Interestelar é 1.2 acima da média"
$\mathbf{p}_u^T \mathbf{q}_i$	Interação latente	"Ana gosta de ficção científica, e Interestelar é ficção científica"

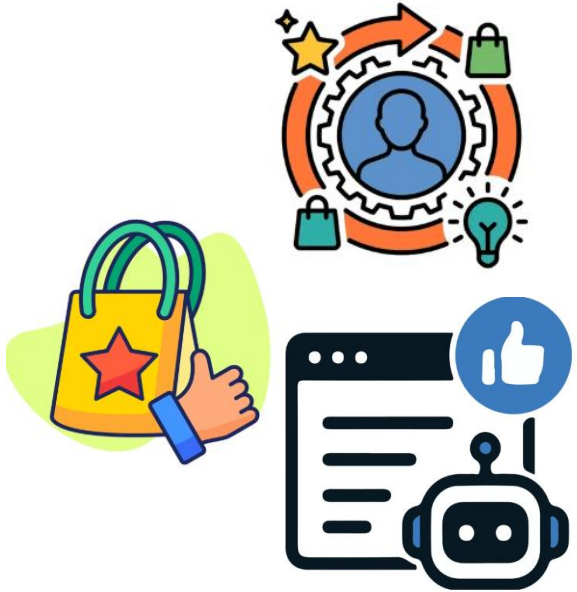


Otimização via SGD

Para cada interação observada (u, i, r_{ui}):

1. Calcule o erro:

$$e_{ui} = r_{ui} - \hat{r}_{ui} = r_{ui} - (\mu + b_u + b_i + \mathbf{p}_u^T \mathbf{q}_i)$$

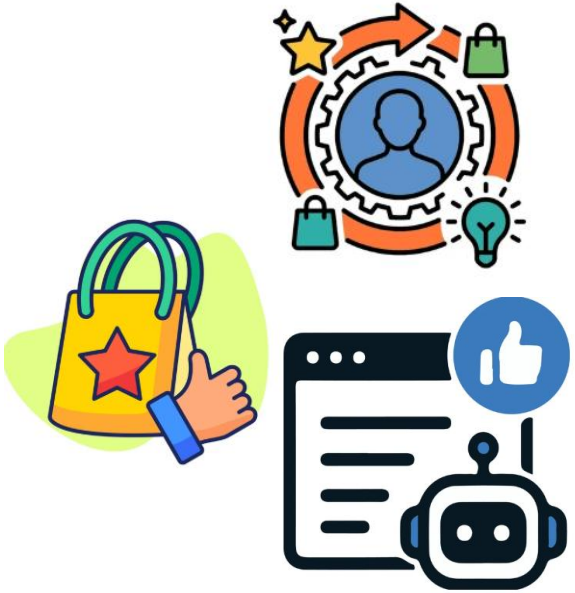


Otimização via SGD

Para cada interação observada (u, i, r_{ui}):

2. Atualize os parâmetros na direção oposta ao gradiente:

$$
\begin{aligned}
b_u &\leftarrow b_u + \eta(e_{ui} - \lambda b_u) \\
b_i &\leftarrow b_i + \eta(e_{ui} - \lambda b_i) \\
\mathbf{p}_u &\leftarrow \mathbf{p}_u + \eta(e_{ui}\mathbf{q}_i - \lambda \mathbf{p}_u) \\
\mathbf{q}_i &\leftarrow \mathbf{q}_i + \eta(e_{ui}\mathbf{p}_u - \lambda \mathbf{q}_i)
\end{aligned}
$$

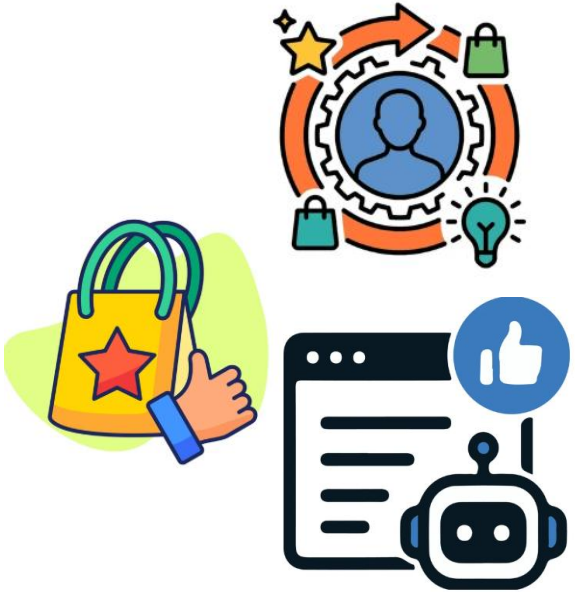


onde ηé a **taxa de aprendizado** (learning rate).

λ: parâmetro de **regularização** (evita overfitting)

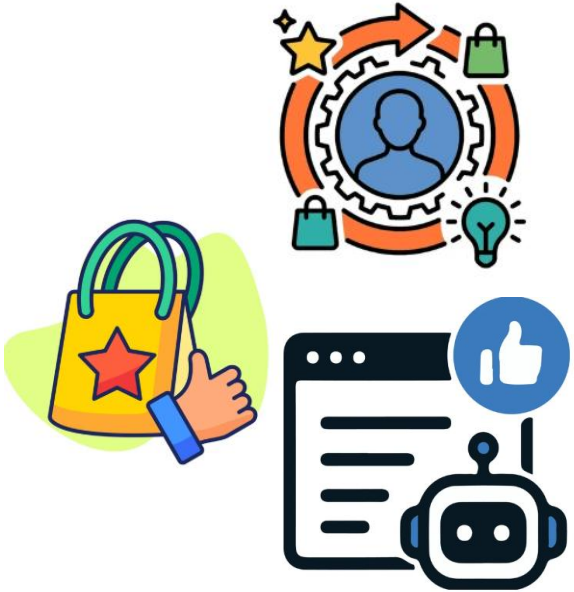
Aprimoramentos

Aspecto	SVD Tradicional	FunkSVD
Matriz de entrada	Completa (exige imputação)	Esparsa (só observados)
Tratamento de missing	Imputa (enviesa)	Ignora (correto)
Otimização	Decomposição algébrica	SGD iterativo
Regularização	Não nativa	Explícita (λ)
Viés	Não modela	Modela (μ, b_u, b_i)



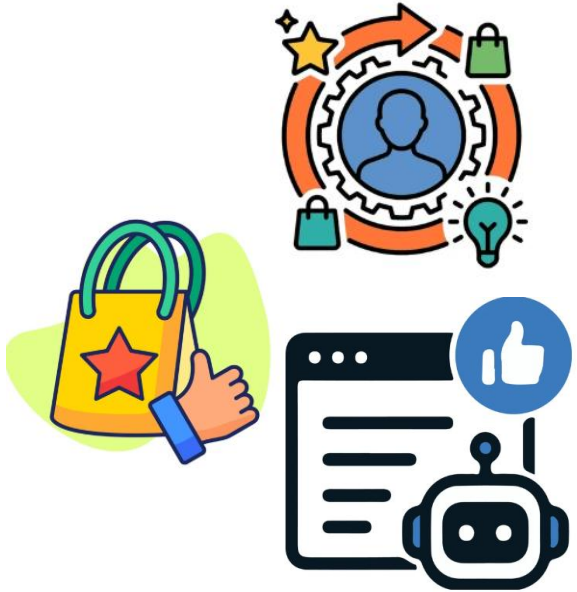
Vantagens

Vantagem	Explicação
Lida com esparsidade	Aprende apenas com observados, sem imputação
Escalável	Complexidade linear em
Flexível	Permite perdas customizadas (RMSE, BPR, log-loss)
Regularização explícita	Controle direto de overfitting



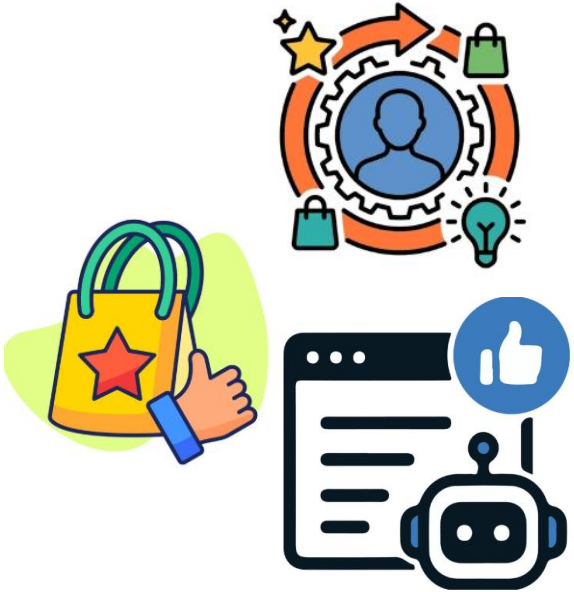
Vantagens

Vantagem	Explicação
Modela viés	Captura efeitos sistemáticos de usuário/item
Atualizações online	Novos ratings podem ser incorporados incrementalmente
Interpretável	Fatores latentes capturam padrões (gêneros, estilos)
Simples de implementar	Poucas linhas de código com SGD
Base para outros modelos	SVD++, NCF, AutoRec derivam dele



Em síntese

FunkSVD é a ponte entre a teoria clássica (SVD) e a prática moderna (deep learning). Ele resolve o problema fundamental da esparsidade ao aprender apenas com dados observados, modelando viés e regularizando explicitamente. É simples, flexível e preciso — por isso permanece como **baseline forte** e **base para técnicas avançada**



Sistemas de recomendação

Implementando .....



Sistemas de recomendação

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.


Facens
AQUI TEM ENGENHARIA