

Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br



Algoritmo K-Means

Cronograma

1. O que é o K-Means?
2. Função objetivo (inércia / WCSS)
3. Inicialização: o Ponto Crítico
4. Número de Clusters (k)
5. Aplicações do K-Means
6. Aplicações do K-Means
7. Limitações do K-Means
8. Passo a Passo do Algoritmo
9. Quando não usar o K-Means

O que é o K-Means?

O **K-Means** é um algoritmo de **aprendizado não supervisionado** do tipo **particional**, usado para **agrupamento (clustering)**. Seu objetivo é dividir n observações em k grupos (clusters) distintos, de modo que os pontos dentro d cada grupo sejam **mais similares entre si** do que em relação aos pontos d outros grupos.

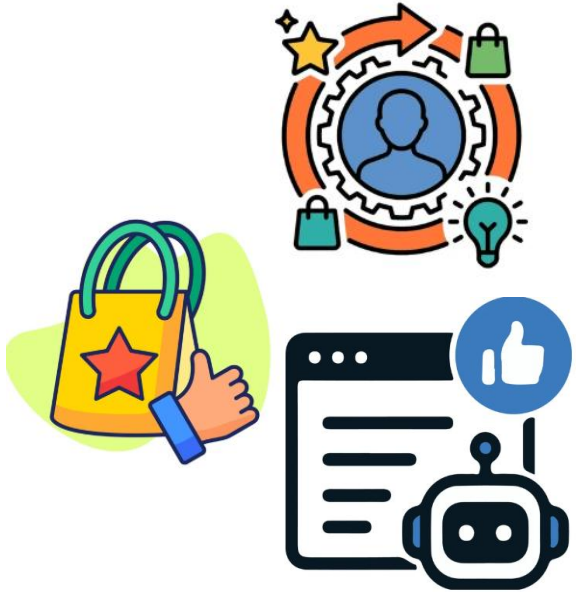


Foi proposto por **Stuart Lloyd em 1957** (publicado em 1982) e é um dos algoritmos de clustering mais populares pela sua **simplicidade, eficiência e escalabilidade**

O que é o K-Means?

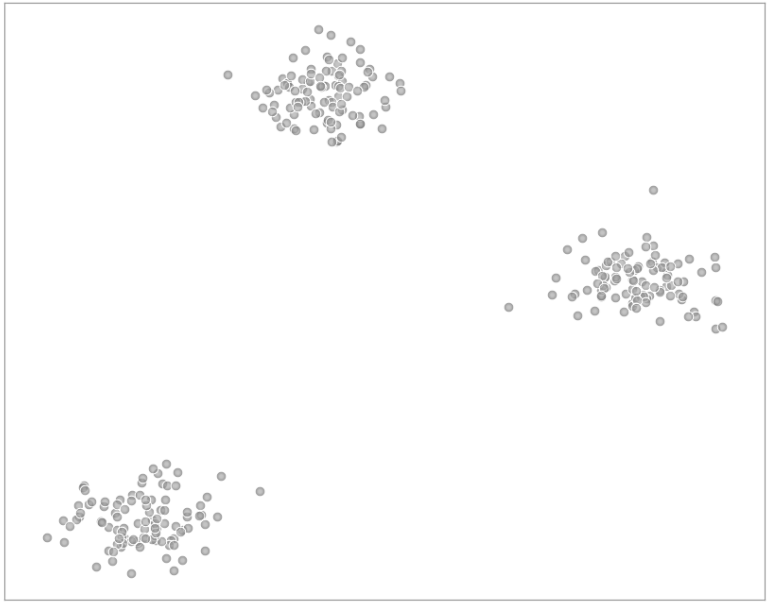
Intuição geométrica

Dado um conjunto de pontos no espaço, o K-Means busca k **centroides** (centros) de forma que cada ponto seja atribuído ao centroide mais próximo. O resultado final são k "bolhas" (regiões de Voronoi) que particionam o espaço.

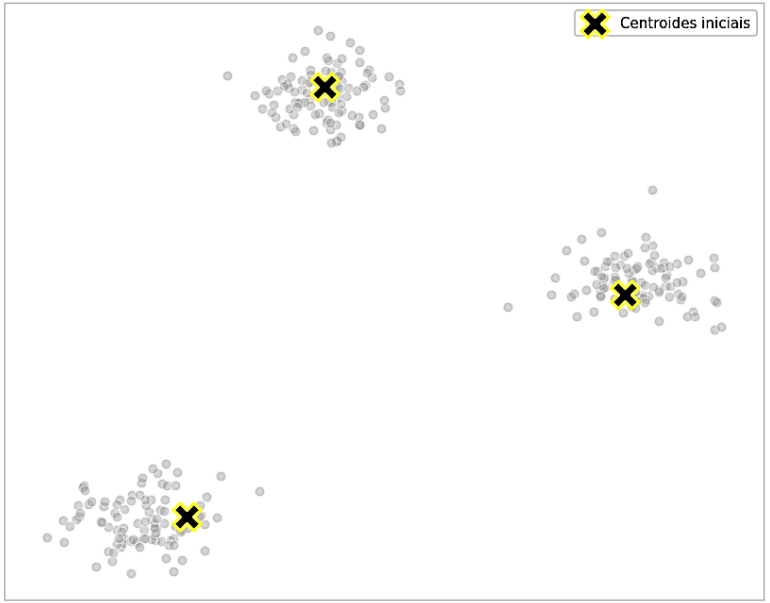


O que é o K-Means?

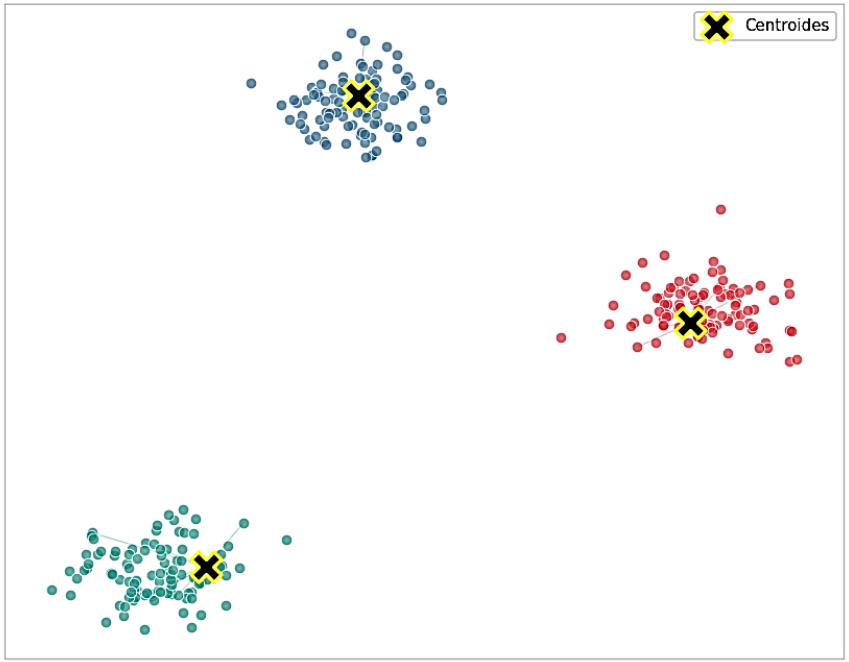
1. Dados Brutos (sem rótulos)
K-Means deve descobrir a estrutura oculta

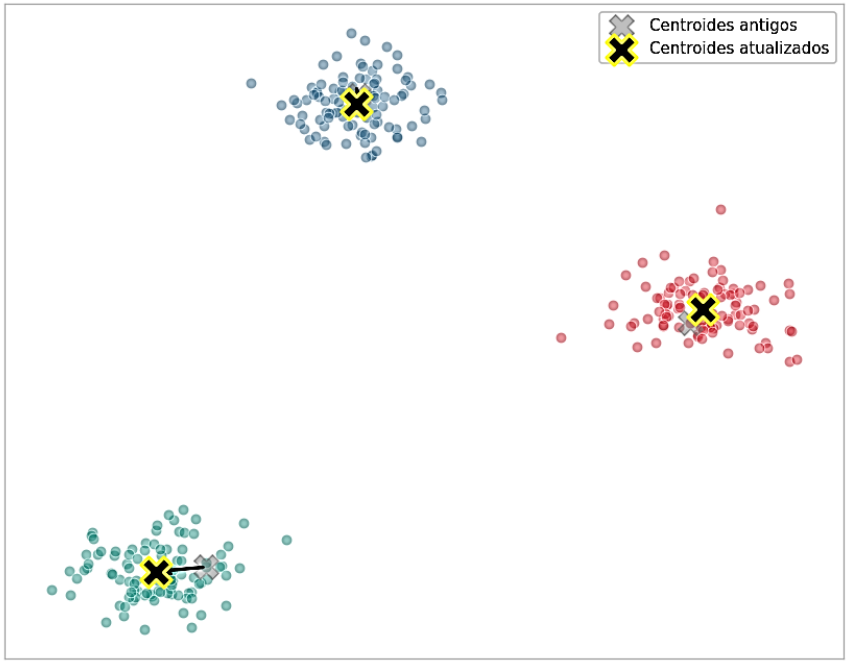


2. Inicialização com K-Means++
Centroides escolhidos com probabilidade ∝ distância²

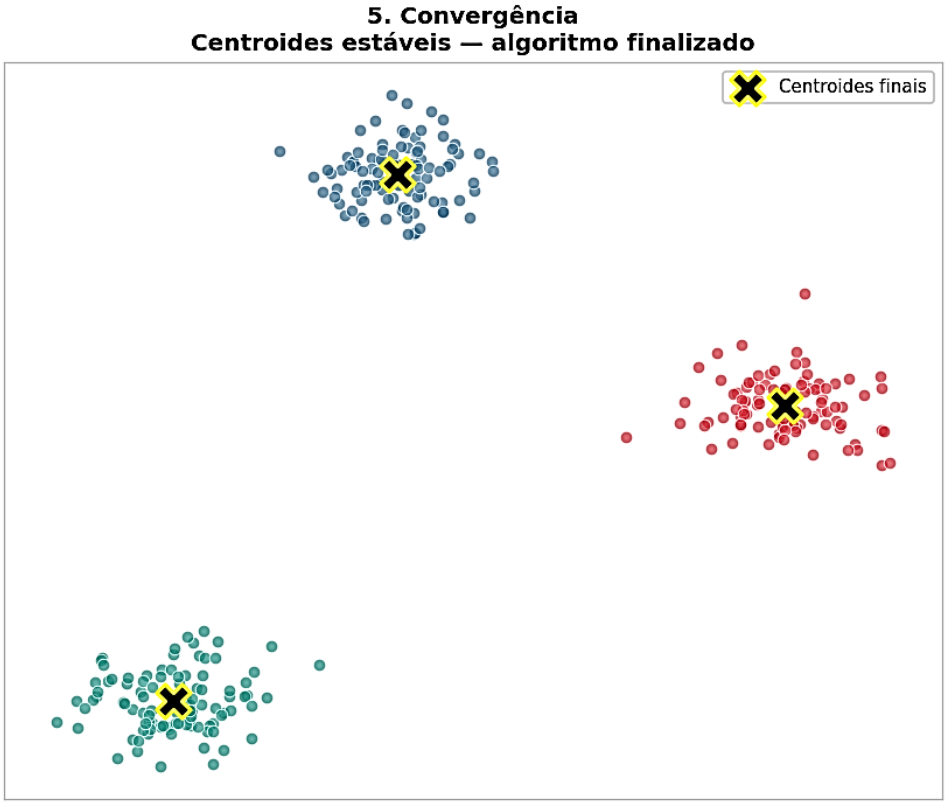


O que é o K-Means?

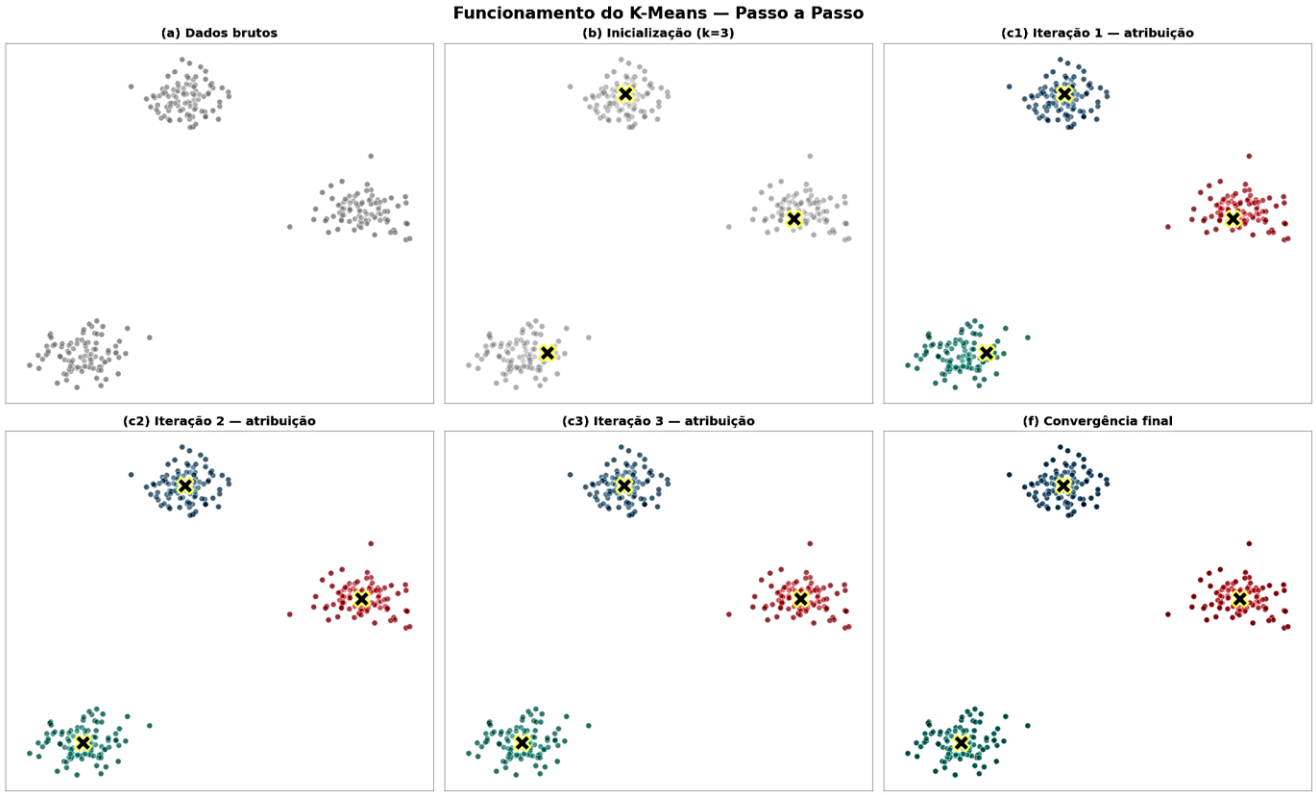




O que é o K-Means?



O que é o K-Means?



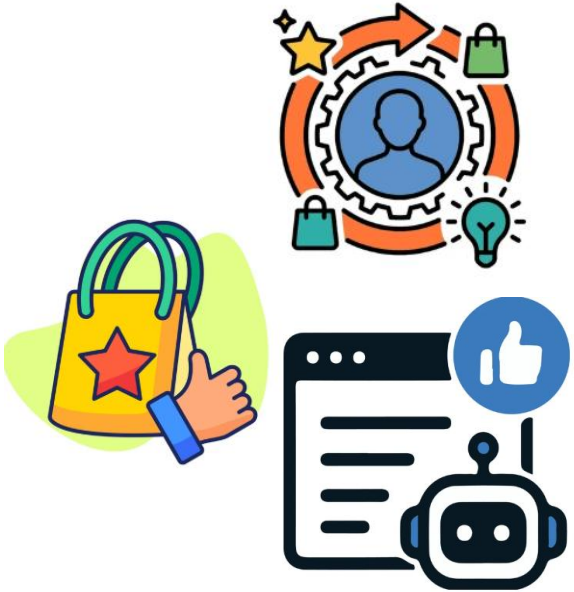
Função objetivo (inércia / WCSS)

Formulação Matemática

Função objetivo (inércia / WCSS)

O K-Means minimiza a **soma dos quadrados das distâncias intra-cluster** (*Within-Cluster Sum of Squares* — WCSS):

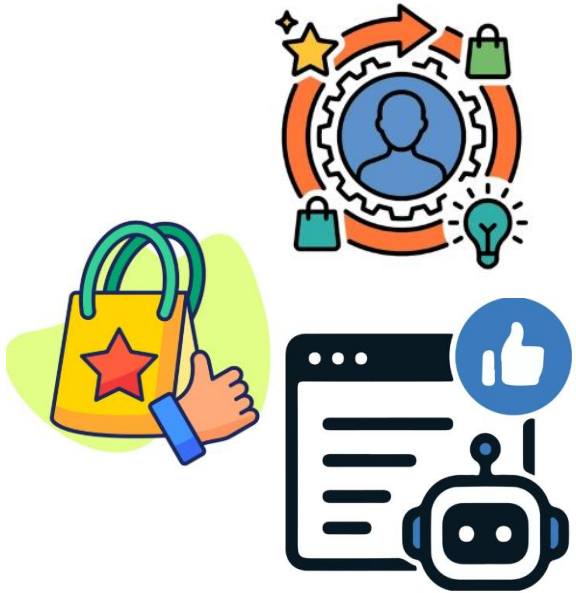
$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \| x - \mu_i \|^2$$



Função objetivo (inércia / WCSS)

Função objetivo (inércia / WCSS)

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \| x - \mu_i \|^2$$



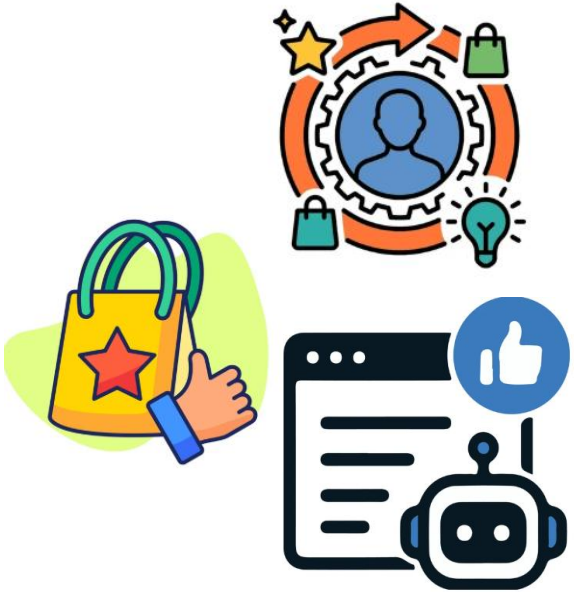
Onde:

- C_i= conjunto de pontos do cluster i
- μ_i= centroide (média) do cluster i
- $\| x - \mu_i \|^2$= distância euclidiana ao quadrado
- **Objetivo:** encontrar a partição que **minimiza J**.

Função objetivo (inércia / WCSS)

Convergência

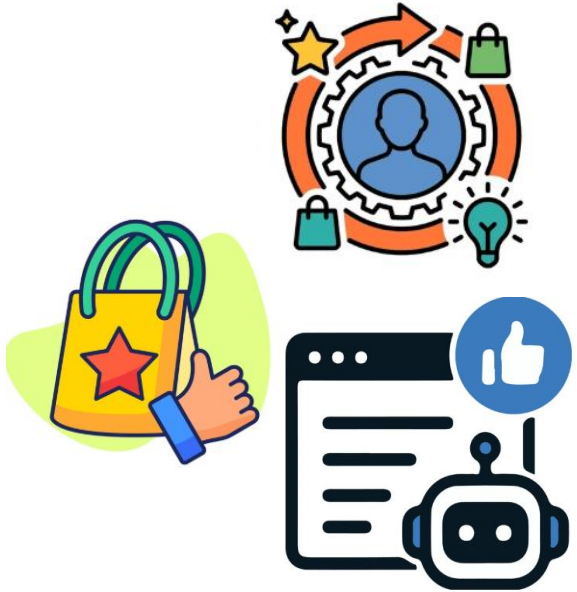
- O algoritmo **sempre converge** (em tempo finito), pois:
- Cada passo de atribuição **reduz ou mantém** J
- Cada passo de atualização **reduz ou mantém** J
- Existe um número finito de partições possíveis
- Porém, converge para um **mínimo local**, que pode não ser o global.



Inicialização: o Ponto Crítico

A escolha inicial dos centroides afeta drasticamente o resultado. Três estratégias:

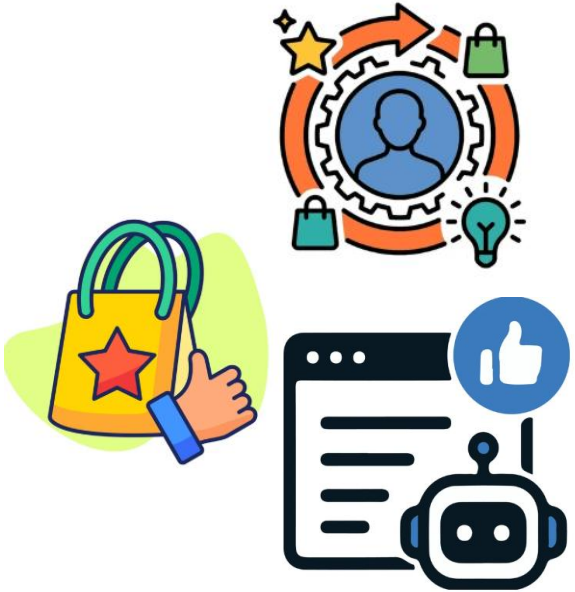
Método	Descrição	Qualidade
Aleatória	Escolhe k pontos aleatórios	Ruim (instável)
Forgy	Escolhe k pontos do dataset como centroides	Média
K-Means++ ⭐	Escolhe centroides com probabilidade proporcional à distância² dos já escolhidos	Ótima (padrão no scikit-learn)



Número de Clusters (k)

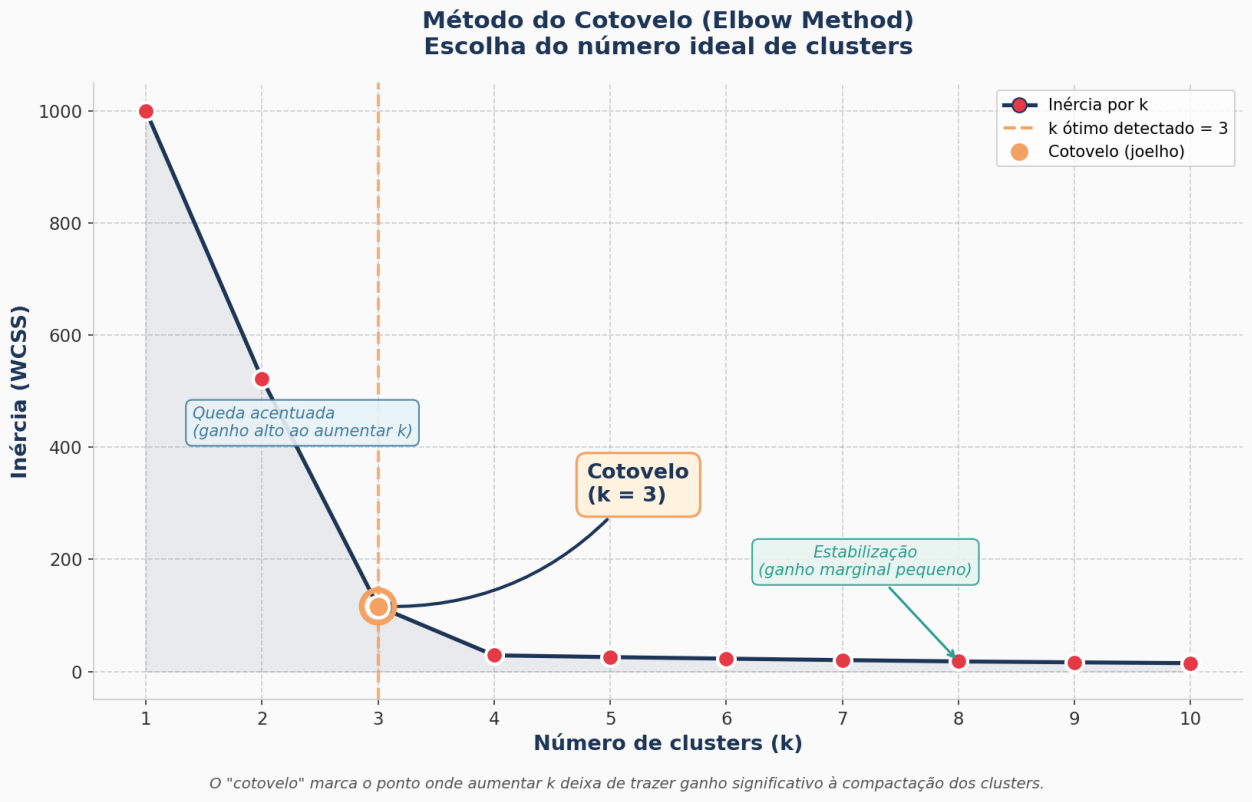
Como Escolher o Número de Clusters (k)?

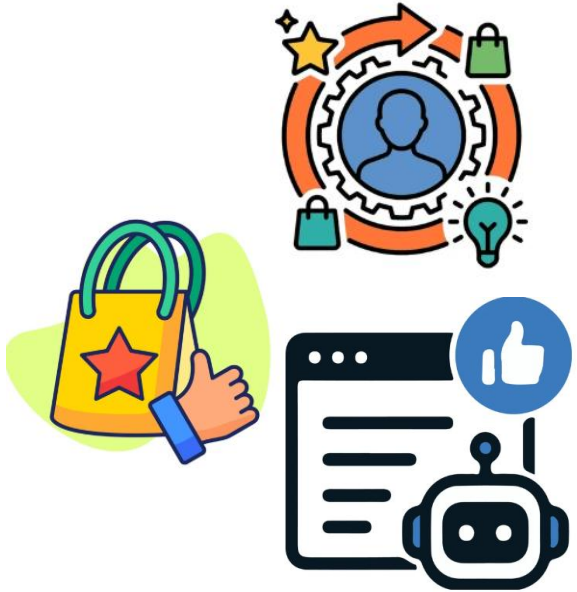
O K-Means **exige que k seja definido a priori**. Métodos para escolher:



- **Método do Cotovelo (Elbow Method)**
- **Coeficiente de Silhueta (Silhouette Score)**
- **Método Gap Statistic**
- **Índice de Davies-Bouldin**

Número de Clusters (k)



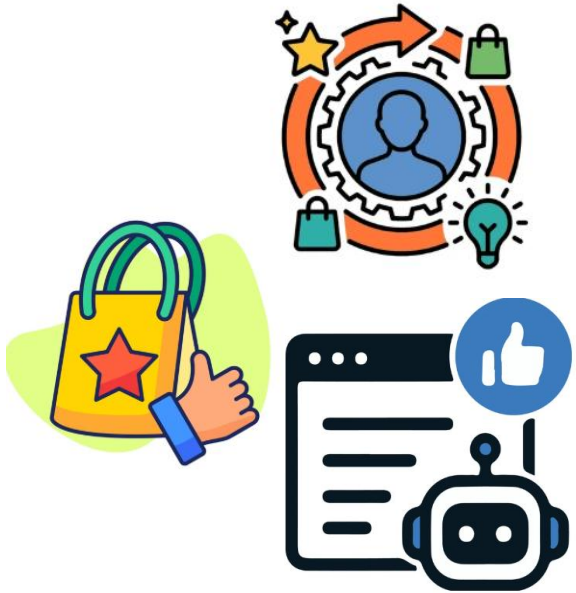


Número de Clusters (k)?

Coeficiente de Silhueta (Silhouette Score)

Mede o quão bem cada ponto se encaixa no seu cluster vs. no cluster vizinho:

$$s(i) = \frac{b(i) - a(i)}{\max(a,(i)b(i))} \in [-,11]$$



- $a(i)$= distância média aos pontos do mesmo cluster
- $b(i)$= distância média aos pontos do cluster mais próximo
- **Interpretação:** > 0.5 = boa estrutura; < 0.25 = fraca.

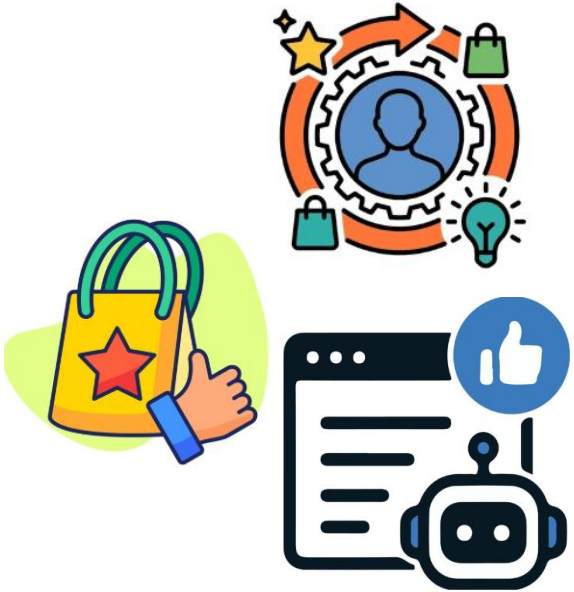
Número de Clusters (k)

Método Gap Statistic

- Compara a inércia observada com a esperada sob uma distribuição nula (dados aleatórios).

Índice de Davies-Bouldin

- Razão entre dispersão intra-cluster e separação inter-cluster. **Menor = melhor**.

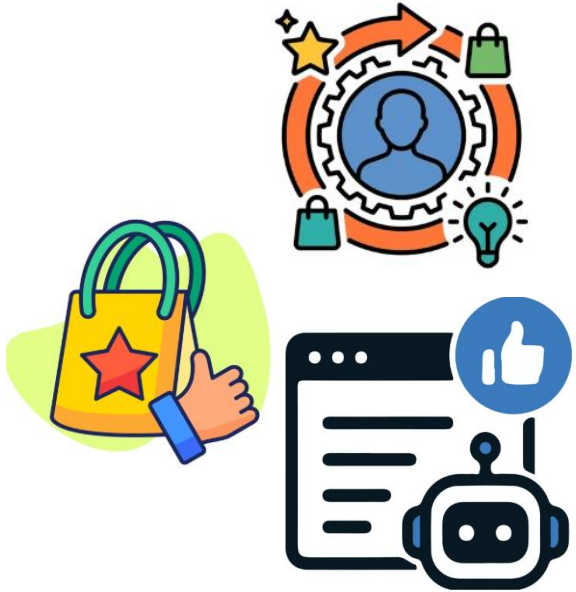


Aplicações do K-Means

Segmentação de Clientes (Marketing)

Agrupar clientes por comportamento de compra, renda, frequência, etc.

Exemplo: Varejista segmenta em "econômicos", "premium", "ocasionais", "fiéis".

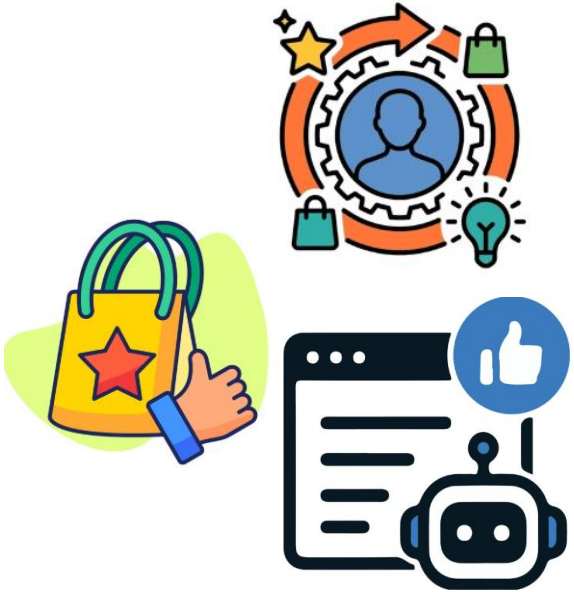


Aplicações do K-Means

Compressão de Imagens

Reduzir o número de cores de uma imagem para k cores (quantização). Cada pixel vira um ponto em RGB; K-Means encontra as k cores dominantes.

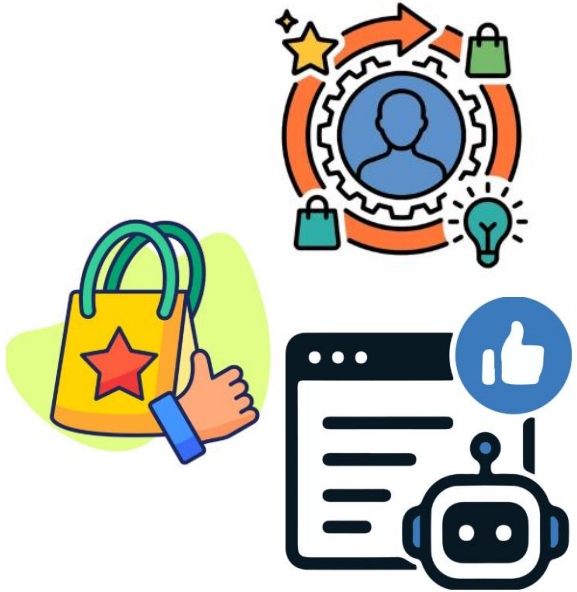
Aplicação real: formato GIF, compressão de imagens médicas.



Aplicações do K-Means

Segmentação de Imagens (Visão Computacional)

Separar regiões de uma imagem (ex: tumor vs. tecido saudável em exames).



Aplicações do K-Means

Sistemas de Recomendação

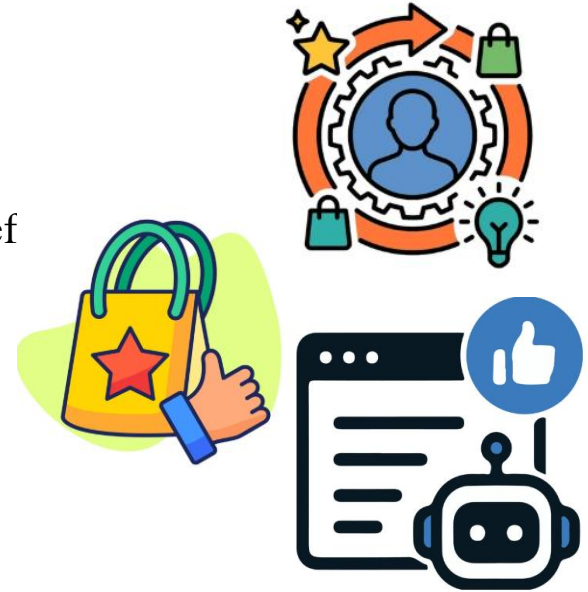
Agrupar usuários com gostos similares (pré-processamento para KNN ou filtragem colaborativa)



Aplicações do K-Means

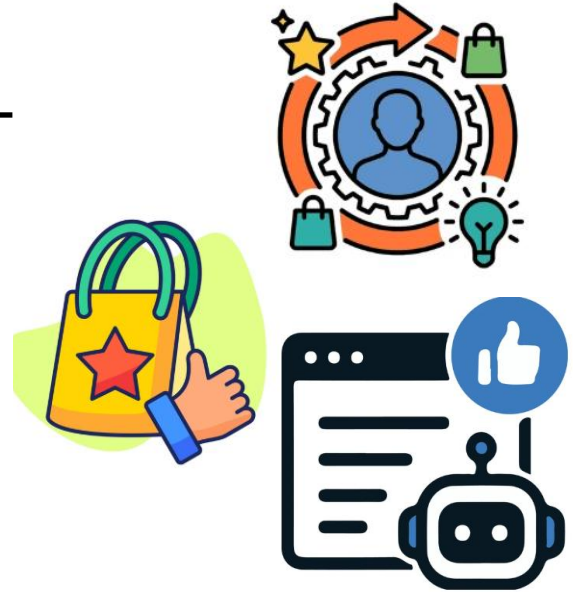
Detecção de Anomalias

Pontos distantes de todos os centroides podem ser outliers (fraude, def industrial).



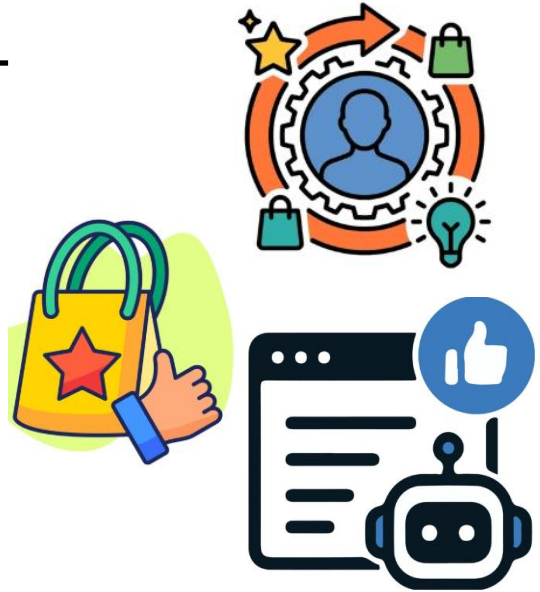
Limitações do K-Means

Limitação	Descrição	Impacto
k precisa ser definido a priori	Não descobre o número ótimo de clusters	Alto
Sensível à inicialização	Pode convergir para mínimo local ruim	Mitigado por K-Means++
Assume clusters esféricos	Funciona mal com clusters alongados ou irregulares	Alto
Sensível a outliers	Médias são distorcidas por valores extremos	Alto



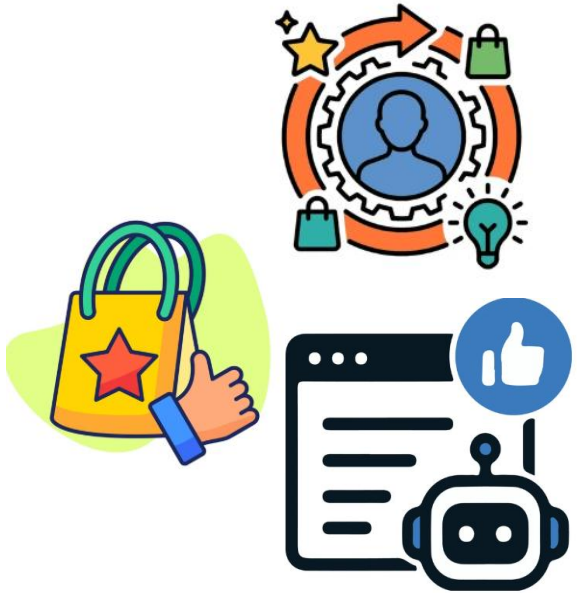
Limitações do K-Means

Limitação	Descrição	Impacto
Assume clusters de tamanho similar	Tende a dividir clusters grandes	Médio
Só lida com variáveis numéricas	Não aceita categóricas diretamente	Médio
Requer escala uniforme	Variáveis com escalas diferentes dominam	Alto (usar padronização)
Não determinístico	Resultados variam entre execuções	Médio
Complexidade O(n·k·d·i)	Pode ser lento para n e k muito grandes	Baixo com MiniBatch



Passo a Passo do Algoritmo

1. Padronizar os dados (StandardScaler / MinMaxScaler)
2. Tratar outliers (ou usar K-Medoids)
3. Testar k ∈ [2, 10] com Elbow + Silhouette
4. Rodar K-Means++ com n_init=10 (ou 25)
5. Validar clusters (silhueta, Davies-Bouldin, interpretação)
6. Interpretar centroides e perfis



Use o K-Means quando:

1. Você **já tem uma estimativa de k** (ou pode testar poucos valores)
2. Os clusters são **aproximadamente esféricos e bem separados**
3. O dataset é **grande** (K-Means é escalável — O(n·k·d))
4. As variáveis são **numéricas e contínuas**
5. Você precisa de **centroides interpretáveis** (ex: perfil médio do cluster)
6. Os dados foram **padronizados** e outliers tratados
7. Você quer um **baseline rápido** para clustering



Quando não usar o K-Means

- Clusters com formas arbitrárias → use **DBSCAN** ou **Spectral Clustering**
- Muitos outliers → use **DBSCAN** ou **K-Medoids (PAM)**
- k desconhecido → use **Hierarchical Clustering** ou **HDBSCAN**
- Dados categóricos → use **K-Modes** ou **K-Prototypes**
- Dados com ruído denso → use **DBSCAN** ou **Mean Shift**



Implementando

Implementando .....



Sistemas de recomendação

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.


Facens
AQUI TEM ENGENHARIA