

Séries temporais e sistemas de recomendação

Fabio Santiago
fabio.santiago@facens.br



Métricas de recomendação

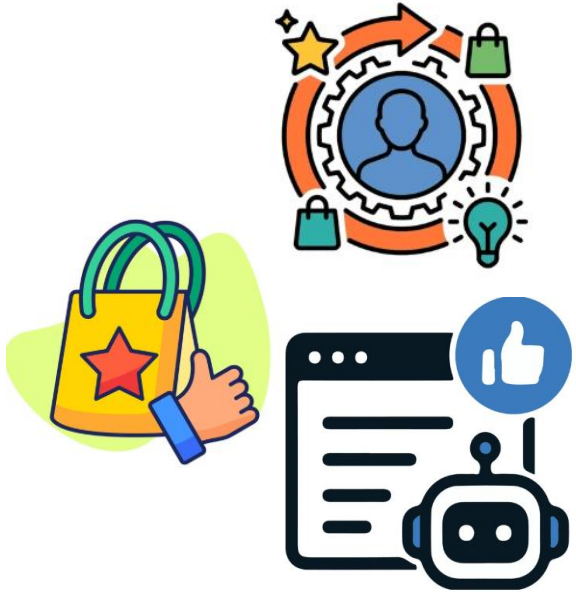
Cronograma

- Contextualizando
- Métricas de Precisão do Chute
- Mean Absolute Error
- RMSE (Root Mean Squared Error)
- Métricas de Ranking
- Precision@K
- Recall@K
- MAP@K (Mean Average Precision)
- NDCG@K (Normalized Discounted Cumulative Gain)

Contextualizando

Após a construção de um sistema de recomendação, uma pergunta natural é : **como saber se ele é bom?**

- Basta medir quantas previsões de nota acertamos? **Não.**
- Basta medir se as recomendações são diversificadas? **Também não.**
- Só olhar para o lucro da empresa? **Incompleto.**

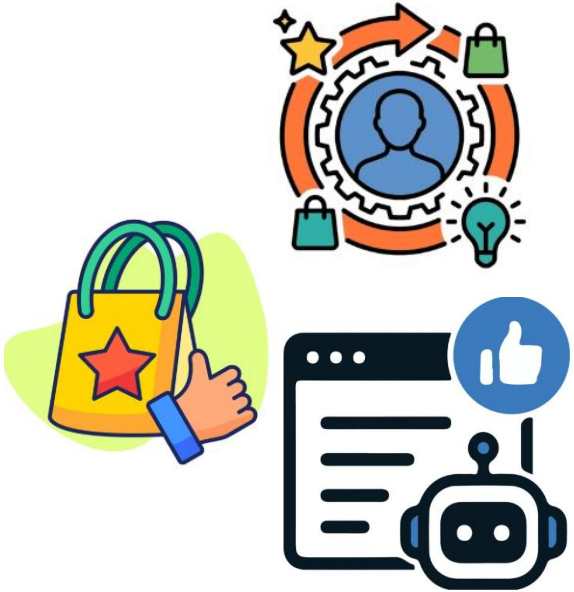


Um sistema de recomendação é um **produto multidimensional**.

Contextualizando

Para responder a questão anterior, o modelo desenvolvido precisa ser avaliado por três famílias de métricas.

- **Precisão do chute**
- **Ranking**
- **Negócio/Diversidade.**

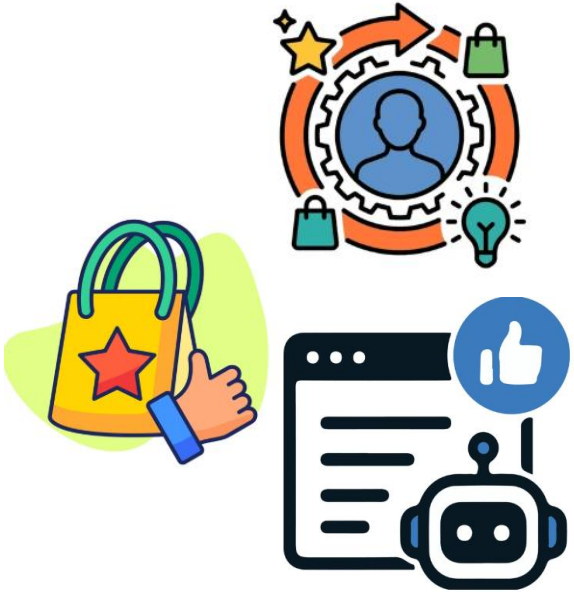


Métricas de Precisão do Chute

Conceito

Quando um sistema prevê **notas numéricas** (ex.: 1 a 5 estrelas), queremos medir **quão perto** as previsões estão dos valores reais. É um problema de **regressão**.

.

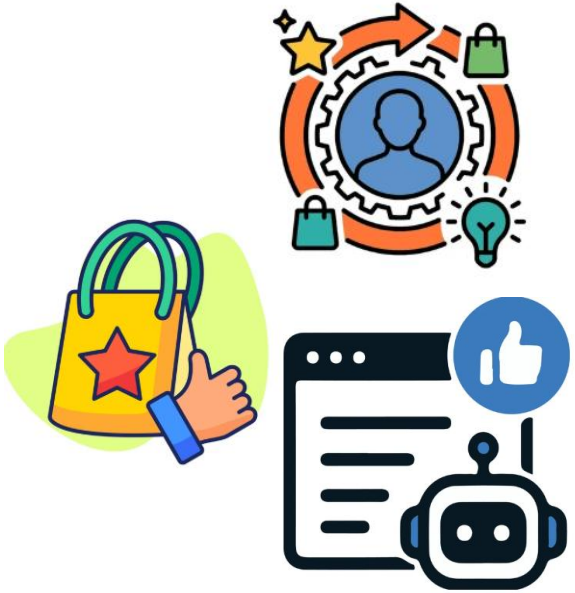


Métricas de Precisão do Chute

Exemplo 1

Suponha que temos 5 avaliações reais e o sistema previu:

Usuário	Filme	Nota Real	Nota Prevista	Erro
Ana	Matrix	5	4.2	0.8
Ana	Titanic	2	3.5	-1.5
Bruno	Matrix	4	4.8	-0.8
Bruno	Toy Story	5	3.0	2.0
Carla	Interestelar	3	4.1	-1.1

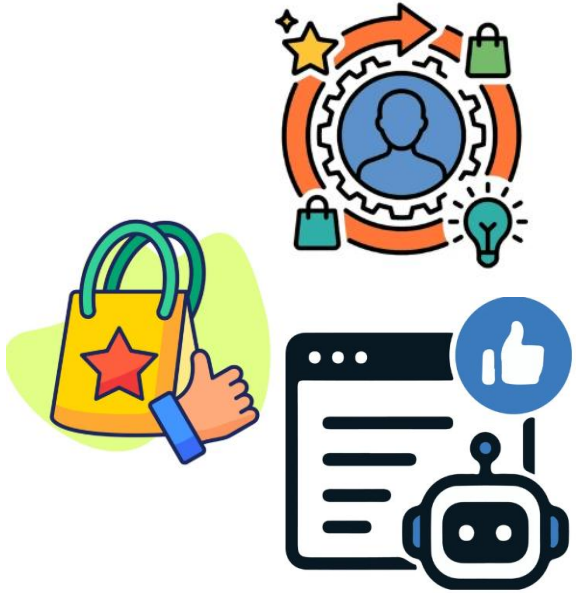


Mean Absolute Error

O que é: Média do valor absoluto dos erros.

Fórmula:

$$MAE = \frac{1}{N}\sum_{i=1}^{N} | y_i - \hat{y}_i |$$



Interpretação: Erro médio absoluto, **robusto para outliers**

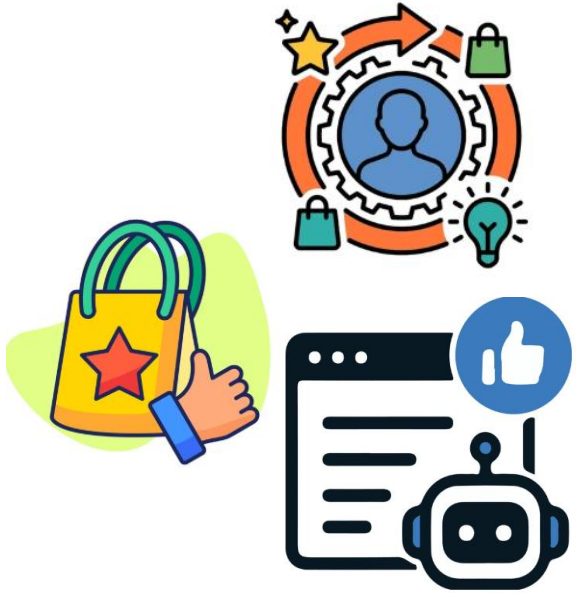
Limitação: prever bem notas não garante boas recomendações. Um sistema pode acertar a nota e ainda recomendar itens ruins. Por isso existem as métricas de ranking

Mean Absolute Error

O que é: Média do valor absoluto dos erros.

Fórmula:

$$MAE = \frac{1}{N}\sum_{i=1}^{N} | y_i - \hat{y}_i |$$



Interpretação: Erro médio absoluto, **robusto para outliers**

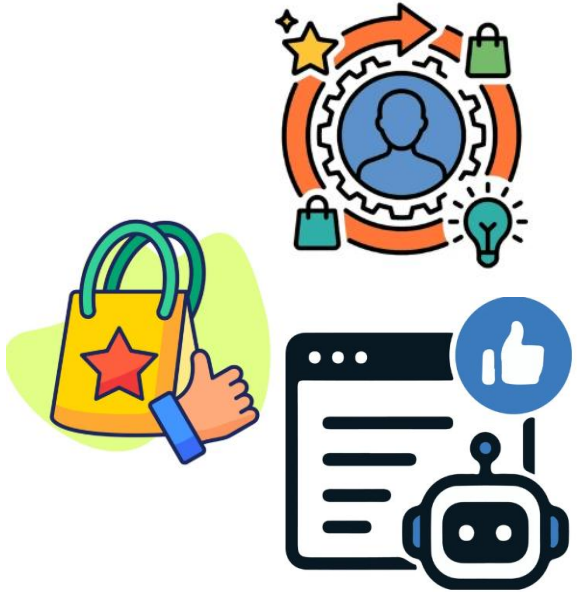
Limitação: prever bem notas não garante boas recomendações. Um sistema pode acertar a nota e ainda recomendar itens ruins. Por isso existem as métricas de ranking

Mean Absolute Error

Aplicando ao exemplo1 , tem-se:

$$MAE = \frac{1}{N}\sum_{i=1}^{N} | y_i - \hat{y}_i |$$

$$\text{MAE} = \frac{0.8 + 1.5 + 0.8 + 2.0 + 1.1}{5} = \frac{6.2}{5} = 1.24$$



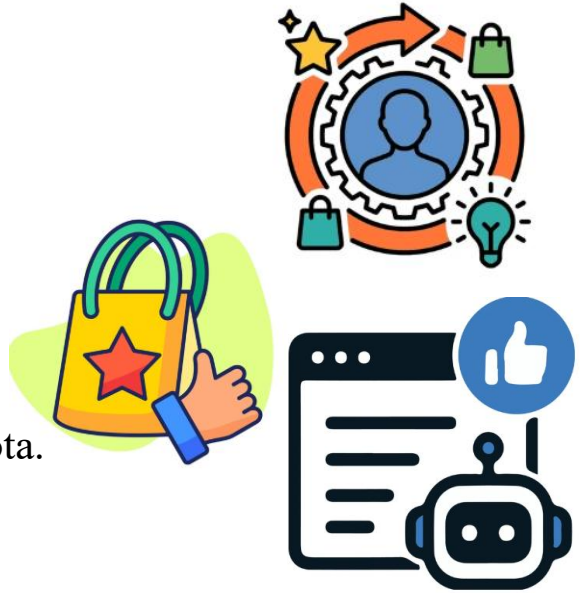
Interpretação: "Em média, erramos 1.24 estrelas por previsão."

RMSE (Root Mean Squared Error)

O que é: Raiz da média dos erros ao quadrado.

Fórmula:

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}$$

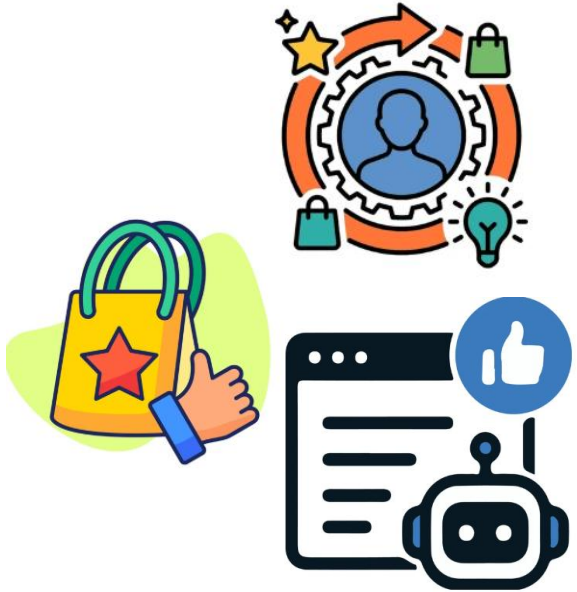


- **Interpretação:** Mede o erro médio em unidades da própria nota. Penaliza **mais fortemente erros grandes** (por causa do quadrado).
- **Uso típico:** Competições como Netflix Prize; quando se quer evitar erros muito grandes.

RMSE (Root Mean Squared Error)

Com os dados do exemplo1, tem-se:

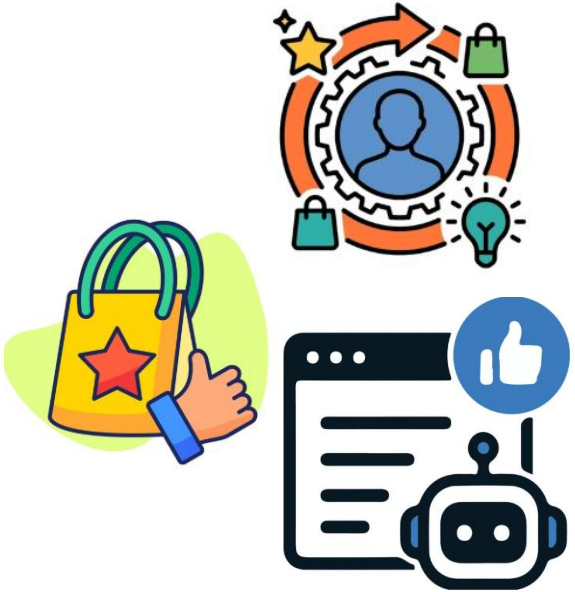
$$\text{RMSE} = \sqrt{\frac{0.64 + 2.25 + 0.64 + 4.00 + 1.21}{5}} = \sqrt{\frac{8.74}{5}} \approx 1.32$$



- **Interpretação:** Erro médio de 1.32 estrelas, **com penalização maior para erros grandes**

MAE vs RMSE — Quando usar cada um?

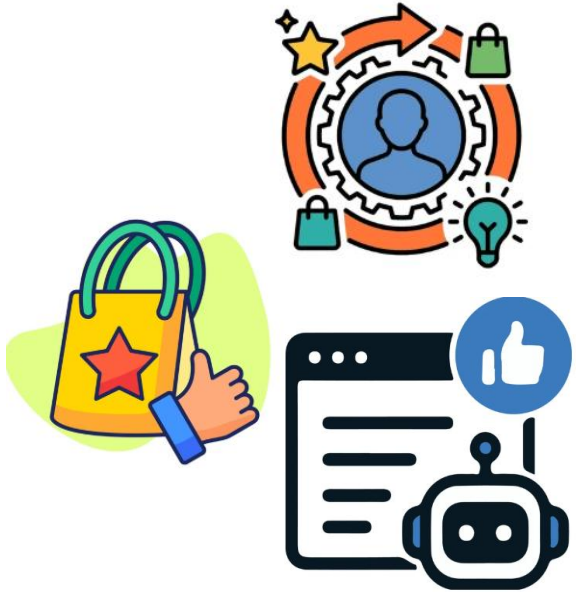
Situação	Métrica recomendada
Erros muito grandes são graves (ex.: recomendar filme horrível)	RMSE
Erros são todos igualmente ruins	MAE
Dados com muitos outliers	MAE (mais robusto)



Limitação crítica

Prever bem as notas **NÃO** significa recomendar bem!

Exemplo: Se um sistema só recomenda filmes medíocres (nota 3), ele pode ter RMSE baixo, mas nunca vai encantar ninguém. Precisamos de métricas de **ranking**.

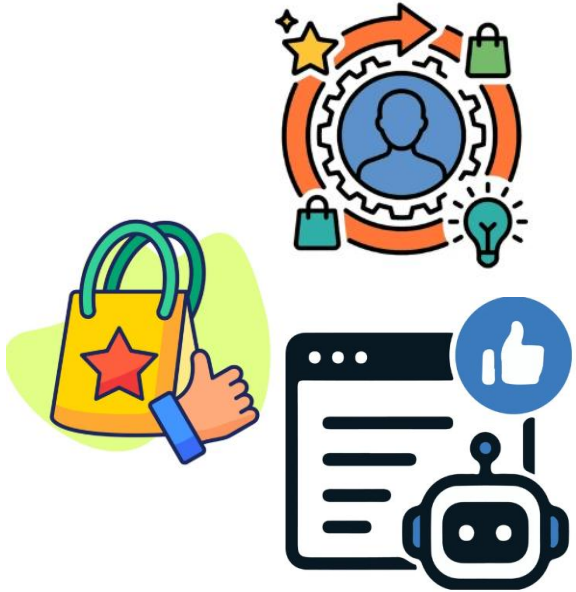


Métricas de Ranking

Exemplo

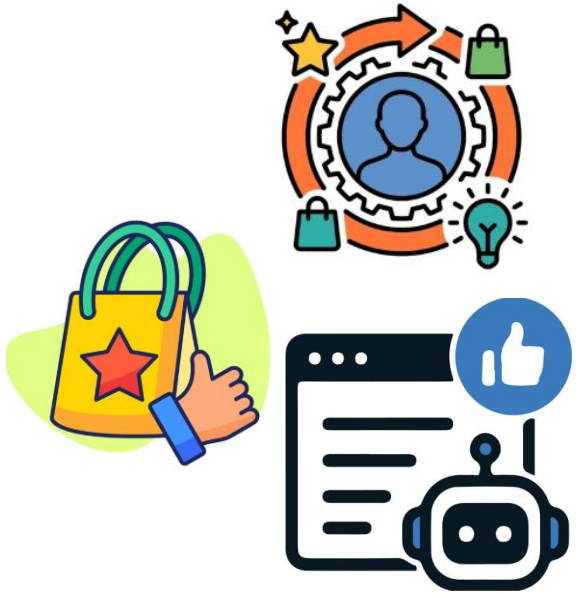
Para a usuária **Ana**, o sistema recomendou 5 filmes. Sabemos que Ana gostou (nota ≥ 4) de 3 filmes do catálogo:

Filmes relevantes para Ana: {Matrix, Interestelar, Pulp Fiction}



Métricas de Ranking

O objetivo aqui é avaliar a **qualidade da lista ordenada** (Top-K) que o sistema entrega ao usuário.

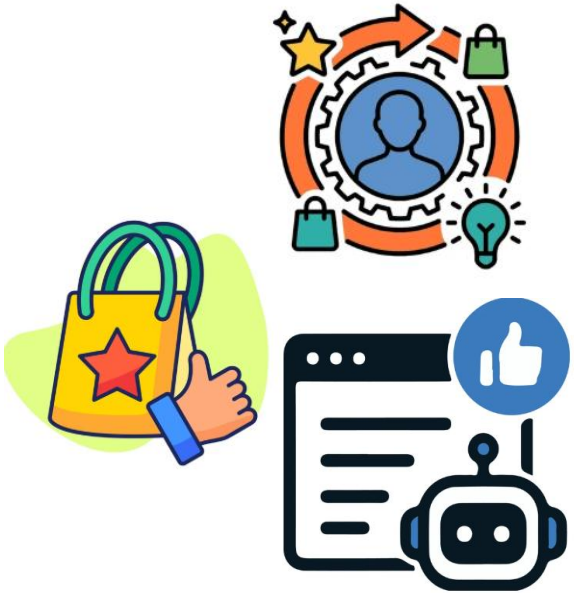


Métricas de Ranking

Exemplo 2

Para a usuária **Ana**, o sistema recomendou 5 filmes. Sabemos que Ana gostou (nota ≥ 4) de 3 filmes do catálogo:

Filmes relevantes para Ana: {Matrix, Interestelar, Pulp Fiction}

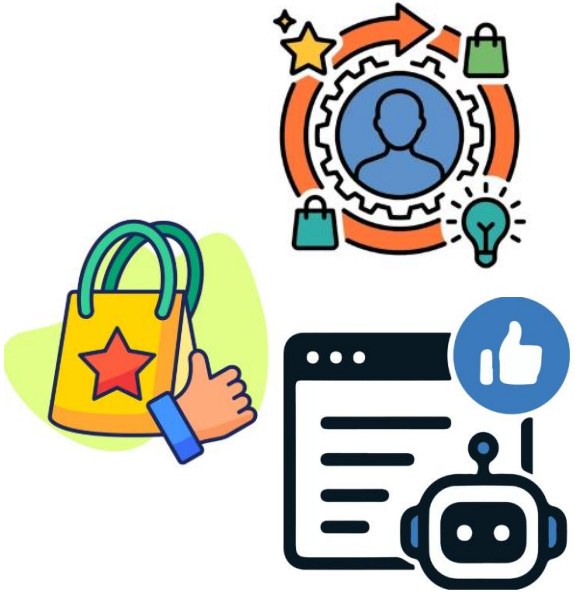


Métricas de Ranking

Exemplo 2

Recomendações do sistema (Top-5):

Posição	Filme	É relevante?
1	Matrix	✅
2	Toy Story	❌
3	Interestelar	✅
4	Titanic	❌
5	Pulp Fiction	✅



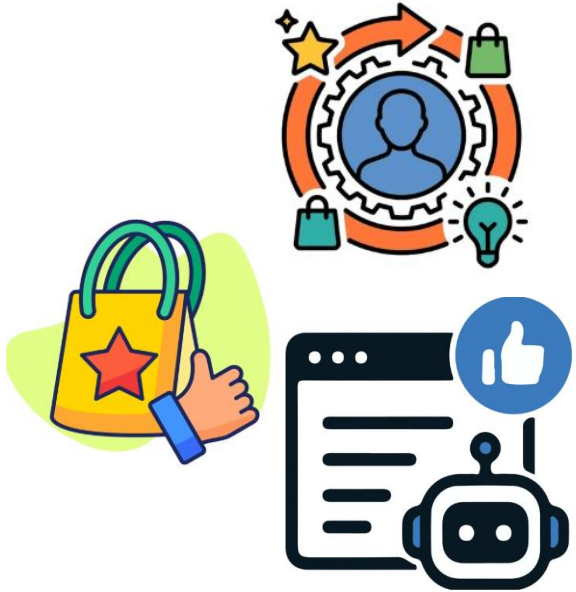
Precision@K

O que é: Fração dos K itens recomendados que são relevantes.

Fórmula:

$$Precision@K = \frac{\text{itens relevantes nos top K}}{K}$$

- **Interpretação:** "De 10 recomendações, quantas eram boas?"
- **Limitação:** Não considera a **posição** do item na lista.



Precision@K

Pergunta: "Dos K recomendados, quantos são relevantes?"

Fórmula:

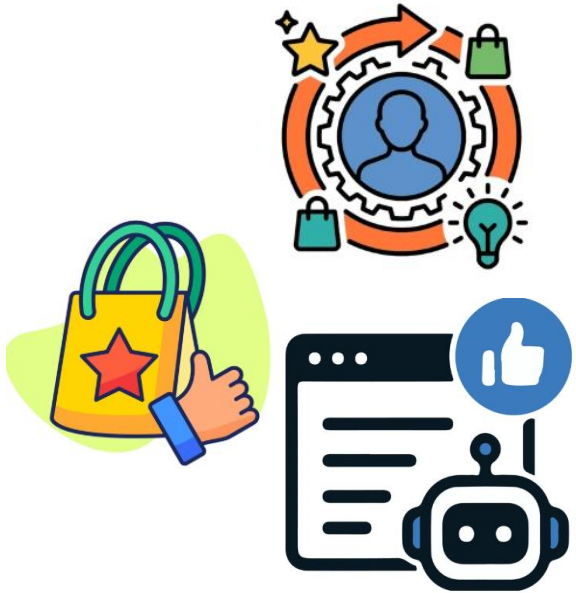
$$\text{Precision@K} = \frac{\text{relevantes no Top−K}}{K}$$

Cálculo com K=5:

$$\text{Precision@5} = \frac{3}{5} = 0.60$$

Com K=3: $\frac{2}{3} \approx 0.67$

Interpretação: "De cada 5 recomendações, 3 são boas."

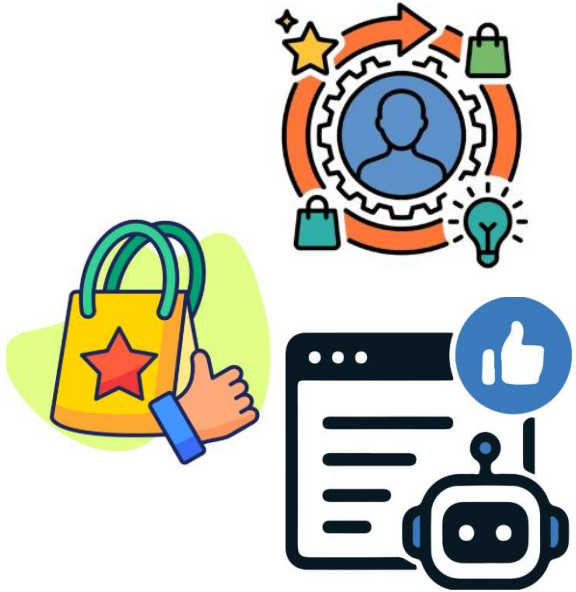


Recall@K

O que é: Fração dos itens relevantes que foram capturados nos K primeiros.

Fórmula:

$$Recall@K = \frac{\text{itens relevantes nos top K}}{\text{total de itens relevantes}}$$



Interpretação: "De tudo que era relevante, quanto o sistema conseguiu trazer?"

Recall@K

Pergunta: "De todos os relevantes, quantos apareceram no Top-K?"

Fórmula:

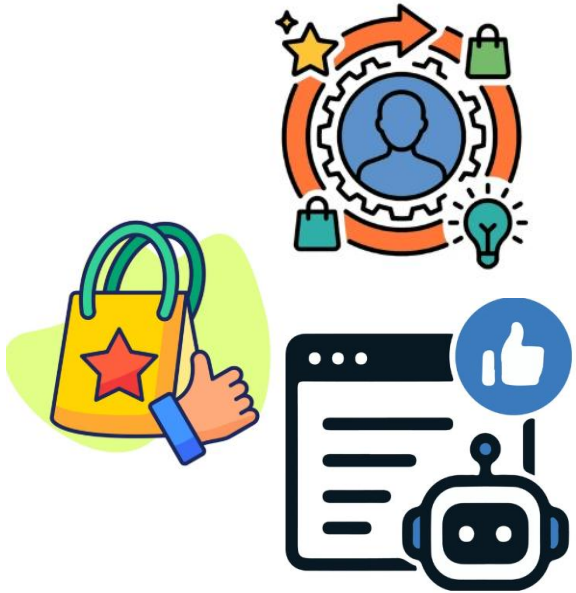
$$\text{Recall@K} = \frac{\text{relevantes no Top}-\text{K}}{\text{total de relevantes}}$$

Cálculo com K=5:

$$\text{Recall@5} = \frac{3}{3} = 1.00$$

Com K=3: $\frac{2}{3} \approx 0.67$

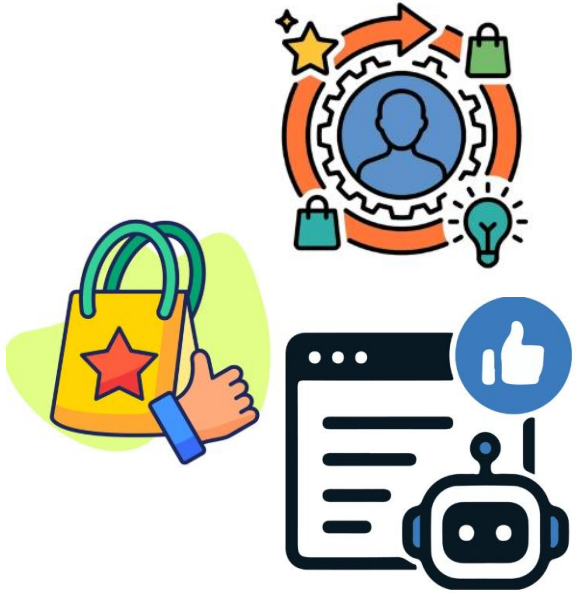
Interpretação: "Pegamos 100% dos filmes que Ana gostaria."



MAP@K (Mean Average Precision)

O que é: Média da Average Precision (AP) ao longo dos usuários.

AP: média das precisões calculadas em cada posição onde há um item relevante.



Fórmula (AP):

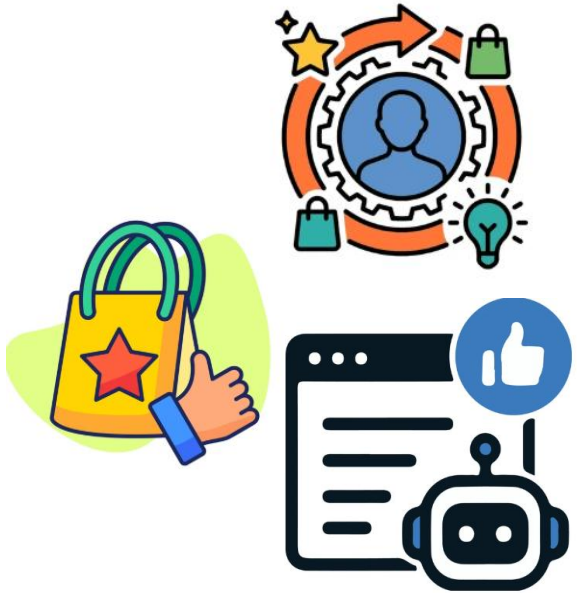
$$AP@K = \frac{1}{R}\sum_{k=1}^{K} Precision@k \cdot rel(k)$$

onde R= nº de itens relevantes e $\boldsymbol{rel(k)}$**= 1 se o item na posição k é relevante.**

MAP@K (Mean Average Precision)

Fórmula (AP):

$$AP@K = \frac{1}{R}\sum_{k=1}^{K} Precision@k \cdot rel(k)$$



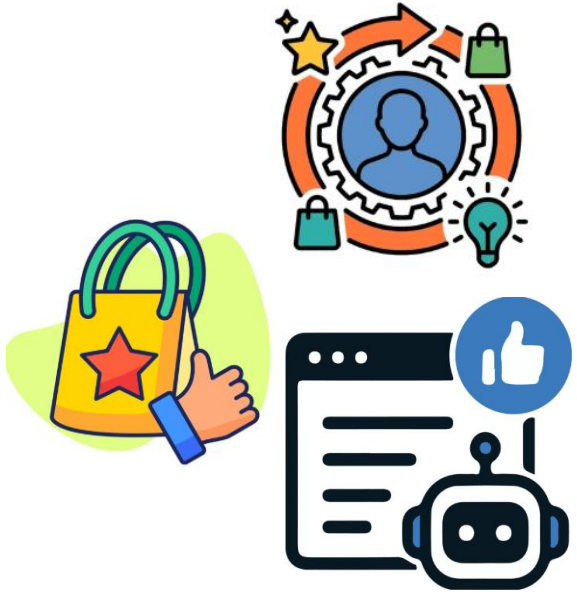
Interpretação: Recompensa recomendações relevantes **em posições mais altas**. É uma métrica mais completa que Precision@K isolada

MAP@K (Mean Average Precision)

Exemplo 3

Duas listas com Precision@5 = 0.6:

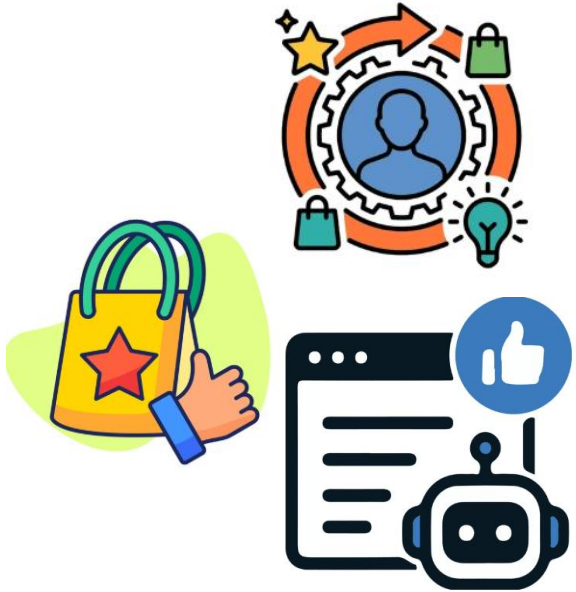
Lista A (boa)	Lista B (ruim)
✅ Matrix (1º)	❌ Toy Story (1º)
✅ Interestelar (2º)	❌ Titanic (2º)
✅ Pulp Fiction (3º)	❌ Diário (3º)
❌ Titanic	✅ Matrix (4º)
❌ Toy Story	✅ Interestelar (5º)



MAP@K (Mean Average Precision)

Ambas têm Precision@5 = 0.6, mas **A é melhor** porque acerta cedo.

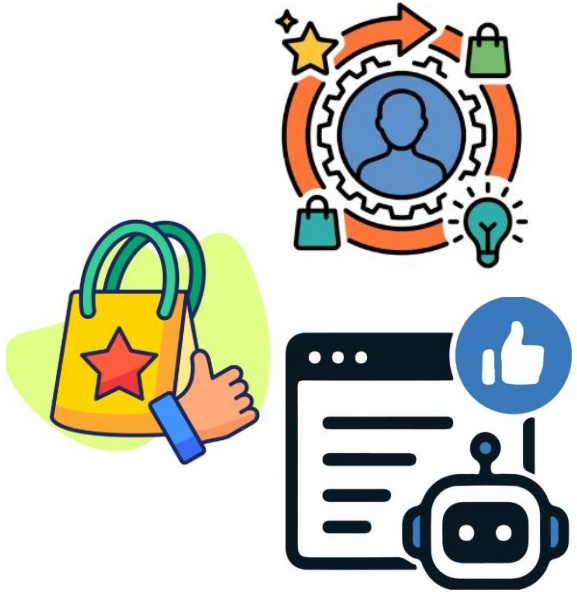
Precisamos de uma métrica que **valorize posições altas**



MAP@K (Mean Average Precision)

Cálculo para a Lista A (R=3):

k	Item	rel(k)	Precision@k	Contribuição
1	Matrix	1	1/1 = 1.00	1.00
2	Interestelar	1	2/2 = 1.00	1.00
3	Pulp Fiction	1	3/3 = 1.00	1.00
4	Titanic	0	—	0
5	Toy Story	0	—	0

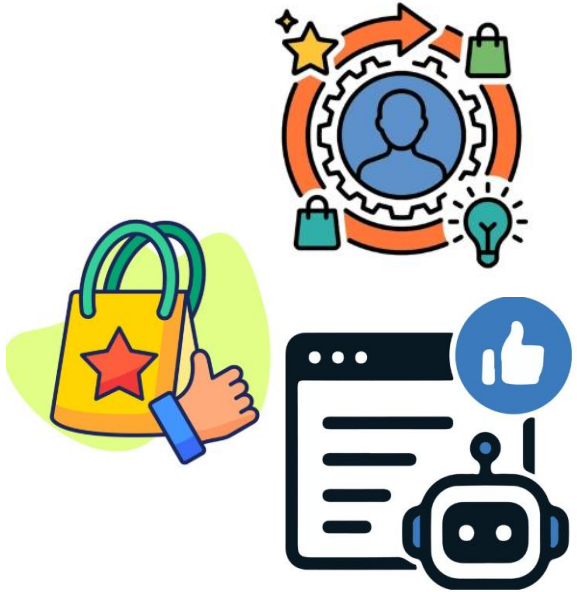


$$\text{AP@5(A)} = \frac{1+1+1}{3} = 1.00$$

MAP@K (Mean Average Precision)

Cálculo para a Lista B:

k	Item	rel(k)	Precision@k	Contribuição
1	Toy Story	0	—	0
2	Titanic	0	—	0
3	Diário	0	—	0
4	Matrix	1	1/4 = 0.25	0.25
5	Interestelar	1	2/5 = 0.40	0.40



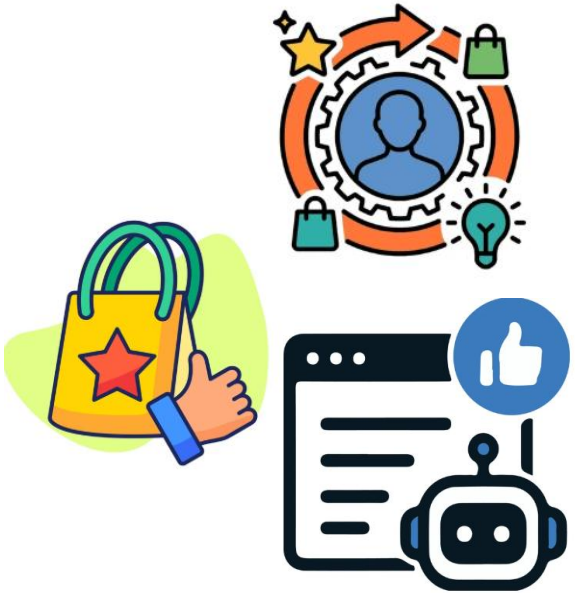
$$\text{AP@5(B)} = \frac{0.25 + 0.40}{3} \approx 0.217$$

NDCG@K (Normalized Discounted Cumulative Gain)

O que é: Mede o ganho acumulado considerando **graus de relevância** (não só binário) e **desconto pela posição**.

DCG@K:

$$DCG@K = \sum_{i=1}^{K} \frac{2^{rel_i} - 1}{\log_2(i+1)}$$

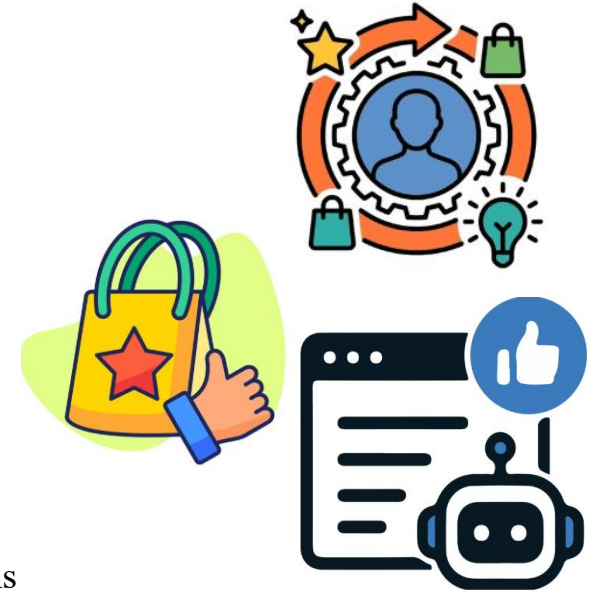


- rel_i= grau de relevância do item na posição i(ex.: nota real 1–5)
- O $\log_2$**desconta** itens em posições mais baixas

NDCG@K (Normalized Discounted Cumulative Gain)

NDCG@K:

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$



onde IDCG é o DCG da ordenação ideal.

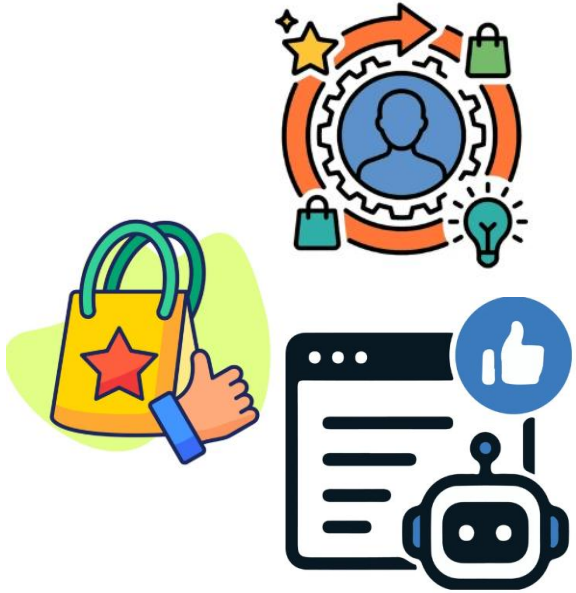
- **Interpretação:** Vai de 0 a 1. Itens relevantes no topo valem mais; itens menos relevantes contribuem menos. Ideal quando há **níveis de relevância** (ex.: nota 5 é mais relevante que nota 3).

NDCG@K (Normalized Discounted Cumulative Gain)

NDCG@K:

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$

onde IDCG é o DCG da ordenação ideal.



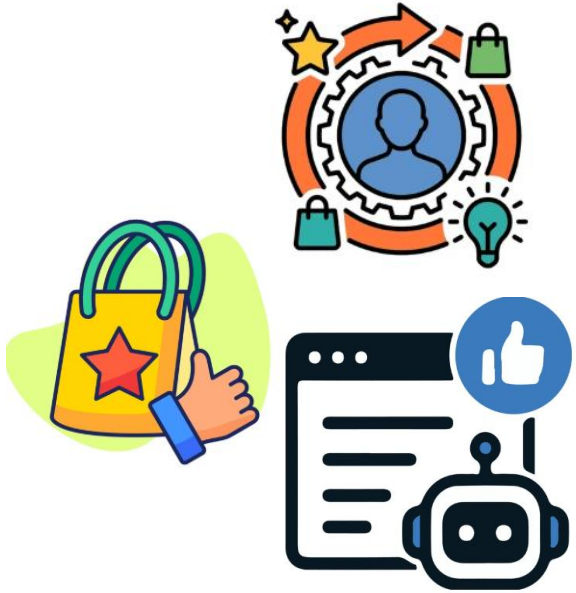
Interpretação: Vai de 0 a 1. Itens relevantes no topo valem mais; itens menos relevantes contribuem menos. Ideal quando há **níveis de relevância** (ex.: nota 5 é mais relevante que nota 3).

NDCG@K (Normalized Discounted Cumulative Gain)

NDCG@K:

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$

onde IDCG é o DCG da ordenação ideal.

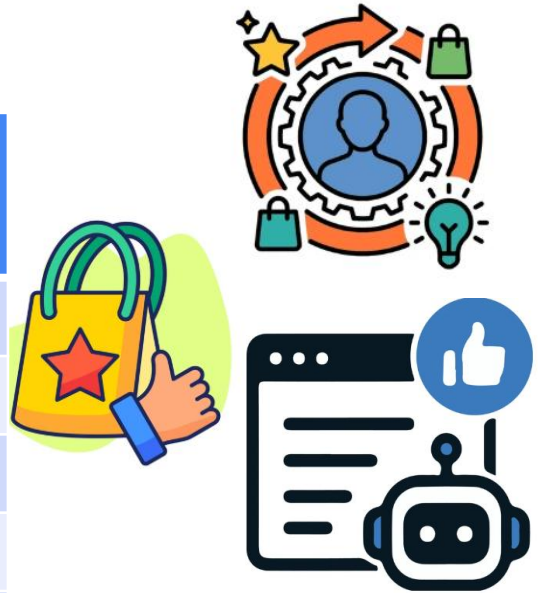


Interpretação: Vai de 0 a 1. Itens relevantes no topo valem mais; itens menos relevantes contribuem menos. Ideal quando há **níveis de relevância** (ex.: nota 5 é mais relevante que nota 3).

NDCG@K (Normalized Discounted Cumulative Gain)

Exemplo:

Posição	Filme	Nota real	Ganho $(2^{rel}-1)$	Desconto $\log_2(i+1)$	Contribuição
1	Matrix	5	31	1.00	31.00
2	Toy Story	2	3	1.58	1.90
3	Interestelar	5	31	2.00	15.50
4	Titanic	1	1	2.32	0.43
5	Pulp Fiction	4	15	2.58	5.81

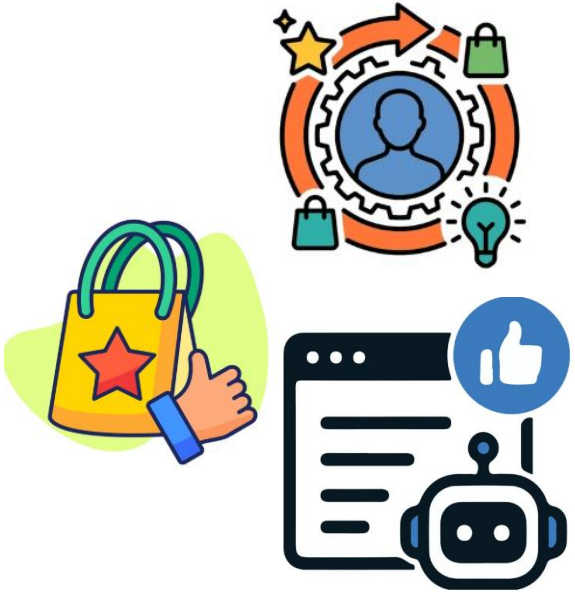


DCG@5=31+1.90+15.50+0.43+5.81=54.64

NDCG@K (Normalized Discounted Cumulative Gain)

Normalização (IDCG): calculamos o DCG da **ordenação ideal** (relevantes no topo):

Posição ideal	Nota	Ganho	Desconto	Contribuição
1	5	31	1.00	31.00
2	5	31	1.58	19.62
3	4	15	2.00	7.50
4	2	3	2.32	1.29
5	1	1	2.58	0.39



NDCG@K (Normalized Discounted Cumulative Gain)

Portanto,

$$\text{IDCG@5} = 59.80$$

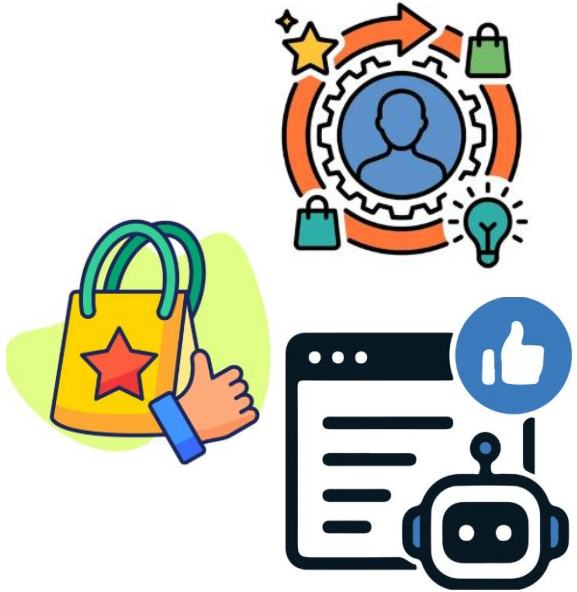
$$\text{NDCG@5} = \frac{54.64}{59.80} \approx 0.914$$



Interpretação: NDCG varia de **0 a 1**. 1 = ordenação perfeita. 0.914 = excelente!

Comparativo entre métricas de ranking

Métrica	Vantagem	Limitação
Precision@K	Simples e intuitiva	Ignora posição
Recall@K	Mede cobertura	Ignora posição
MAP@K	Valoriza posição	Relevância binária
NDCG@K	Valoriza posição e grau	Mais complexa



Sistemas de recomendação

Implementando .....

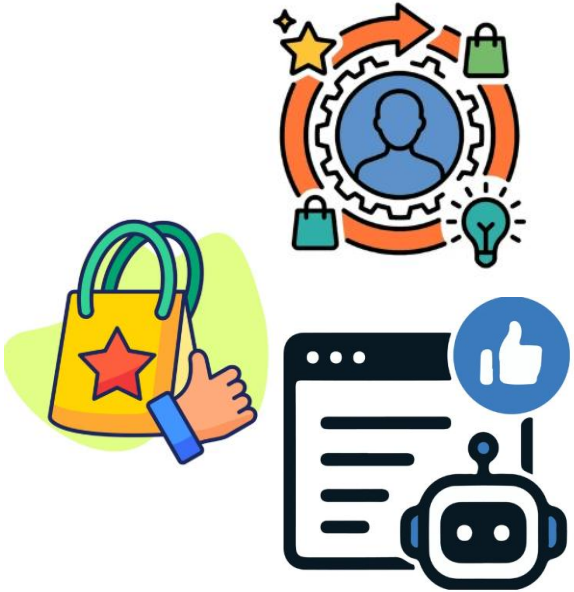


Métricas de Negócio e Diversidade

Conceito

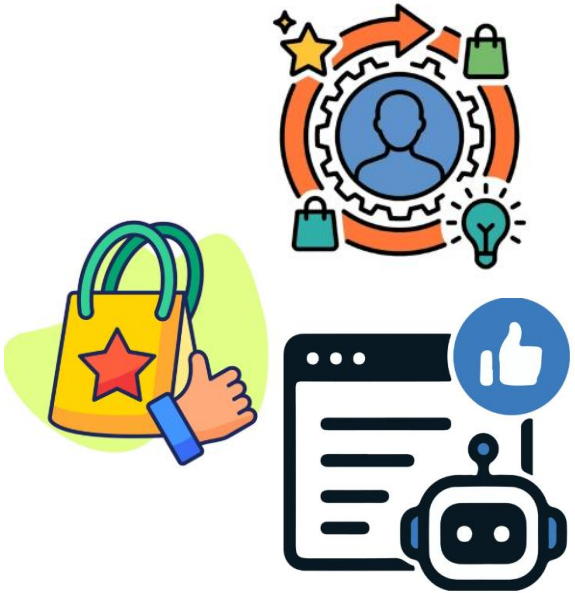
Acertar recomendações **não é suficiente**. Um bom sistema também precisa:

- **Variedade** (não recomendar só best-sellers)
- **Novidade** (surpreender o usuário)
- **Serendipidade** (acertar o inesperado)
- **Diversidade** (não entregar 10 filmes iguais)



Métricas de Negócio e Diversidade

Cobertura (Coverage)



Pergunta: "Qual fração do catálogo o sistema consegue recomendar?"

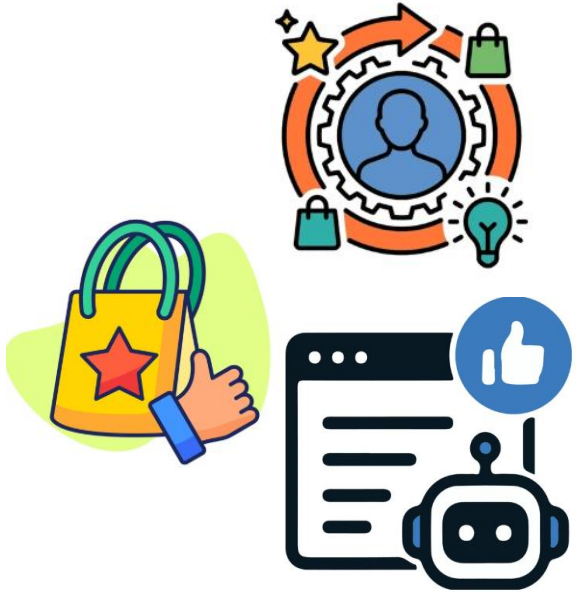
Fórmula:

$$\text{Coverage} = \frac{|\ \text{itens recomendados ao menos uma vez}\ |}{|\ \text{catalogo total}\ |}$$

Métricas de Negócio e Diversidade

Exemplo: Catálogo tem 10.000 filmes. O sistema recomendou 3.200 filmes distintos para todos os usuários.

$$\text{Coverage} = \frac{3200}{10000} = 0.32 \ (32\%)$$



Por que importa?

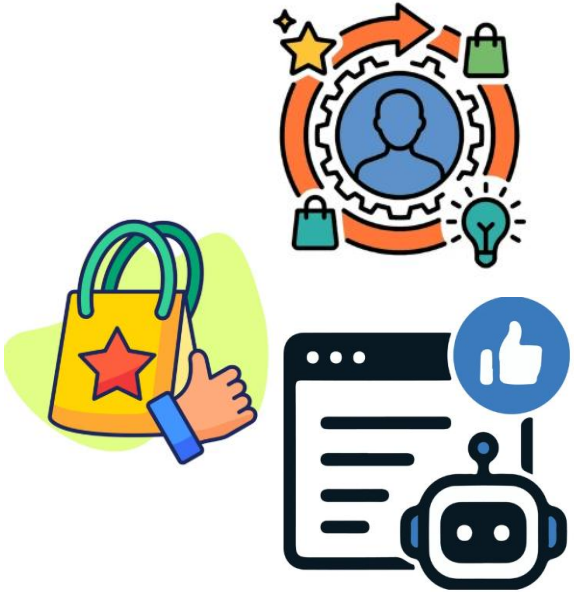
Cobertura baixa = sistema viciado nos mesmos itens populares.

Cobertura alta = sistema explora a **cauda longa** do catálogo

Métricas de Negócio e Diversidade

Novidade (Novelty)

Pergunta: "Os itens recomendados são incomuns/pouco populares?"



Fórmula típica (baseada em popularidade):

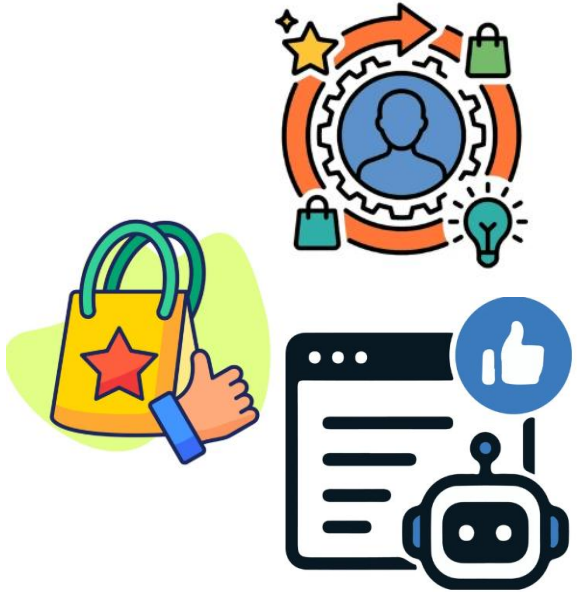
$$\text{Novelty}(i) = -\log_2\big(p(i)\big)$$

Onde $p(i)$= probabilidade (popularidade) do item $i$no dataset.

Métricas de Negócio e Diversidade

Novidade (Novelty)

Filme	Popularidade $p(i)$	Novelty $-\log_2(p)$
Matrix (blockbuster)	0.50	1.00
Interestelar	0.20	2.32
Filme cult	0.01	6.64



Interpretação: Itens populares têm baixa novidade; itens raros têm alta novidade.

Cuidado: Novidade alta demais pode virar **irrelevância** — o usuário nunca ouviu falar e não se interessa

Métricas de Negócio e Diversidade

Pergunta: "As recomendações são **inesperadas, mas agradáveis**?"

Serendipidade = **Surpresa** + **Relevância**

Exemplo prático:

- **Não é serendipidade:** recomendar "Star Wars" para quem já viu todos os filmes da saga.
- **Também não é:** recomendar um documentário sobre fungos para quem só assiste ação.
- **É serendipidade:** recomendar "Interestelar" para alguém que nunca assistiu sci-fi, mas descobriu que ama o gênero.



Métricas de Negócio e Diversidade

Pergunta: "As recomendações são **inesperadas, mas agradáveis**?"

Serendipidade = **Surpresa** + **Relevância**

Exemplo prático:

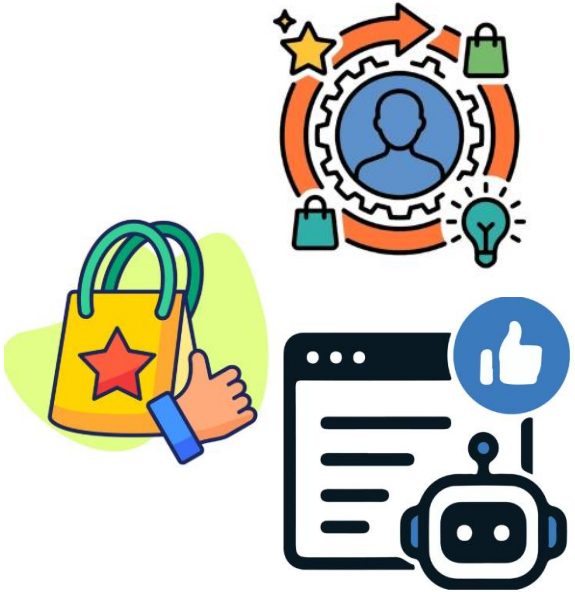
- **Não é serendipidade:** recomendar "Star Wars" para quem já viu todos os filmes da saga.
- **Também não é:** recomendar um documentário sobre fungos para quem só assiste ação.
- **É serendipidade:** recomendar "Interestelar" para alguém que nunca assistiu sci-fi, mas descobriu que ama o gênero.



Métricas de Negócio e Diversidade

Por que é difícil de medir?

- Precisa de **contexto do usuário** (o que ele já conhece).
- Precisa de **julgamento de valor** (o que é "agradável").
- Geralmente avaliada com **estudos com usuários** (A/B tests, questionários).



Sistemas de recomendação

BIBLIOGRAFIA BÁSICA

HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. Melbourne: OTexts, 2021.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. Time Series Analysis: Forecasting and Control. 5. ed. Hoboken: Wiley, 2015.

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016. 6.

BIBLIOGRAFIA COMPLEMENTAR

RICCI, F.; ROKACH, L.; SHAPIRA, B. Recommender Systems Handbook. 2. ed. Cham: Springer, 2022. • GRUS, J. Data Science do Zero. 2. ed. Rio de Janeiro: Alta Books, 2020.

ALMEIDA, J. M. et al. Sistemas de Recomendação. Rio de Janeiro: LTC, 2016. • MORETTIN, P. A.; TOLOI, C. M. C. Análise de Séries Temporais. 3. ed. São Paulo: Blucher, 2018.

BROWNLEE, J. Deep Learning for Time Series Forecasting. Melbourne: Machine Learning Mastery, 2018.


Facens
AQUI TEM ENGENHARIA