

Grade Curricular:

Encontro I Fundamentos de Séries Temporais e Modelos Clássicos

- Apresentações
- Grade Curricular
- Objetivos
- Método de Ensino
- Critérios de Avaliação
- Referências Bibliográficas
- **Modelos Clássicos**
 - Definição e componentes de séries temporais (Tendência, Sazonalidade, Ciclo e Ruído)
 - Estacionariedade e testes (ADF, KPSS).
 - Função de Autocorrelação (FAC) e Autocorrelação Parcial (FACP).
 - Modelo SARIMA (diferenciação ordinária e sazonal)
 - Validação de resíduos (Ruído Branco - Teste de Ljung-Box).
 - Exercícios resolvidos.
 - Atividade prática
- **Modelos de Aditivos Modernos (Prophet)**
 - Arquitetura do Prophet (Meta/Facebook): Tendência não linear, sazonalidade via Séries de Fourier e efeito de feriados.
 - Tratamento de outliers e valores ausentes.
 - Exercícios resolvidos
 - Atividade prática
- **Atividades práticas em aula**
- **Datasets**
 - AirPassengers
 - Johnson&Johnson
 - Nile
 - UKgas
 - USAccDeaths
 - Shampoo Sales.

Encontro II Deep Learning e Transformers para Séries Temporais

- **Abordagem com MLP (Multilayer Perceptron):**
 - Conceito de janela deslizante (*sliding window*) para criar features defasadas.
 - Estrutura da rede: camadas densas e função de ativação (ex: ReLU).
 - Limitações: ausência de memória de estado e dificuldade com dependências de longo prazo.
- **Abordagem com RNN (Redes Neurais Recorrentes):**
 - Introdução ao conceito de memória sequencial e o problema do gradiente vanishing.
 - Arquitetura LSTM (Long Short-Term Memory): células de memória com portas (*input, forget, output*).
 - Vantagens da LSTM para capturar dependências de longo prazo em séries temporais.
- **Aspectos Práticos e de Implementação**
 - Pré-processamento de Dados:
 - Normalização (Min-Max Scaling ou Standardization) para melhorar a convergência da rede.
 - Divisão dos dados em treino, validação e teste (com validação *walk-forward* para evitar *data leakage*)
- **Atividades práticas em aula**
- **Datasets**
 - SPAM.csv, Tweets.csv
 - London bike sharing dataset
 - S&P 500 Stock Data (Kaggle)
 - Wheat Price Forecasting Dataset
 - Jena Climate Dataset (Max Planck Institute)
 - Hourly Energy Consumption (Kaggle - PJM Interconnection)

Encontro III Transformers Temporais e Introdução a Sistemas de Recomendação

- **Transformers Temporais:**
 - Por que a atenção funciona bem em dados temporais?
 - Mecanismo de Self-Attention e Codificação Posicional (*Positional Encoding*).
 - Introdução a arquiteturas modernas para séries temporais.
- **Introdução aos Sistemas de Recomendação:**
 - O problema do *Overload* de informação e o papel do SysRec no negócio.
 - Tipos de Feedback: Implícito (cliques, tempo de tela) vs. Explícito (avaliações de 1 a 5 estrelas).
- **Filtragem Baseada em Conteúdo (Content-Based):**
 - Representação de itens por vetores de características
 - Cálculo de similaridade
- **Filtragem Colaborativa (Collaborative Filtering):**
 - Baseada em Vizinhaça: *User-Based* e *Item-Based* (k-NN).
 - Fatoração de Matrizes: SVD (Singular Value Decomposition) e ALS (Alternating Least Squares).
- **Atividades práticas em aula**
- **Datasets**
 - MovieLens
 - Book-Crossing Dataset
 - TMDb 5000 / Netflix Movies Dataset:
 - Goodreads Books Dataset:

Encontro IV Métricas Avançadas, Escalabilidade e Produção

- **Métricas de Recomendação:**

- Métricas de Precisão do Chute: RMSE, MAE.
- Métricas de Ranking: Precision@K, Recall@K, MAP@K (Mean Average Precision) e NDCG@K (Normalized Discounted Cumulative Gain).
- Métricas de Negócio e Diversidade: Cobertura (Coverage), Novidade (Novelty), Serendipidade e Diversidade da lista.

- **Escalabilidade e Processamento:**

- O problema da matriz esparsa em grande escala.
- Busca por Vizinhos Mais Próximos Aproximados (ANN - Approximate Nearest Neighbors) usando bibliotecas como **Faiss** ou **Annoy**.
- Arquiteturas de Recomendação em 2 Estágios: *Retrieval* (Candidatos) + *Ranking* (Re-ordenação).

- **Dataset**

- E-commerce Clickstream / Instacart Market Basket Analysis Dataset

Estágios de Aprendizado:

Estágio I 01 encontros	Compreender a estrutura de dados temporais, dominar a modelagem clássica (ARIMA) e aplicar modelos estatísticos modernos/robustos (Prophet) para lidar com sazonalidade e feriados..
Estágio II 2 encontros	Evoluir dos modelos estatísticos para arquiteturas de aprendizado profundo, entendendo o papel das redes recorrentes e a revolução dos Transformers no domínio temporal.
Estágio III 3 encontros	Compreender a taxonomia dos Sistemas de Recomendação (SysRec), implementar abordagens clássicas baseadas em conteúdo e dominar a Filtragem Colaborativa via Fatoração de Matrizes.
Estágio IV 4 encontros	Avaliar sistemas de recomendação além da acurácia, compreender os desafios de escalar algoritmos para milhões de usuários/itens e projetar arquiteturas de produção.

Ferramentas & Tecnologias:

Google Colab	Plataforma de desenvolvimento com Markdown (demonstrações de conexões e uso de Banco de Dados).
--------------	---